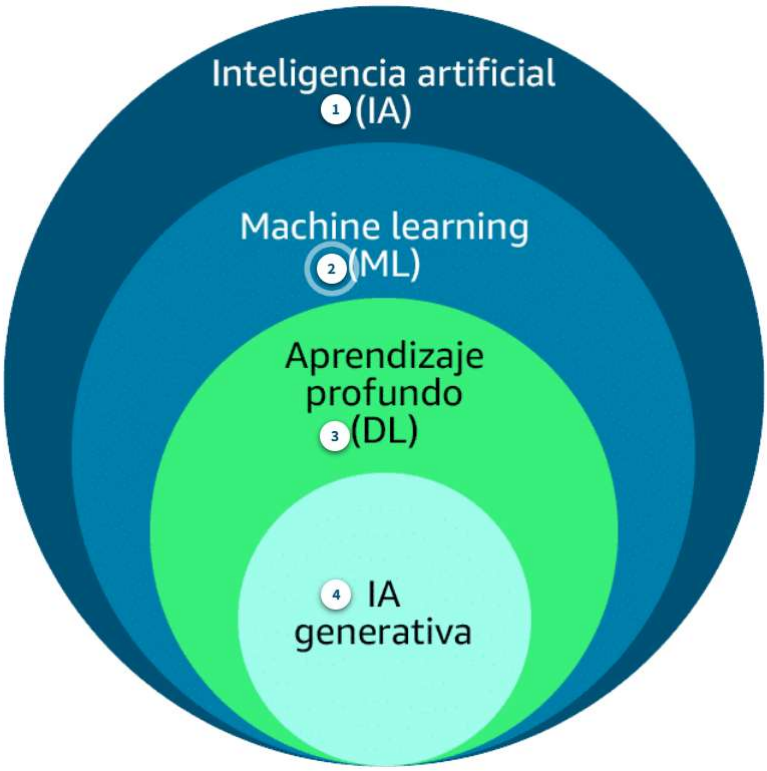
FUNDAMENTALS OF MACHINE LEARNING AND ARTIFICIAL INTELLIGENCE

INTRODUCCIÓN.

Relación entre la IA, el ML, aprendizaje profundo e IA generativa.



1. **Inteligencia Artificial (IA).** La IA es un campo amplio que abarca el desarrollo de sistemas inteligentes capaces de realizar tareas que normalmente requieren inteligencia humana, como la percepción, el razonamiento, el aprendizaje, la resolución de problemas y la toma de decisiones. La IA sirve como un término que abarca varias técnicas y abordajes, incluidos el machine learning, el aprendizaje profundo y la IA generativa, entre otros.
2. **Machine learning (ML).** El ML es un tipo de IA que permite comprender y crear métodos que hacen posible que las máquinas aprendan. Estos métodos utilizan datos para mejorar el rendimiento de las computadoras en un conjunto de tareas.
3. **Aprendizaje profundo (DL).** El aprendizaje profundo (o deep learning) usa el concepto de neuronas y sinapsis de forma similar a cómo está conectado nuestro cerebro. Un ejemplo de aplicación de aprendizaje profundo es Amazon Rekognition, que puede analizar en cuestión de segundos millones de imágenes y videos en streaming y almacenados.

4. **IA Generativa.** La IA generativa es un subconjunto del aprendizaje profundo porque puede adaptar modelos creados mediante el aprendizaje profundo, pero sin la necesidad de reentrenamiento ni ajustes. Los sistemas de IA generativa son capaces de generar nuevos datos en función de los patrones y estructuras aprendidos de los datos de entrenamiento.

ASPECTOS BÁSICOS DE LA INTELIGENCIA ARTIFICIAL.

Aspectos básicos del machine learning.

La creación de un modelo de machine learning implica la recopilación y preparación de datos, la selección de un algoritmo adecuado, el entrenamiento del modelo con los datos preparados y la evaluación de su rendimiento mediante pruebas e iteraciones.

Datos de entrenamiento:



El proceso de machine learning comienza con la recopilación y el procesamiento de los datos de entrenamiento. Los datos de mala calidad suelen denominarse *basura que entra* y *basura que sale*, por lo que un modelo de machine learning es tan bueno como los datos que se utilizan para entrenarlo. Si bien la preparación y el procesamiento de los datos a veces son un proceso rutinario, podría decirse que es la etapa más crítica para hacer que todo el modelo funcione según lo previsto o perjudicar su rendimiento.

Hay varios tipos diferentes de datos que se utilizan para entrenar un modelo de ML. En primer lugar, es importante conocer la diferencia entre los datos etiquetados y los no etiquetados.

- **Datos etiquetados:**

  Los datos etiquetados son un conjunto de datos en el que cada instancia o ejemplo va acompañado de una etiqueta o variable de destino que representa el resultado o la clasificación que se espera. Por lo general, estas etiquetas las proporcionan expertos humanos o se obtienen mediante un proceso confiable.

  Ejemplo: En una tarea de clasificación de imágenes, los datos etiquetados consistirían en imágenes junto con sus etiquetas de clase correspondientes (por ejemplo, gato, perro, automóvil).

- **Datos sin etiquetar:**

  Los datos sin etiquetar son un conjunto de datos en el que las instancias o los ejemplos no tienen etiquetas ni variables de destino asociadas. Los datos se componen únicamente de características de entrada, sin ningún resultado ni una clasificación correspondiente.

  Ejemplo: una recopilación de imágenes sin etiquetas ni anotaciones

Los principales tipos de datos que se utilizan en el entrenamiento son los datos estructurados y no estructurados. Existen varios subtipos, que se pueden ver al expandir las siguientes categorías.

- **Datos estructurados:**

  Los datos estructurados se refieren a los datos que están organizados y tienen un formato predefinido, normalmente en forma de tablas o bases de datos con filas y columnas. Este tipo de datos es adecuado para los algoritmos tradicionales de machine learning que requieren características y etiquetas bien definidas. A continuación, se detallan los tipos de datos estructurados.

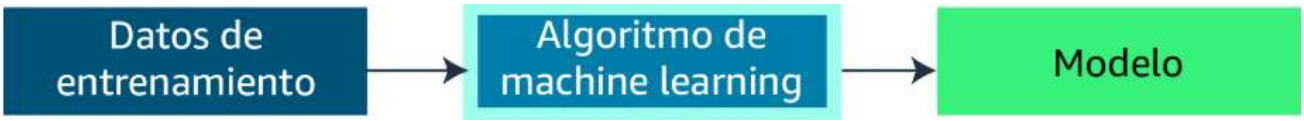
  - ✓ **Datos tabulares:** Esto incluye los datos almacenados en hojas de cálculo, bases de datos o archivos CSV, con filas que representan instancias y columnas que representan características o atributos.
  - ✓ **Datos de series temporales:** Este tipo de datos consiste en secuencias de valores que se miden en puntos sucesivos en el tiempo, como los precios de las acciones, las lecturas de los sensores o los datos meteorológicos.

- **Datos no estructurados:**

  Los datos no estructurados son aquellos que carecen de una estructura o formato predefinidos, como texto, imágenes, audio y video. Este tipo de datos requiere técnicas de machine learning más avanzadas para extraer patrones e información significativos.

  - ✓ **Datos de texto:** Esto incluye documentos, artículos, publicaciones en redes sociales y otros datos textuales.
  - ✓ **Datos de imagen:** Esto incluye imágenes digitales, fotografías y fotogramas de video.

Proceso de machine learning:



Los datos de entrenamiento compilados se cargan en algoritmos de machine learning. El proceso de ML se divide tradicionalmente en tres categorías amplias: el *aprendizaje supervisado*, el *aprendizaje no supervisado* y el *aprendizaje por refuerzo*.



En el *aprendizaje supervisado*, los algoritmos se entrenan con datos etiquetados. El objetivo es aprender una función de mapeo que pueda predecir el resultado de nuevos datos de entrada no vistos.

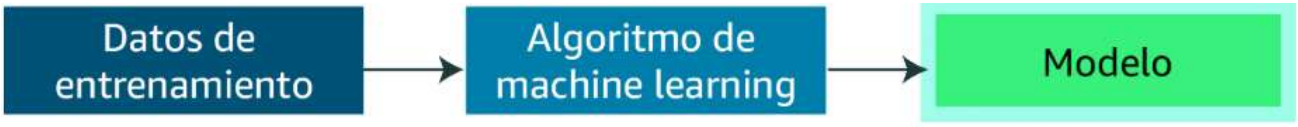


El *aprendizaje no supervisado* se refiere a los algoritmos que aprenden a partir de datos no etiquetados. El objetivo es descubrir patrones, estructuras o relaciones inherentes dentro de los datos de entrada.



En el *aprendizaje por refuerzo*, la máquina solo recibe una puntuación de rendimiento como guía; en el aprendizaje semisupervisado, solo se etiqueta una parte de los datos de entrenamiento. La retroalimentación se hace en forma de recompensas o penalizaciones por las acciones de la máquina y esta aprende de estos comentarios para mejorar las decisiones que toma con el paso del tiempo.

Inferencia



Una vez que se ha entrenado el modelo, es hora de comenzar el proceso de usar la información que un modelo ha aprendido para hacer predicciones o tomar decisiones. Esto se denomina inferencia.

Hay dos tipos principales de inferencia en el machine learning: la inferencia por lotes y la inferencia en tiempo real.

- **Inferencia por lotes:**

  La inferencia por lotes se produce cuando la computadora toma una gran cantidad de datos, como imágenes o texto, y los analiza todos a la vez para ofrecer un conjunto de resultados. Este tipo de inferencia se usa a menudo para tareas como el análisis de datos, donde la velocidad del proceso de toma de decisiones no es tan crucial como la precisión de los resultados en sí.

- **Inferencia en tiempo real:**

  La inferencia en tiempo real es cuando la computadora tiene que tomar decisiones rápidamente, en respuesta a la nueva información a medida que se recibe. Esto es importante para las aplicaciones en las que la toma de decisiones inmediata es fundamental, como en los chatbots o los vehículos autónomos. La computadora tiene que procesar los datos entrantes y tomar una decisión casi instantáneamente, pero no tiene tiempo para analizar un conjunto de datos amplio.

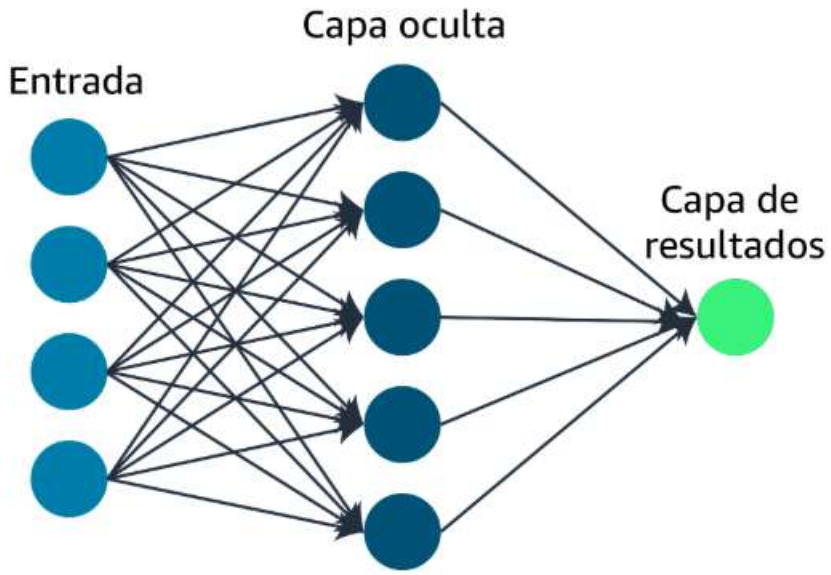
Tanto la inferencia por lotes como la inferencia en tiempo real tienen sus propias ventajas y casos prácticos únicos. Su caso práctico determinará el tipo de inferencia que utiliza.

Aspectos básicos del aprendizaje profundo.

El campo del aprendizaje profundo se inspira en la estructura y función del cerebro. Implica el uso de redes neuronales artificiales, que son modelos computacionales diseñados para imitar la forma en que el cerebro humano procesa la información.

Redes neuronales:

En el centro del aprendizaje profundo se encuentran las redes neuronales. Al igual que nuestros cerebros tienen neuronas que están conectadas entre sí, las redes neuronales tienen muchas unidades diminutas llamadas nodos que están interconectados. Estos nodos se organizan en capas. Las capas incluyen una capa de entrada, una o más capas ocultas y una capa de resultados.



Cuando mostramos muchos ejemplos a una red neuronal, como datos sobre clientes que compraron ciertos productos o usaron ciertos servicios, ella descubre cómo identificar patrones ajustando las conexiones entre sus nodos. Es como si los nodos hablaran entre sí y, poco a poco, descubrieran los patrones que separan a los diferentes tipos de clientes.

Cuando una red neuronal aprende a reconocer estos patrones a partir de los ejemplos, puede analizar los datos de clientes completamente nuevos que nunca había visto antes y, aun así, hacer predicciones sobre lo que podrían comprar o cómo podrían comportarse.

Las siguientes son algunas de las ramas de la IA en las que se utiliza el aprendizaje profundo para mejorar los resultados.

- **Visión artificial:**

  La visión artificial es un campo de la inteligencia artificial que hace posible que las computadoras interpreten y comprendan videos e imágenes digitales. El aprendizaje profundo ha revolucionado la visión artificial, ya que proporciona técnicas poderosas para tareas como la clasificación de imágenes, la detección de objetos y la segmentación de imágenes.

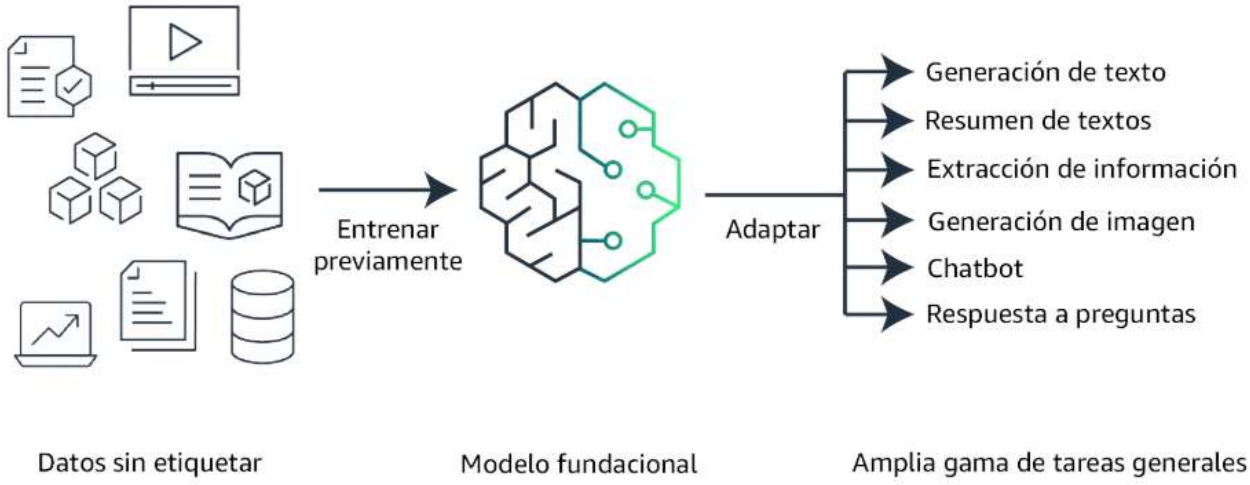
- **Procesamiento de lenguaje natural (NLP):**

  El procesamiento del lenguaje natural (NLP) es una rama de la inteligencia artificial que se ocupa de la interacción entre las computadoras y los lenguajes humanos. El aprendizaje profundo ha logrado avances significativos en el NLP, lo que posibilita tareas como la clasificación de textos, el análisis de sentimientos, la traducción automática y la generación de lenguaje.

Aspectos básicos de la IA generativa.

El machine learning existe desde hace décadas, lo que plantea la pregunta: ¿qué ha llevado al surgimiento de la IA generativa en este momento? La respuesta es sencilla: han sido las enormes inversiones en recursos. Contratar a un equipo grande, gastar en recursos de cómputo y, lo que es importante, tener la voluntad de invertir en grandes ideas y desarrollarlas son factores que contribuyen al crecimiento de la IA generativa.

Modelos funcionales:



La IA generativa se basa en modelos que están entrenados previamente con datos a escala de Internet. Estos modelos se denominan modelos fundacionales (FM). Con los FM, en lugar de recopilar datos etiquetados para cada modelo y entrenar varios modelos como en el ML tradicional, puede adaptar un solo FM para que realice múltiples tareas. Estas tareas incluyen la generación de texto, el resumen del texto, la extracción de información, la generación de imágenes, las interacciones con los chatbots y las respuestas a preguntas. Los FM también pueden servir como punto de partida para desarrollar modelos más especializados.

Para obtener más información sobre el ciclo de vida del modelo fundacional, elija los botones de flecha para ver cada una de las ocho diapositivas siguientes.

Ciclo de vida de los FM:

El ciclo de vida del modelo fundacional es un proceso integral que incluye varias etapas, cada una de las cuales desempeña un rol crucial en el desarrollo y la implementación de modelos fundacionales efectivos y fiables.

Paso 1 – Selección de datos.

Los datos sin etiquetar se pueden usar a escala para el entrenamiento previo, ya que son mucho más fáciles de obtener en comparación con los datos etiquetados. Los datos sin etiquetar incluyen datos sin procesar, como imágenes, archivos de texto o videos, sin etiquetas informativas significativas que proporcionen contexto. Los FM requieren entrenamiento sobre conjuntos de datos masivos de diversas fuentes.

Paso 2 – Entrenamiento previo.

Si bien los modelos tradicionales de ML se basan en patrones de aprendizaje supervisados, no supervisados o por refuerzo, los FM suelen entrenarse previamente mediante un aprendizaje autosupervisado. Con el

aprendizaje autosupervisado, no se requieren los ejemplos etiquetados. El aprendizaje autosupervisado utiliza la estructura de los datos para generar etiquetas automáticamente.
Durante la etapa inicial de entrenamiento previo, el algoritmo del FM puede aprender el significado, el contexto y la relación de las palabras en los conjuntos de datos. Por ejemplo, el modelo podría aprender si la palabra "tomar" se refiere a "bebida" (el sustantivo) o a "tragar líquido" (el verbo).

Después del preentrenamiento inicial, el modelo se puede seguir entrenando con datos adicionales. Esto se conoce como entrenamiento previo continuo. El objetivo es ampliar la base de conocimientos del modelo y mejorar su capacidad para comprender y generalizar en diferentes dominios o tareas.

Paso 3 – Optimización.
Los modelos de lenguaje entrenados previamente se pueden optimizar mediante técnicas como la ingeniería de peticiones, la generación aumentada por recuperación (RAG) y el ajuste de los datos específicos de las tareas. Estos métodos varían en complejidad y costo, y se analizarán más adelante en esta lección.

Paso 4 – Evaluación.
Ya sea que ajuste o no un modelo, o utilice un modelo previamente entrenado ya disponible, el siguiente paso lógico es evaluarlo. El rendimiento de un FM se puede medir utilizando las métricas y puntos de referencia adecuados. Es importante evaluar el rendimiento del modelo y su capacidad para satisfacer las necesidades empresariales.

Paso 5 – Implementación.
Cuando el FM cumple con los criterios de rendimiento deseados, se puede implementar en el entorno de producción de destino. La implementación puede implicar la integración del modelo en aplicaciones, API u otros sistemas de software.

Paso 6 – Retroalimentación y mejora continua.
Tras la implementación, el rendimiento del modelo se monitorea continuamente y se recopila la retroalimentación de los usuarios, los expertos en el dominio y otras partes interesadas. Esta retroalimentación, junto con los datos de monitoreo del modelo, se usa para identificar áreas de mejora, detectar posibles sesgos o desviaciones e informar sobre futuras iteraciones del modelo. El bucle de retroalimentación permite la mejora continua del modelo fundacional mediante el ajuste, el entrenamiento previo continuo o el reentrenamiento, según sea necesario.

Es importante tener en cuenta que el ciclo de vida de la FM es un proceso iterativo, en el que las lecciones aprendidas y los conocimientos adquiridos en cada etapa pueden informar y mejorar las iteraciones posteriores.

Amazon Bedrock da acceso a una selección de FM de alto rendimiento de empresas líderes en IA, como AI21 Labs, Anthropic, Cohere, Meta, Mistral AI, Stability AI y Amazon.
Con estos FM como base, puede optimizar aún más sus resultados con ingeniería de peticiones, ajuste o RAG.

Hay algunos tipos de FM que son esenciales para comprender las capacidades de la IA generativa.

Modelos de lenguaje grande

Los modelos de lenguaje grande (LLM) se pueden basar en una variedad de arquitecturas, pero la más común en los modelos de última generación actuales es la arquitectura de transformadores. Los LLM basados en transformadores son modelos útiles que pueden entender y generar texto similar al humano. Están entrenados con grandes cantidades de datos de texto de Internet, libros y otras fuentes, y aprenden patrones y relaciones entre palabras y frases.
Para entender mejor cómo funcionan los LLM, elija las siguientes pestañas para obtener información sobre los tokens, las integraciones y los vectores.

- **Tokens:**

  Los tokens son las unidades básicas de texto que el modelo procesa. Pueden ser palabras, frases o caracteres individuales como un punto. Los tokens también ofrecen la estandarización de los datos de entrada, lo que facilita que el modelo los procese.

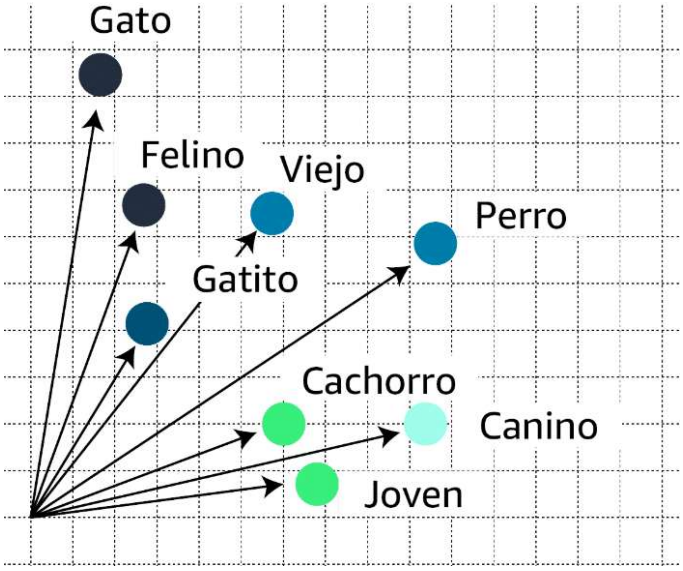
  Como ejemplo, la frase “Un cachorro es a un perro lo que un gatito es a un gato” puede dividirse en los siguientes tokens: “Un” “cachorro” “es” “a” “un” “perro” “lo” “que” “un” “gatito” “es” “a” “un” “gato”.



- **Integraciones y vectores:**

  Las integraciones son representaciones numéricas de los tokens, en las que a cada token se le asigna un vector (una lista de números) que captura su significado y sus relaciones con otros tokens. Estos vectores se aprenden durante el proceso de entrenamiento y permiten que el modelo comprenda el contexto y los matices del lenguaje.

Por ejemplo, el vector de integración del token “gato” puede estar cerca de los vectores “felino” y “gatito” en el espacio de integración, lo que indica que están relacionados semánticamente. De esta manera, el modelo puede entender que “gato” es similar a “felino” y a “gatito” sin estar programado explícitamente con esas relaciones.



Los LLM utilizan estos tokens, integraciones y vectores para comprender y generar texto. Los modelos pueden captar relaciones complejas en el lenguaje, de modo que pueden generar un texto coherente y apropiado para el contexto, responder preguntas, resumir información e incluso dedicarse a la escritura creativa.

Modelos de difusión

La difusión es un sistema de arquitectura de aprendizaje profundo que comienza con ruido puro o datos aleatorios. Los modelos agregan gradualmente más y más información significativa a este ruido hasta que terminan con un resultado claro y coherente, como una imagen o un fragmento de texto. Los modelos de difusión aprenden a través de un proceso de dos pasos de difusión directa y difusión inversa.

- **Difusión directa:**

  Mediante la difusión directa, el sistema introduce gradualmente una pequeña cantidad de ruido en una imagen de entrada hasta que solo queda el ruido.



- **Difusión inversa:**

  En la etapa de difusión inversa subsiguiente, la imagen ruidosa se introduce gradualmente en la eliminación del ruido hasta que se genera una nueva imagen.



Aunque algunas de las aplicaciones más conocidas e impresionantes de los modelos de difusión han sido los modelos de conversión de texto a imagen, los modelos de difusión se pueden aplicar a una variedad de tareas más allá de la simple generación de imágenes.

Modelos multimodales

En lugar de depender únicamente de un único tipo de entrada o de resultado, como texto o imágenes, los modelos multimodales pueden procesar y generar varios modos de datos simultáneamente. Por ejemplo, un modelo multimodal podría tomar una imagen y algo de texto como entrada y, a continuación, generar una nueva imagen y un título que la describa como resultado.

Este tipo de modelos aprenden las maneras en que las diferentes modalidades, como las imágenes y el texto, se conectan y pueden influirse entre sí. Los modelos multimodales se pueden utilizar para automatizar los subtítulos de video, crear gráficos a partir de instrucciones por escrito, responder a las preguntas de forma más inteligente mediante la combinación de información textual y visual, e incluso traducir contenido manteniendo los elementos visuales relevantes.

Otros modelos generativos

Existen varios tipos de modelos generativos que se utilizan en el ML y la IA. Amplíe las siguientes pestañas para obtener más información sobre dos de estos modelos generativos que aún no se han abordado en esta lección.

- **Redes generativas antagónicas (GAN):**

  Las GAN son un tipo de modelo generativo que involucra a dos redes neuronales que compiten entre sí en un marco de juego de suma cero. Las dos redes son el generador y el discriminador.

  Generador: Esta red genera nuevos datos sintéticos (por ejemplo, imágenes, texto o audio) al tomar ruido aleatorio como entrada y transformarlo en datos que se asemejan a la distribución de datos de entrenamiento.

Discriminador: Esta red toma como entrada los datos reales del conjunto de entrenamiento y los datos sintéticos generados por el generador. Su objetivo es distinguir entre los datos reales y los generados.

Durante el entrenamiento, el generador intenta generar datos que puedan engañar al discriminador y hacerle creer que son reales, mientras que el discriminador trata de clasificar los datos reales y los datos generados de forma correcta. Este proceso contradictorio continúa hasta que el generador produce datos que no se pueden distinguir de los datos reales.

- **Codificadores automáticos variacionales (VAE):**
  Los VAE son un tipo de modelo generativo que combina ideas de autocodificadores (un tipo de red neuronal) e inferencia variacional (una técnica de la estadística bayesiana). En un VAE, el modelo consta de dos partes:

  Codificador: Esta red neuronal toma los datos de entrada (por ejemplo, una imagen) y los asigna a un espacio latente de menor dimensión que captura las características esenciales de los datos.

  Decodificador: Esta red neuronal toma la representación latente del codificador y genera una reconstrucción de los datos de entrada originales.

  El aspecto clave de los VAE es que se busca que el espacio latente siga una distribución de probabilidad específica (normalmente una distribución gaussiana), lo que permite generar nuevos datos mediante el muestreo de este espacio latente y el paso de las muestras por el decodificador.

Optimización de los resultados del modelo:

Una parte clave del ciclo de vida del modelo fundacional es la fase de optimización. Un FM se puede optimizar aún más de varias maneras diferentes. Estas técnicas varían en complejidad y costo, y la opción más rápida y económica es la ingeniería de peticiones.

- **Ingeniería de peticiones:**



Las peticiones actúan como instrucciones para los modelos fundacionales. Se centra en desarrollar, diseñar y optimizar las peticiones para mejorar el resultado de los FM según sus necesidades. Le brinda una manera de guiar el comportamiento del modelo hacia los resultados que quiere lograr.

Un formulario de petición depende de la tarea que esté asignando a un modelo. A medida que explora los ejemplos de ingeniería de peticiones, revisará aquellas que contienen algunos de los elementos siguientes o todos ellos:

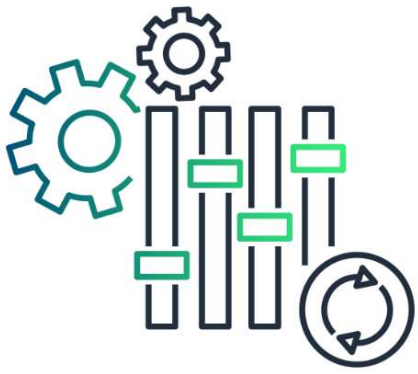
- ✓ **Instrucciones:** Esta tarea la debe realizar el FM. Proporciona una descripción de la tarea o una instrucción sobre cómo debe funcionar el modelo.
- ✓ **Contexto:** Información externa que sirve de guía para el modelo.
- ✓ **Datos de entrada:** La entrada para la que se desea una respuesta.
- ✓ **Indicador de salida:** El tipo o formato de salida.

El siguiente es un ejemplo de una petición que podría darse a un FM.

Ejemplo:

Usted es un periodista experimentado que se destaca en condensar artículos largos en resúmenes breves. Resume el siguiente texto en 2 o 3 oraciones.
Texto: [Introduzca el texto largo del artículo]

- **Ajuste:**



Si bien los FM se entrenan previamente mediante un aprendizaje autosupervisado y tienen la capacidad inherente de comprender la información, ajustar el modelo base del FM puede mejorar el rendimiento. El ajuste es un proceso de aprendizaje supervisado que implica tomar un modelo previamente entrenado y agregar conjuntos de datos específicos y más pequeños. Cuando se agregan estos conjuntos de datos más limitados, se modifican las ponderaciones de los datos para articularlos mejor con la tarea.

Hay dos maneras de ajustar un modelo:

- ✓ El **refinamiento de las instrucciones** usa ejemplos de cómo el modelo debe responder a una instrucción específica. El ajuste de las peticiones es un tipo de ajuste de las instrucciones.
- ✓ **El aprendizaje por refuerzo a partir de retroalimentación humana (Reinforcement learning from human feedback, RLHF)** proporciona datos de retroalimentación humana, lo que da como resultado un modelo que se alinea mejor con las preferencias humanas.

Tenga en cuenta este caso práctico para realizar ajustes. Si está trabajando en una tarea que requiere conocimientos del sector, puede tomar un modelo previamente entrenado y ajustarlo con los datos del sector. Si la tarea implica investigación médica, por ejemplo, el modelo previamente entrenado se puede ajustar con artículos de publicaciones médicas para lograr resultados más contextualizados.

- **Generación aumentada por recuperación:**



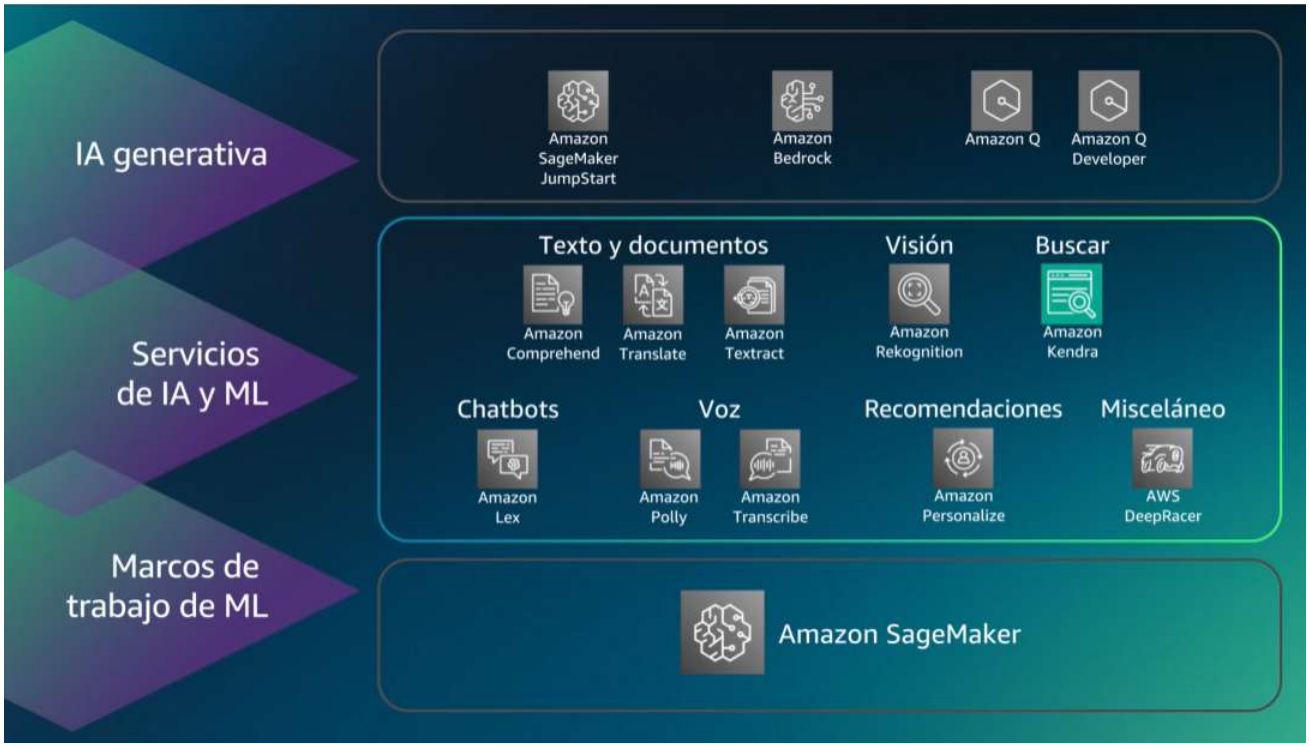
La generación aumentada por recuperación (RAG) es una técnica que brinda datos relevantes para el dominio, como contexto, a fin de producir respuestas basadas en esos datos. Esta técnica es similar a la de ajuste. Sin embargo, en lugar de tener que ajustar un FM con un pequeño conjunto de ejemplos etiquetados, la RAG recupera un pequeño conjunto de documentos relevantes y los usa para proporcionar contexto para responder a la petición del usuario. La RAG no cambiará las ponderaciones de los modelos fundacionales, pero el ajuste sí lo hará.

SERVICIOS DE AWS.

Infraestructura y tecnología de AWS.

AWS ofrece un conjunto completo de servicios de ML e IA generativa que pueden ayudarlo a aprovechar todo el potencial de estas tecnologías transformadoras.

Pila de servicios de AI/ML de AWS:



Conocerá la infraestructura de ML de la IA de AWS y las diferentes capas y dominios para crear aplicaciones con estas tecnologías de ML de la IA.

La pila comienza en la capa de marcos de trabajo de ML. En el centro de esta capa se encuentra Amazon SageMaker. SageMaker es un servicio de aprendizaje automático completamente administrado que puede utilizar para crear, entrenar e implementar sus propios modelos personalizados. SageMaker proporciona herramientas e infraestructura para acelerar el ciclo de vida de desarrollo e implementación del ML.

La siguiente es la capa de servicios de ML de la IA, donde encontrará una amplia gama de servicios especializados diseñados para diferentes casos de uso. En el dominio de textos y documentos, está Amazon Comprehend para el procesamiento del lenguaje natural, Amazon Translate para la traducción de idiomas y Amazon Textract para extraer datos de documentos escaneados.

Para los chatbots, AWS ofrece Amazon Lex, que puede usar para crear interfaces conversacionales impulsadas por las mismas tecnologías de aprendizaje profundo que impulsan Amazon Alexa. En el dominio de voz, puede encontrar Amazon Polly para la conversión de texto a voz y Amazon Transcribe para el reconocimiento de voz automático.

En el dominio de la visión, cuenta con Amazon Rekognition, un servicio de visión artificial basado en el aprendizaje profundo que puede analizar imágenes y videos para una amplia gama de aplicaciones. Para la búsqueda, Amazon Kendra reinventa la búsqueda empresarial de sitios web y aplicaciones para que los usuarios puedan encontrar fácilmente el contenido que buscan.

En el dominio de recomendaciones, tenemos Amazon Personalize para la personalización y las recomendaciones en tiempo real. Por último, en la categoría miscelánea, está AWS DeepRacer, un auto de carreras a escala 1/18 totalmente autónomo que le permite adquirir experiencia práctica con el aprendizaje por refuerzo.

AWS ofrece aún más en la capa de IA generativa. Encontrará un conjunto de servicios y herramientas que desbloquean el poder de los modelos fundacionales. Esto incluye Amazon SageMaker JumpStart, que proporciona un conjunto de soluciones para los casos de uso más comunes.

Amazon Bedrock es un servicio completamente administrado que hace que los FM de Amazon y las principales startups de IA estén disponibles a través de una API. Con Amazon Bedrock, puede empezar rápidamente, experimentar con los FM, personalizarlos de forma privada con sus propios datos e integrar e implementar sin problemas máquinas virtuales en las aplicaciones de AWS. Si prefiere experimentar con la creación de aplicaciones de IA, puede obtener experiencia práctica con PartyRock, un Playground de Amazon Bedrock.

Por último, tiene aplicaciones como Amazon Q, un asistente generativo basado en la IA diseñado para el trabajo que se puede adaptar a los datos de una empresa. Y está Amazon Q Developer, que ofrece recomendaciones de código basadas en el ML para acelerar el desarrollo en una variedad de lenguajes de programación y aplicaciones.

Cada uno de estos servicios está diseñado para permitirle aprovechar el potencial de la IA y el ML, impulsando la innovación, la eficiencia y el crecimiento.

Amazon SageMaker AI es el nuevo nombre del servicio heredado de Amazon SageMaker. Este servicio gestiona específicamente los flujos de trabajo de machine learning tradicionales: creación, formación e implementación de modelos.

AWS innova rápidamente en toda la pila de IA y machine learning, y ofrece capacidades integrales, desde infraestructura y herramientas hasta aplicaciones innovadoras, como la codificación basada en IA. Los clientes valoran el enfoque centrado en los datos de AWS, la seguridad y la variedad de ofertas de nivel empresarial que abarcan todos los niveles.

- **Marcos de trabajo de ML:**



La capa de marcos de trabajo de machine learning desempeña un papel crucial en el desarrollo y la implementación de modelos de machine learning. Amazon SageMaker AI es la base de la capa de marcos. SageMaker AI ofrece las herramientas adecuadas para crear, entrenar y ejecutar LLM y otros FM de forma eficiente y rentable. Para obtener más información acerca de este servicio, haga clic en la siguiente pestaña.

Amazon SageMaker AI:

Con SageMaker AI, puede crear, entrenar e implementar modelos de machine learning para cualquier caso de uso con infraestructuras, herramientas y flujos de trabajo completamente administrados. SageMaker AI elimina el trabajo pesado de cada uno de los pasos del proceso de machine learning a fin de facilitar el desarrollo de modelos de alta calidad. SageMaker AI brinda todos los componentes que se utilizan para el machine learning en un único conjunto de herramientas, de modo que los modelos pasan a la producción más rápido, con mucho menos esfuerzo y a un costo menor.

- **Servicios de IA y machine learning:**



AWS ofrece una sólida capa de servicios de IA y ML, que ofrece soluciones listas para usar, como Amazon Comprehend para las tareas de procesamiento de lenguaje natural y Amazon Kendra para la búsqueda inteligente en los datos de la organización. Esta capa incluye una amplia gama de servicios que brindan a

los desarrolladores capacidades de IA y ML sin requerir una amplia administración de la infraestructura ni experiencia especializada. Elija las siguientes pestañas para obtener más información sobre estos servicios.

- ✓ *Amazon Comprehend:*

  Amazon Comprehend utiliza el ML y el procesamiento de lenguaje natural (NLP) para ayudarlo a descubrir la información y las relaciones en sus datos no estructurados. Este servicio realiza las siguientes funciones:

  - Identifica el idioma del texto.
  - Extrae frases clave, lugares, personas, marcas o eventos.
  - Comprende qué tan positivo o negativo es el texto.
  - Analiza el texto mediante la tokenización y partes del discurso.
  - Y organiza automáticamente una recopilación de archivos de texto por tema.

- ✓ *Amazon Translate:*

  Amazon Translate es un servicio de traducción automática neuronal que ofrece traducciones de idiomas rápidas, de alta calidad y asequibles. La traducción automática neuronal es una forma de automatización de la traducción de idiomas que utiliza los modelos de aprendizaje profundo para ofrecer una traducción más precisa y natural que los algoritmos de traducción basados en reglas y estadísticas tradicionales. Con Amazon Translate, puede localizar contenido, como sitios web y aplicaciones, para sus diversos usuarios, traducir grandes volúmenes de texto para su análisis e implementar de manera eficiente la comunicación multilingüe entre los usuarios.

- ✓ *Amazon Textract:*

  Amazon Textract es un servicio que extrae automáticamente texto y datos de documentos escaneados. Amazon Textract va más allá del reconocimiento óptico de caracteres (OCR) y también identifica el contenido de los campos de los formularios y la información almacenada en las tablas.

- ✓ *Amazon Lex:*

  Amazon Lex es un servicio de IA completamente administrado que permite diseñar, crear, probar e implementar interfaces de conversación en cualquier aplicación mediante voz y texto. Amazon Lex ofrece las funcionalidades avanzadas de aprendizaje profundo del reconocimiento automático de voz (ASR) para convertir la voz en texto y la comprensión del lenguaje natural (NLU) para reconocer la intención del texto. Esto le permite crear aplicaciones con experiencias de usuario muy atractivas e interacciones

conversacionales realistas, y crear nuevas categorías de productos. Con Amazon Lex, las mismas tecnologías de aprendizaje profundo que se usan en Amazon Alexa ahora están disponibles para cualquier desarrollador. Puede crear de manera eficiente bots conversacionales sofisticados en lenguaje natural y sistemas de respuesta de voz interactiva (IVR) basados en voz.

- ✓ *Amazon Polly:*

  Amazon Polly es un servicio que convierte el texto en un discurso realista. Amazon Polly le permite crear aplicaciones que hablan, de modo que puede crear categorías completamente nuevas de productos compatibles con la voz. Amazon Polly es un servicio de IA que utiliza tecnologías avanzadas de aprendizaje profundo para sintetizar un discurso que suena como una voz humana. Amazon Polly incluye una amplia selección de voces realistas distribuidas en docenas de idiomas, por lo que puede seleccionar la voz ideal y crear aplicaciones basadas en voz que funcionen en muchos países diferentes.

- ✓ *Amazon Transcribe:*

  Amazon Transcribe es un servicio de reconocimiento automático de voz (ASR) que convierte automáticamente la voz en texto. El servicio puede transcribir archivos de audio almacenados en formatos comunes, como WAV y MP3, con marcas de tiempo para cada palabra, de modo que pueda buscar el texto y localizar rápidamente el audio en la fuente original. También puede enviar una transmisión de audio en directo a Amazon Transcribe y recibir una transmisión de transcripciones en tiempo real. Amazon Transcribe está diseñado para manejar una amplia gama de características acústicas y del habla, lo que incluye variaciones en el volumen, el tono y la velocidad del habla. Los clientes pueden usar Amazon Transcribe para una variedad de aplicaciones empresariales, incluidas las siguientes:
  - Transcripción de llamadas de servicio al cliente basadas en voz.
  - Generación de subtítulos en contenido de audio y video.
  - Análisis de contenido (basados en texto) de audio y video.

- ✓ *Amazon Rekognition:*

  Amazon Rekognition facilita la adición de análisis de imágenes y videos a sus aplicaciones. Utiliza una tecnología de aprendizaje profundo comprobada y altamente escalable que no requiere experiencia en ML para su uso. Con Amazon Rekognition, puede identificar objetos, personas, textos, escenas y actividades en imágenes y videos, e incluso detectar contenido inapropiado. Amazon Rekognition también ofrece capacidades de análisis facial y búsqueda facial de gran precisión. Puede usarlo para

detectar, analizar y comparar rostros para una amplia variedad de casos prácticos de verificación de usuarios, recuento de personas y seguridad pública.

- ✓ *Amazon Kendra:*

  Amazon Kendra es un servicio de búsqueda inteligente con tecnología de ML. Amazon Kendra reinventa la búsqueda empresarial para sus sitios web y aplicaciones. Sus empleados y clientes pueden encontrar cómodamente el contenido que buscan, incluso si está disperso en varias ubicaciones y repositorios de contenido dentro de su organización.

- ✓ *Amazon Personalize:*

  Amazon Personalize es un servicio de ML que los desarrolladores pueden usar para generar recomendaciones individualizadas para los clientes que usan sus aplicaciones.

  Con Amazon Personalize, usted proporciona un flujo de actividad desde su aplicación (páginas vistas, registros, compras, etc.). También proporciona un inventario de los elementos que desea recomendar, como artículos, productos, videos o música. Se puede optar por dar a Amazon Personalize información demográfica adicional de los usuarios, como la edad o la ubicación geográfica. Amazon Personalize procesa y examina los datos, identifica lo que es significativo, selecciona los algoritmos correctos y entrena y optimiza un modelo de personalización a la medida de sus datos.

- ✓ *AWS DeepRacer:*

  AWS DeepRacer es un auto de carreras a escala 1/18 que le ofrece una forma interesante y divertida de comenzar con el aprendizaje por refuerzo (RL). El RL es una técnica avanzada de ML que adopta un enfoque muy diferente al de otros métodos de ML para los modelos de entrenamiento. Su talento especial es que aprende comportamientos muy complejos sin necesidad de datos de entrenamiento etiquetados y puede tomar decisiones a corto plazo mientras se optimiza para un objetivo a más largo plazo.

- **IA generativa:**



La capa de servicios de IA generativa de la pila de IA y machine learning ofrece un conjunto de herramientas y servicios potentes diseñados específicamente para las tareas de IA generativa. Esta capa incluye servicios como SageMaker JumpStart para acelerar el desarrollo y la implementación de modelos. Amazon Bedrock ofrece una selección de FM de alto rendimiento de las principales empresas de IA a través de una única API. Con estos servicios, los desarrolladores y las organizaciones pueden aprovechar las capacidades de los modelos de IA generativa, abriendo nuevas posibilidades para la creación de contenido, la síntesis de datos y las experiencias de IA interactivas. Elija las siguientes pestañas para obtener más información sobre estos servicios.

✓ *Amazon SageMaker JumpStart:*

SageMaker JumpStart ayuda a empezar rápidamente con el machine learning. Para facilitar el inicio, SageMaker JumpStart ofrece un conjunto de soluciones para los casos de uso más comunes, que se pueden implementar rápidamente. Las soluciones son completamente personalizables y muestran el uso de arquitecturas de referencia y plantillas de AWS CloudFormation para que pueda acelerar su recorrido por el machine learning. SageMaker JumpStart también admite la implementación y el ajuste con un solo clic de más de 150 modelos populares de código abierto, como el procesamiento de lenguaje natural, la detección de objetos y los modelos de clasificación de imágenes.

✓ *Amazon Bedrock:*

Amazon Bedrock es un servicio completamente administrado que hace que los FM de Amazon y los principales startups de IA estén disponibles a través de una API. Con la experiencia sin servidor de Amazon Bedrock, puede empezar rápidamente, experimentar con los FM, personalizarlos de forma privada con sus propios datos e integrar e implementarlos sin problemas en sus aplicaciones de AWS.

✓ *Amazon Q:*

Amazon Q puede ayudarlo a obtener respuestas rápidas y relevantes a preguntas urgentes, resolver problemas, generar contenido y tomar medidas con los datos y la experiencia que se encuentran en los repositorios de información, el código y los sistemas empresariales de su compañía. Al chatear con

Amazon Q, le da información y consejos relevantes e inmediatos para ayudar a simplificar las tareas, acelerar la toma de decisiones y fomentar la creatividad y la innovación.

- ✓ *Amazon Q Developer:*

  Amazon Q Developer está diseñado para mejorar la productividad de los desarrolladores y ofrece recomendaciones de código basadas en ML para acelerar el desarrollo de aplicaciones de C#, Java, JavaScript, Python y TypeScript. El servicio se integra con varios entornos de desarrollo integrados (IDE) y ayuda a los desarrolladores a escribir código más rápido al generar funciones completas y bloques lógicos de código, que a menudo constan de más de 10 a 15 líneas de código.

Ventajas y beneficios de las soluciones de IA de AWS:

Desde pequeños startups hasta grandes empresas, las organizaciones confían en AWS para innovar con herramientas útiles de la IA. AWS ofrece funciones de seguridad y privacidad de primer nivel para mantener sus datos seguros y le brinda acceso a los modelos de IA más avanzados disponibles.

Con AWS, puede crear y ampliar sus propias aplicaciones de IA personalizadas que utilizan la IA generativa. Estas aplicaciones se pueden adaptar a sus necesidades específicas. AWS lo ayuda a aprovechar la tecnología de la IA generativa y a crear algo verdaderamente único y personalizado.

Para obtener más información sobre las ventajas de usar los servicios de AWS para crear aplicaciones de IA, elija cada uno de los marcadores numerados.



1. **Desarrollo e implementación de acelerados:**
   - Amazon Q Developer puede generar código en tiempo real. Amazon organizó un desafío de productividad durante la versión preliminar de Amazon Q Developer. Los participantes que utilizaron el servicio tenían un 27 % más de probabilidades de completar las tareas de forma correcta y lo hicieron un promedio de un 57 % más rápido que aquellos que no utilizaron Amazon Q Developer.

- SageMaker gestiona tareas como el procesamiento previo de datos, el entrenamiento de modelos y la implementación. De este modo, los desarrolladores pueden centrarse en la lógica de la aplicación y en la experiencia del usuario.
- Amazon Bedrock ofrece acceso a modelos y API previamente entrenados. De este modo, los desarrolladores pueden integrar rápidamente las capacidades de IA en sus aplicaciones sin necesidad de un amplio entrenamiento ni de hardware especializado. Esto acelera el proceso de desarrollo y permite ciclos de iteración más rápidos, lo que reduce el tiempo de comercialización de las aplicaciones basadas en la IA.

2. **Escalabilidad y optimización de costos:**
   - Con los modelos de precios de pago por uso, las empresas solo pagan por los recursos que consumen. Esto reduce los costos iniciales y facilita la utilización eficiente de los recursos.
   - La infraestructura global y las capacidades de computación distribuidas de AWS permiten que las aplicaciones se escalen sin problemas en todas las regiones y administren grandes conjuntos de datos o tráfico de gran volumen.
3. **Flexibilidad y acceso a los modelos:**
   - AWS actualiza y amplía continuamente sus servicios de IA, ofreciendo acceso a los últimos avances en modelos, técnicas y algoritmos de machine learning.
   - Amazon Bedrock ofrece una selección de FM de alto rendimiento de empresas líderes en IA, como AI21 Labs, Anthropic, Cohere, Meta, Mistral AI, Stability AI y AWS, a través de una única API.
4. **Integración con las herramientas y los servicios de AWS:**
   - Servicios como Amazon Comprehend y Amazon Rekognition ofrecen capacidades de IA listas para usar que se pueden incorporar fácilmente a las aplicaciones.
   - Los servicios de IA de AWS se integran perfectamente con otros servicios de AWS para que los desarrolladores puedan crear soluciones integrales que utilicen varios servicios en la nube.
   - El ecosistema de AWS ofrece una amplia gama de herramientas, SDK y API para que los desarrolladores puedan incorporar capacidades de IA en sus aplicaciones existentes o crear aplicaciones basadas en IA completamente nuevas.

AWS ofrece una infraestructura segura y conforme para crear aplicaciones de IA. AWS utiliza características de seguridad sólidas, atributos de cumplimiento específicos del sector y un modelo de responsabilidad compartida. También ofrece servicios y herramientas que pueden respaldar el desarrollo y la implementación responsables y seguros de soluciones de IA generativa y tradicional.

Consideraciones sobre los costos:

Al trabajar con los servicios de IA y ML en AWS, es fundamental comprender las diversas consideraciones de costo que implican. Estas compensaciones pueden afectar a factores como la capacidad de respuesta, la disponibilidad, la redundancia, el desempeño, la cobertura regional, los modelos de precios, el rendimiento y la capacidad de utilizar modelos personalizados. Para explorar estos aspectos en más detalle, elija cada una de las siguientes tarjetas.

- **Capacidad de respuesta y disponibilidad:**
  Los servicios de IA generativa de AWS están diseñados para ofrecer una alta capacidad de respuesta y disponibilidad. Sin embargo, los niveles más altos de capacidad de respuesta y disponibilidad a menudo conllevan un costo mayor. Por ejemplo, los servicios con menor latencia y mayor disponibilidad (p. ej., la implementación multirregional) suelen tener precios más altos en comparación con las alternativas con garantías de rendimiento y disponibilidad más bajas.
- **Redundancia y cobertura regional:**
  Para garantizar la redundancia y la alta disponibilidad, los servicios de IA generativa de AWS se pueden implementar en varias zonas de disponibilidad o, incluso, en varias regiones de AWS. Esta redundancia conlleva un costo adicional, ya que los recursos deben aprovisionarse y los datos deben replicarse en varias ubicaciones.
- **Rendimiento:**
  AWS ofrece diferentes opciones de cómputo (por ejemplo, CPU, GPU y aceleradores de hardware personalizados) para los servicios de IA generativa. Las opciones de mayor rendimiento, como las instancias de GPU, suelen tener un costo más elevado, pero pueden ofrecer importantes mejoras de rendimiento para determinadas cargas de trabajo.
- **Precios basados en tokens:**
  Muchos servicios de IA generativa de AWS, como Amazon Q Developer y Amazon Bedrock, utilizan un modelo de precios basado en tokens. Esto significa que se paga por la cantidad de tokens (una unidad de texto o código) generados o procesados por el servicio. Cuantos más tokens genere o procese, mayor será el costo.
- **Rendimiento aprovisionado:**
  Algunos servicios de IA generativa de AWS, como Amazon Polly y Amazon Transcribe, le permiten aprovisionar una cantidad específica de rendimiento (por ejemplo, capacidad de procesamiento de audio o texto) por adelantado. Los niveles de rendimiento aprovisionados más altos suelen tener un costo mayor, pero pueden garantizar un desempeño predecible para las cargas de trabajo urgentes.

- **Modelos personalizados:**
  AWS ofrece modelos entrenados previamente para diversas tareas de IA generativa, pero usted también puede usar sus propios modelos personalizados o ajustar los modelos existentes. El entrenamiento y la implementación de modelos personalizados pueden generar costos adicionales, según la complejidad del modelo, los datos de entrenamiento y los recursos de cómputo necesarios.

Es importante evaluar cuidadosamente sus requisitos y cargas de trabajo específicos a la hora de elegir los servicios de AWS. Factores como los enumerados anteriormente pueden tener un impacto significativo en el costo y el rendimiento generales.

Al comprender estas consideraciones de costos, puede tomar decisiones informadas y optimizar sus implementaciones de IA de AWS para equilibrar los costos, el rendimiento y otros requisitos de manera efectiva.