RESPONSIBLE ARTIFICIAL INTELLIGENCE PRACTICES

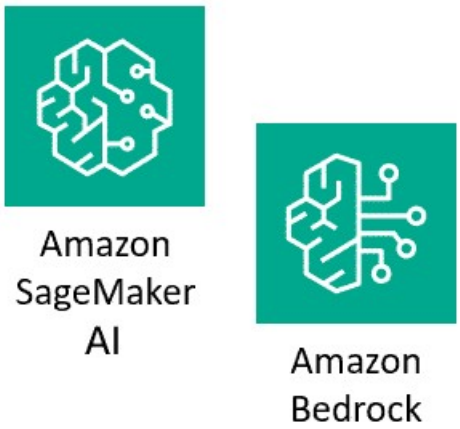
INTRODUCCIÓN.

En este curso, aprenderá sobre las prácticas de la inteligencia artificial (IA) responsable.

En la primera sección de este curso, aprenderá qué es la IA responsable. Aprenderá a definir la IA responsable, comprenderá los desafíos que la IA responsable intenta superar y explorará las dimensiones fundamentales de la IA responsable.



Luego, en la siguiente sección del curso, profundizará en algunos temas para desarrollar sistemas de IA responsable. En esta sección del curso, conocerá los servicios y las herramientas que ofrece AWS para ayudarlo a desarrollar una IA responsable. También aprenderá sobre las consideraciones de la IA responsable que se deben tener en cuenta al momento de seleccionar un modelo y preparar los datos para sus sistemas de IA.



Finalmente, en la última sección del curso, aprenderá sobre los modelos transparentes y explicables. Aprenderá lo que significa que un modelo sea transparente y explicable. También aprenderá sobre las ventajas y desventajas a tener en cuenta entre la seguridad y la transparencia de un modelo de IA y los principios del diseño enfocado en el ser humano para una IA explicable.



IA RESPONSABLE

¿Qué es la IA responsale?:

La IA responsable se refiere a las prácticas y los principios que garantizan que los sistemas de IA sean transparentes y confiables, al tiempo que mitigan los posibles riesgos y resultados negativos. Estos estándares de responsabilidad deben tenerse en cuenta durante todo el ciclo de vida de una aplicación de IA. Se incluyen las fases iniciales de diseño, desarrollo, implementación, supervisión y evaluación.



Para operar la IA de manera responsable, las empresas deben garantizar de manera proactiva que su sistema cuenta con las siguientes características:

- Es totalmente transparente y responsable, y cuenta con mecanismos de supervisión y vigilancia.
- Su gestión está a cargo de un equipo de liderazgo que responde a las estrategias de IA responsable.
- Su desarrollo está a cargo de equipos con experiencia en principios y prácticas de IA responsable.
- Se creó siguiendo las pautas de IA responsable.

¿Qué tipo de IA requiere una IA responsable?:

La IA responsable no es exclusiva de ninguna forma de IA. Debe tenerse en cuenta a la hora de crear sistemas de IA tradicionales o generativos.

- **IA Tradicional:**

  Los modelos tradicionales de machine learning realizan tareas en función de los datos que usted proporciona. Pueden hacer predicciones como la clasificación, el análisis de sentimientos, la clasificación de imágenes y mucho más. Sin embargo, cada modelo solo puede realizar una tarea. Y para hacerlo de forma correcta, el modelo debe entrenarse cuidadosamente en función de los datos. A medida que se entrenan, analizan los datos y buscan patrones. Luego, los modelos hacen una predicción según estos patrones.

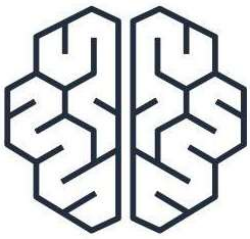
  Algunos ejemplos de la IA tradicional incluyen los motores de recomendación, los juegos y la asistencia por voz.



- **IA Generativa:**

  La inteligencia artificial generativa (IA generativa) se basa en modelos fundacionales (foundation model, FM). Estos modelos se entrenan previamente con cantidades masivas de datos de dominio general que van más allá de sus propios datos. Pueden realizar múltiples tareas. En función de lo que ingrese el usuario, por lo general, en forma de texto denominado mensaje, el modelo genera contenido. Este contenido proviene de patrones de aprendizaje y relaciones que permiten al modelo predecir el resultado deseado.

  Algunos ejemplos de IA generativa incluyen los chatbots, la generación de código y la generación de texto e imágenes.



La IA generativa ofrece valor empresarial:

El potencial de los FM es muy emocionante. Hay varios FM disponibles, cada uno con puntos fuertes y características únicas.

Se espera que surjan nuevas arquitecturas en el futuro, y esta diversidad de FM desencadenará una ola de innovación. Esto puede impulsar los siguientes valores empresariales de los que se pueden beneficiar las empresas:

- **Creatividad**: cree contenidos e ideas nuevos, como conversaciones, historias, imágenes, videos y música.
- **Productividad**: mejore la productividad de forma radical en todas las líneas de negocio, casos de uso y sectores.
- **Conectividad**: comuníquese con los clientes e interactúe con ellos y entre organizaciones de nuevas maneras.

DESAFÍOS DE LA IA RESPONSABLE EN LA IA TRADICIONAL Y LA IA GENERATIVA

Sesgos en los sistemas de IA:

Exactitud de los modelos:

El principal problema al que se enfrentan los desarrolladores en las aplicaciones de IA es la exactitud. Tanto las aplicaciones de IA tradicionales como las generativas funcionan con modelos que se entrenan con conjuntos de datos. Estos modelos pueden hacer predicciones o generar contenido basándose únicamente en los datos con los que están entrenados. Si no están entrenados de forma adecuada, obtendrá resultados inexactos. Por lo tanto, es importante abordar el sesgo y la varianza en el modelo.

- **Sesgos:**

  El sesgo es uno de los mayores desafíos a los que se enfrenta un desarrollador en los sistemas de IA. El sesgo en un modelo significa que al modelo le faltan características importantes de los conjuntos de datos. Esto quiere decir que los datos son demasiado básicos. El sesgo se mide por la diferencia entre las predicciones que se esperan del modelo y los valores reales que intentamos predecir. Si la diferencia es estrecha, el modelo tiene un sesgo bajo. Si la diferencia es amplia, el modelo tiene un sesgo alto.

  Cuando un modelo tiene un sesgo alto, es porque está subajustado. El subajuste significa que el modelo no capta las suficientes diferencias en las características de los datos y, por lo tanto, el modelo tiene un rendimiento deficiente en los datos de entrenamiento.

- **Varianza:**

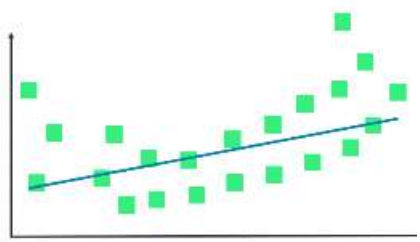
  La varianza presenta un desafío diferente para los desarrolladores. La varianza se refiere a la sensibilidad del modelo a las fluctuaciones o al ruido en los datos de entrenamiento. El problema es que el modelo podría considerar que el ruido en los datos es importante en los resultados. Cuando la varianza es alta, el modelo se familiariza tanto con los datos de entrenamiento que puede hacer predicciones con gran precisión. Esto se debe a que captura todas las características de los datos.

  Sin embargo, cuando se introducen nuevos datos en el modelo, la exactitud del modelo disminuye. Esto se debe a que los nuevos datos pueden tener diferentes características para las que el modelo no ha sido entrenado. Aquí es cuando aparece el problema del sobreajuste. El sobreajuste se produce cuando el modelo funciona bien con los datos de entrenamiento, pero no con los datos de evaluación. Se debe a que el modelo memoriza los datos que ha visto y no puede generalizar con ejemplos no vistos.

Compensación entre sesgo y varianza:

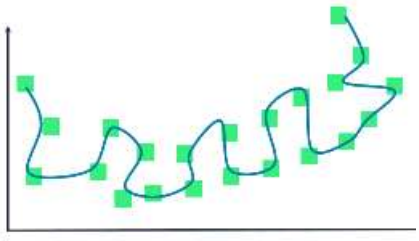
La compensación entre sesgo y varianza se produce cuando se optimiza el modelo con el equilibrio adecuado entre sesgo y varianza. Esto significa que se debe optimizar el modelo para que no quede subajustado o sobreajustado. El objetivo es lograr un modelo entrenado con el sesgo más bajo y la menor varianza para un conjunto de datos determinado.

Revise los siguientes ejemplos de modelos subajustados, sobreajustados y equilibrados.



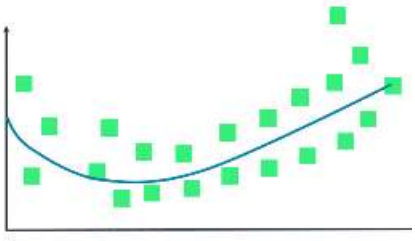
Subajustado

En el ejemplo subajustado, el sesgo es alto y la varianza es baja. En este caso, la regresión es una línea recta. De este modo, vemos que el modelo está subajustando los datos porque no captura todas sus características.



Sobreajustado

En el ejemplo sobreajustado, el sesgo es bajo y la varianza es alta. En este caso, la curva de regresión se ajusta perfectamente a los datos. Esto significa que captura el ruido y, básicamente, memoriza los datos. No funcionará bien con datos nuevos.



Equilibrado

En el ejemplo equilibrado, el sesgo es bajo, al igual que la varianza. En este caso, la regresión es una curva. Esto es lo que usted necesita. Que el modelo capture suficientes características de los datos, sin capturar el ruido.

Para ayudar a superar los errores de sesgo y varianza, puede usar lo siguiente:

- **Validación cruzada:**

  La validación cruzada es una técnica para evaluar modelos de ML mediante el entrenamiento de varios modelos de ML en subconjuntos de los datos de entrada disponibles y su evaluación en el subconjunto complementario de los datos. La validación cruzada se debe utilizar para detectar el sobreajuste.

- **Aumento de los datos:**

  Agregue más muestras de datos para aumentar el alcance del aprendizaje del modelo.

- **Regularización:**

  Use la regularización. La regularización es un método que penaliza los valores de peso extremos para ayudar a evitar que los modelos lineales se sobreajusten a los ejemplos de los datos de entrenamiento.

- **Modelos más sencillos:**

  Utilice arquitecturas de modelos más sencillos para que le resulten útiles con el sobreajuste. Si el modelo está subajustado, es posible que sea demasiado sencillo.

- **Reducción de dimensiones (análisis de componentes principales):**

  Aplique la reducción de dimensiones. La reducción de dimensiones es un algoritmo de machine learning no supervisado que intenta reducir la dimensionalidad (cantidad de características) dentro de un conjunto de datos y, al mismo tiempo, conservar la mayor cantidad de información posible.

- **Finalice el entrenamiento antes de tiempo:**

  Finalice la formación antes de tiempo para que el modelo no memorice los datos.

Desafíos de la IA generativa:

Así como la IA generativa tiene beneficios únicos, también tiene desafíos únicos. Algunos de estos desafíos incluyen la toxicidad, las alucinaciones, la propiedad intelectual, el plagio y la falsificación.



- **Toxicidad:**

  La toxicidad es la posibilidad de generar contenido (ya sea texto, imágenes u otras modalidades) que sea ofensivo, perturbador o inapropiado. Esta es una de las principales preocupaciones con respecto a la IA generativa. Incluso resulta difícil definir y medir la toxicidad. La subjetividad a la hora de determinar qué es el contenido tóxico es un desafío adicional. Además, la frontera entre la restricción del contenido tóxico y la censura puede ser poco clara y dependerá del contexto y la cultura.

Por ejemplo, ¿deberían suprimirse citas que podrían considerarse ofensivas fuera de contexto si están claramente etiquetadas como citas? ¿Qué pasa con las opiniones que pueden resultar ofensivas para algunos usuarios, pero que están claramente etiquetadas como opiniones?

Entre los desafíos técnicos, se incluye el contenido ofensivo que puede estar redactado de manera muy sutil o indirecta, sin el uso de un lenguaje evidentemente incendiario.

- **Alucinaciones:**

  Las alucinaciones son afirmaciones o declaraciones que parecen plausibles, pero que pueden comprobarse como incorrectas. Teniendo en cuenta el siguiente muestreo de distribución de palabras empleado por los modelos de lenguaje grande (large language model, LLM), tal vez no sorprenda que, en casos prácticos más objetivos o fácticos, los LLM sean susceptibles a las alucinaciones.

  Por ejemplo, un fenómeno común en los LLM actuales es la creación de citas científicas inexistentes. Supongamos que se envía un mensaje a un LLM y se le pide que hable de algunos artículos de un autor en particular. En realidad, el modelo no busca citas legítimas, sino que las genera a partir de la distribución de palabras asociadas con ese autor. El resultado puede incluir títulos y temas realistas relacionados con el área del autor. Sin embargo, es posible que estos no sean artículos reales y pueden incluir coautores plausibles, pero no reales.

- **Propiedad intelectual:**

  La protección de la propiedad intelectual era un problema en los primeros LLM. Se debía a que, ocasionalmente, los LLM tendían a producir pasajes de texto o código que eran reproducciones textuales de partes de sus datos de entrenamiento, lo que generaba problemas de privacidad y de otro tipo. Pero incluso las mejoras en este sentido no han impedido que se reproduzcan contenidos de entrenamiento más ambiguos y con más matices.

  Considere esta petición para un modelo generativo de imágenes: "Crea una pintura de un gato que anda en patineta al estilo de Andy Warhol". Si el modelo es capaz de hacerlo de una manera convincente y original porque se basó en imágenes reales de Warhol, podrían surgir objeciones a tal imitación.

- **Plagio y falsificación:**

  Las capacidades creativas de la IA generativa hacen temer que se está utilizando para escribir ensayos universitarios, muestras de textos para solicitudes de empleo y otras formas de falsificaciones o copias ilícitas. En las universidades y muchas otras instituciones, se están abriendo debates sobre este tema y las actitudes al respecto varían ampliamente.

  Algunas personas están a favor de prohibir explícitamente cualquier uso de la IA generativa en entornos en los que se califica o evalúa contenido, mientras que otras personas sostienen que las prácticas educativas deben adaptarse e, incluso, adoptar las nuevas tecnologías. Sin embargo, es probable que el desafío subyacente de verificar que un contenido determinado haya sido escrito por una persona puede plantear problemas en muchos contextos.

- **Alteración de la naturaleza del trabajo:**

  La destreza con la que la IA generativa es capaz de crear textos e imágenes convincentes, obtener buenos resultados en pruebas estandarizadas, escribir artículos enteros sobre determinados temas y resumir o mejorar con éxito la gramática de los artículos proporcionados ha provocado bastante inquietud. Existe la preocupación de que la tecnología pueda afectar o reemplazar a algunas profesiones.

  Si bien esto puede ser prematuro, parece que la IA generativa tendrá un efecto transformador en muchos aspectos del trabajo. Es posible que muchas tareas que antes escapaban a la automatización puedan delegarse a las máquinas.

DIMENSIONES FUNDAMENTALES DE LA IA RESPONSABLE

Las dimensiones fundamentales de la IA responsable incluyen la equidad, la explicabilidad, la privacidad y la seguridad, la robustez, la gobernanza, la transparencia, la seguridad y la capacidad de control. Ninguna dimensión es un objetivo independiente para la IA responsable. De hecho, cada tema se debe considerar como una parte necesaria para una implementación completa de la IA responsable.



Descubrirá que hay una superposición considerable entre muchos de estos temas. Por ejemplo, verá que cuando se implemente la transparencia en su sistema de IA, se requerirán elementos de explicabilidad, equidad y gobernanza. A continuación, explorará cómo se utiliza cada uno de estos temas en la IA responsable.

Equidad:

La equidad es crucial para desarrollar sistemas de IA responsable. Con la equidad, los sistemas de IA promueven la inclusión, previenen la discriminación, defienden los valores responsables y las normas legales y generan confianza en la sociedad.

Debe considerar la equidad en sus aplicaciones de IA con el fin de crear sistemas adecuados y beneficiosos para todas las personas.



Explicabilidad:

La explicabilidad se refiere a la capacidad de un modelo de IA para explicar o justificar de forma clara sus mecanismos y decisiones internos, de modo que sea comprensible para los humanos.

Los humanos deben entender de qué manera los modelos toman decisiones y abordan cualquier problema de sesgo, confianza o equidad.



Privacidad y seguridad:

La privacidad y la seguridad en la IA responsable se refieren a los datos que están protegidos contra el robo y la exposición. Más específicamente, esto significa que, a nivel de privacidad, las personas controlan cuándo y si se pueden usar sus datos. A nivel de seguridad, verifica que ningún sistema o usuario no autorizado tendrá acceso a los datos de la persona.

Cuando se implementa correctamente en un sistema de IA, los usuarios pueden confiar en que sus datos no se verán comprometidos ni se utilizarán sin su autorización.



Transparencia:

La transparencia comunica información sobre un sistema de IA para que las partes interesadas puedan tomar decisiones justificadas sobre su uso del sistema. Parte de esta información incluye los procesos de desarrollo, las capacidades del sistema y las limitaciones.

Proporciona acceso a las personas, las organizaciones y las partes interesadas para evaluar la equidad, la robustez y la explicabilidad de los sistemas de IA. Pueden identificar y mitigar los posibles sesgos, reforzar los estándares de responsabilidad y fomentar la confianza en la tecnología.



Veracidad y robustez:

La veracidad y la robustez de la IA se refieren a los mecanismos para garantizar que un sistema de IA funciona de manera confiable, incluso en situaciones inesperadas, de incertidumbre y en caso de errores.

El objetivo de la veracidad y la robustez de la IA responsable es desarrollar modelos de IA que sean resistentes a los cambios en los parámetros de entrada, las distribuciones de datos y las circunstancias externas.

Esto quiere decir que el modelo de IA debe conservar la fiabilidad, la exactitud y la seguridad en entornos inciertos.



Gobernanza:

La gobernanza es un conjunto de procesos que se utilizan para definir, implementar y hacer cumplir las prácticas de la IA responsable dentro de una organización.

La gobernanza aborda diversos problemas de responsabilidad, jurídicos o sociales que la IA generativa puede provocar.

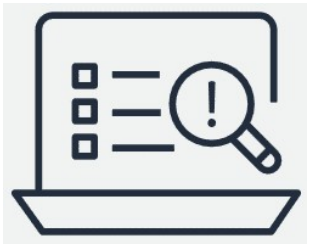
Por ejemplo, las políticas de gobernanza pueden ayudar a proteger los derechos de las personas a la propiedad intelectual. También se puede usar para el cumplimiento de las leyes y reglamentos. La gobernanza es un componente vital de la IA responsable para una organización que busca incorporar prácticas recomendadas responsables.



Seguridad:

La seguridad en la IA responsable se refiere al desarrollo de algoritmos, modelos y sistemas de tal manera que sean responsables, seguros y beneficiosos para las personas y la sociedad en su conjunto.

Esto significa que los sistemas de IA deben diseñarse y probarse cuidadosamente para evitar causar daños no deseados a los humanos o al medioambiente. Algunas cuestiones como el sesgo, el uso indebido y los impactos descontrolados deben considerarse de manera proactiva.



Capacidad de control:

La capacidad de control en la IA responsable se refiere a la capacidad de supervisar y guiar el comportamiento de un sistema de IA para que se alinee con la intención y los valores y humanos. Implica desarrollar arquitecturas que sean controlables, de modo que cualquier problema no deseado se pueda gestionar y abordar.

Cuando se garantiza la capacidad de control, la IA responsable puede ayudar a mitigar los riesgos, promover la equidad y la transparencia, y garantizar que los sistemas de IA beneficien a la sociedad en su conjunto.



Beneficios empresariales de la IA responsable:

La IA responsable ofrece beneficios empresariales clave en el desarrollo y la implementación de los sistemas de IA.

- **Mayor confianza y mejor reputación:**
  Es más probable que los clientes interactúen con las aplicaciones de IA si creen que el sistema es equitativo y seguro. De este modo, mejora la reputación y el valor de su marca.
- **Conformidad normativa:**
  A medida que surgen las regulaciones de la IA, las empresas con marcos de trabajo éticos y robustos de IA se encuentran mejor posicionadas para cumplir con las directrices sobre la privacidad, la equidad, la responsabilidad y la transparencia de los datos.

- **Mitigación de los riesgos:**
  Las prácticas de la IA responsable ayudan a mitigar riesgos como los sesgos, las violaciones de la privacidad, las infracciones de seguridad y los impactos negativos no deseados en la sociedad. De este modo, se reducen las responsabilidades legales y los costos financieros.
- **Ventaja competitiva:**
  Las empresas que dan prioridad a la IA responsable pueden diferenciarse de la competencia y obtener una ventaja competitiva, especialmente a medida que aumenta la conciencia de los consumidores sobre la ética de la IA.
- **Mejor toma de decisiones:**
  Los sistemas de IA que se crean teniendo en cuenta la equidad, la responsabilidad y la transparencia son más confiables y es menos probable que produzcan resultados sesgados o defectuosos, lo que conduce a mejores decisiones basadas en datos.
- **Mejores productos y negocios:**
  La IA responsable fomenta un enfoque diverso e inclusivo para el desarrollo de la IA. Debido a que se basa en diversas perspectivas y experiencias, puede impulsar soluciones más creativas e innovadoras.

DESARROLLO DE LOS SISTEMAS DE IA RESPONSABLE

SERVICIOS Y HERRAMIENTAS DE AMAZON PARA UNA IA RESPONSABLE

Como líder en tecnologías en la nube, AWS ofrece servicios como Amazon SageMaker AI y Amazon Bedrock que cuentan con herramientas integradas para ayudarlo a desarrollar una IA responsable. Estas herramientas abarcan temas como la evaluación de los modelos fundacionales, las garantías para la IA generativa, la detección de sesgos, las explicaciones de las predicciones de los modelos, la supervisión y las revisiones humanas y la mejora de la gobernanza.

- **Amazon SageMaker AI:**
  Amazon SageMaker AI es un servicio de machine learning completamente administrado. Con SageMaker AI, los científicos de datos y los desarrolladores pueden crear, entrenar e implementar modelos de machine learning de forma rápida y segura en un entorno hospedado listo para la producción. Proporciona una experiencia de interfaz de usuario para ejecutar flujos de trabajo de machine learning que hace que las herramientas de machine learning de SageMaker AI estén disponibles en varios entornos de desarrollo integrados (integrated development environments, IDE).

Con SageMaker AI, puede almacenar y compartir sus datos sin necesidad de crear y administrar sus propios servidores. De este modo, usted o su organización tendrán más tiempo para crear y desarrollar de manera colaborativa su flujo de trabajo de machine learning y hacerlo antes. SageMaker AI ofrece algoritmos de machine learning administrados para ejecutarse de manera eficiente con datos extremadamente grandes en un entorno distribuido. Gracias a la compatibilidad integrada con algoritmos y marcos de trabajo propios, SageMaker AI ofrece opciones de formación distribuidas y flexibles que se ajustan a sus flujos de trabajo específicos. Puede implementar un modelo en un entorno seguro y escalable desde la consola de SageMaker IA en unos pocos pasos.



- **Amazon Bedrock:**

  Amazon Bedrock es un servicio completamente administrado que pone a su disposición los modelos fundacionales de alto rendimiento de los principales startups de IA y Amazon para su uso a través de una API unificada. Puede elegir entre una amplia gama de FM para encontrar el modelo que mejor se adapte a su caso práctico.

  Amazon Bedrock también ofrece un amplio conjunto de capacidades para crear aplicaciones de IA generativa con seguridad, privacidad e inteligencia artificial responsable.

  Con la experiencia sin servidor de Amazon Bedrock, puede personalizar los FM de forma privada con sus propios datos, integrarlos e implementarlos de forma segura en sus aplicaciones mediante el uso de las herramientas de AWS sin tener que administrar ninguna infraestructura.



Revisión de las herramientas de servicio de Amazon para una IA responsable:

A continuación, conocerá las herramientas de servicio de Amazon que pueden ayudarlo en diferentes áreas de la IA responsable. Estas áreas incluyen la evaluación de los FM, las garantías para la IA generativa, la detección de sesgos, la explicación de las predicciones de los modelos, la supervisión y las revisiones humanas y la mejora de la gobernanza.

Evaluación de los modelos fundacionales

Siempre debe evaluar los FM con el fin de determinar si son adecuados para su caso de uso específico. Para ayudarlo a hacer esto, Amazon ofrece una evaluación de modelos en Amazon Bedrock y Amazon SageMaker AI Clarify.

- **Evaluación de modelos en Amazon Bedrock:**

  Con la **Evaluación de modelos en Amazon Bedrock**, puede evaluar, comparar y seleccionar el mejor modelo fundacional para su caso de uso con solo un par de clics. Amazon Bedrock ofrece una opción de evaluación automática y una de evaluación humana.

  - ✓ La evaluación automática ofrece métricas predefinidas, como la exactitud, la robustez y la toxicidad.
  - ✓ La evaluación humana ofrece métricas subjetivas o personalizadas, como la amabilidad, el estilo y la alineación con la voz de la marca. Para la evaluación humana, puede recurrir a sus empleados internos o a un equipo administrado por AWS como revisores.

- **Amazon SageMaker AI Clarify:**

  SageMaker AI Clarify admite la evaluación de modelos fundacionales. Puede evaluar automáticamente los FM para su caso de uso de IA generativa con métricas como la exactitud, la robustez y la toxicidad a fin de respaldar su iniciativa de IA responsable.

  Para los criterios o el contenido con matices que requiere un juicio humano sofisticado, puede optar por recurrir a su propio personal o recurrir a un personal administrado y proporcionado por AWS para revisar las respuestas del modelo.

Garantías para la IA generativa:

Con las **Barreras de protección para Amazon Bedrock**, puede implementar garantías para sus aplicaciones de IA generativa en función de sus casos de uso y políticas de IA responsable. Las barreras de protección ayudan a controlar la interacción entre los usuarios y los FM mediante la filtración de contenido no deseado y dañino, a redactar información de identificación personal (personally identifiable information, PII) y a mejorar la seguridad y privacidad del contenido en las aplicaciones de IA generativa. Puede crear varias barreras de protección con diferentes configuraciones adaptadas a casos prácticos específicos. Además, puede supervisar y analizar

continuamente las entradas de los usuarios y las respuestas del FM que pueden infringir las políticas definidas por el cliente en las barreras de protección.

- **Nivel de seguridad constante de la IA:**

  Las barreras de protección para Amazon Bedrock permiten evaluar las entradas de los usuarios y las respuestas del FM en función de las políticas específicas de cada caso práctico y proporcionan una capa adicional de protección independientemente del FM subyacente. Las barreras de protección para Amazon Bedrock se pueden aplicar en todos los FM, incluidos Anthropic Claude, Meta Llama 2, Cohere Command, AI21 Labs Jurassic, Amazon Titan Text y otros modelos ajustados. Los clientes pueden crear varias barreras de protección, cada una configurada con una combinación diferente de controles, y usar estas barreras de protección en diferentes aplicaciones y casos prácticos. Las barreras de protección para Amazon Bedrock también se pueden integrar con los Agentes de Amazon Bedrock para crear aplicaciones de IA generativa alineadas con sus políticas de IA responsable.

- **Bloquee temas no deseados:**

  Las organizaciones reconocen la necesidad de administrar las interacciones dentro de las aplicaciones de IA generativa con el fin de lograr una experiencia de usuario relevante y segura. Quieren personalizar aún más las interacciones con el fin de que sigan enfocándose en temas relevantes para su negocio y para alinearse con las políticas de la empresa. Al utilizar una descripción breve en lenguaje natural, las barreras de protección para Amazon Bedrock le permiten definir un conjunto de temas que se debe evitar en el contexto de su aplicación. Las barreras de protección para Amazon Bedrock detectan y bloquean las entradas de los usuarios y las respuestas del FM que pertenecen a los temas restringidos. Por ejemplo, se puede diseñar un asistente bancario que evite temas relacionados con el asesoramiento de inversiones.

- **Filtre el contenido dañino:**

  Las barreras de protección para Amazon Bedrock proporcionan filtros de contenido con umbrales configurables que permiten filtrar el contenido dañino en las categorías de incitación al odio, insultos, contenido sexual y violencia. La mayoría de los FM ya cuentan con protecciones integradas para evitar la generación de respuestas dañinas. Además de estas protecciones, las barreras de protección para Amazon Bedrock le permiten configurar umbrales en las diferentes categorías para filtrar las interacciones dañinas. Las barreras de protección para Amazon Bedrock evalúan automáticamente las consultas de los usuarios y las respuestas de los FM con el fin de detectar y ayudar a evitar el contenido que corresponde a las categorías restringidas. Por ejemplo, un sitio de comercio electrónico puede diseñar un asistente en línea que evite el uso de lenguaje inapropiado, como discursos de odio o insultos.

- **Redacte la PII para proteger la privacidad del usuario:**
  Las barreras de protección para Amazon Bedrock lo ayudan a detectar la PII en las entradas de los usuarios y en las respuestas de los FM. Según el caso práctico, usted puede rechazar de forma selectiva las entradas que contienen PII o redactar la PII en las respuestas del FM. Por ejemplo, puede redactar la información personal de los usuarios mientras genera resúmenes a partir de las transcripts de las conversaciones entre los clientes y los agentes en un centro de llamadas.

Detección de sesgos:

SageMaker AI Clarify ayuda a identificar posibles sesgos en los modelos y conjuntos de datos de machine learning sin necesidad de una codificación exhaustiva. Usted especifica las funciones de entrada, como el género o la edad, y SageMaker AI Clarify ejecuta un trabajo de análisis para detectar posibles sesgos en esas características. A continuación, SageMaker AI Clarify ofrece un informe visual con una descripción de las métricas y las medidas del posible sesgo para que pueda identificar los pasos para corregir el sesgo.



Puede utilizar **Amazon SageMaker Data Wrangler** para equilibrar los datos en cualquier caso de desequilibrio. SageMaker Data Wrangler ofrece tres operadores de balanceo: el submuestreo aleatorio, el sobremuestreo aleatorio y la técnica de sobremuestreo minoritario sintético (Synthetic Minority Oversampling Technique, SMOTE) para reequilibrar los datos de sus conjuntos de datos desequilibrados.



Explicación de las predicciones de los modelos:

SageMaker AI Clarify está integrado con Amazon SageMaker AI Experiments con el fin de proporcionar puntuaciones que detallan qué características tienen una mayor contribución a la predicción del modelo en una entrada concreta para modelos tabulares, de procesamiento de lenguaje natural (natural language processing, NLP) y de visión artificial. Para los conjuntos de datos tabulares, SageMaker AI Clarify también puede generar

un gráfico de importancia de las características agregadas que proporciona información sobre el proceso de predicción general del modelo. Estos detalles pueden ayudar a determinar si una entrada del modelo en particular tiene más influencia de la esperada en el comportamiento general del modelo.

SageMaker AI Experiments es una función de SageMaker AI que se puede utilizar para crear, administrar, analizar y comparar los experimentos de machine learning.

Supervisión y revisiones humanas:

- **Supervisor de modelos de Amazon SageMaker:**

  El Supervisor de modelos de Amazon SageMaker supervisa la calidad de los modelos de machine learning de SageMaker AI en producción. Puede configurar la supervisión continua con un punto de conexión en tiempo real (o un trabajo de transformación por lotes que se ejecute con regularidad) o la supervisión programada para los trabajos de transformación por lotes asíncronos. Con SageMaker Model Monitor, puede configurar alertas que lo notifiquen cuando haya desviaciones en la calidad del modelo. Con la detección temprana y proactiva de estas desviaciones, puede tomar medidas correctivas.

- **Amazon A21:**

  Amazon Augmented AI (Amazon A2I) es un servicio que permite crear los flujos de trabajo necesarios para la revisión humana de las predicciones de ML. Amazon A2I ofrece la revisión humana a todos los desarrolladores y elimina el trabajo pesado e indiferenciado asociado con la creación de sistemas de revisión humana o la administración de una gran cantidad de revisores humanos.

Mejora de la gobernanza:

SageMaker AI ofrece herramientas de gobernanza diseñadas específicamente para ayudar a implementar la IA de forma responsable. Estas herramientas le dan un control y una visibilidad más estrictos sobre sus modelos de IA. Puede capturar y compartir la información del modelo y mantenerse informado sobre su comportamiento, como el sesgo, todo en un solo lugar.

Entre las herramientas de gobernanza se incluyen las siguientes:

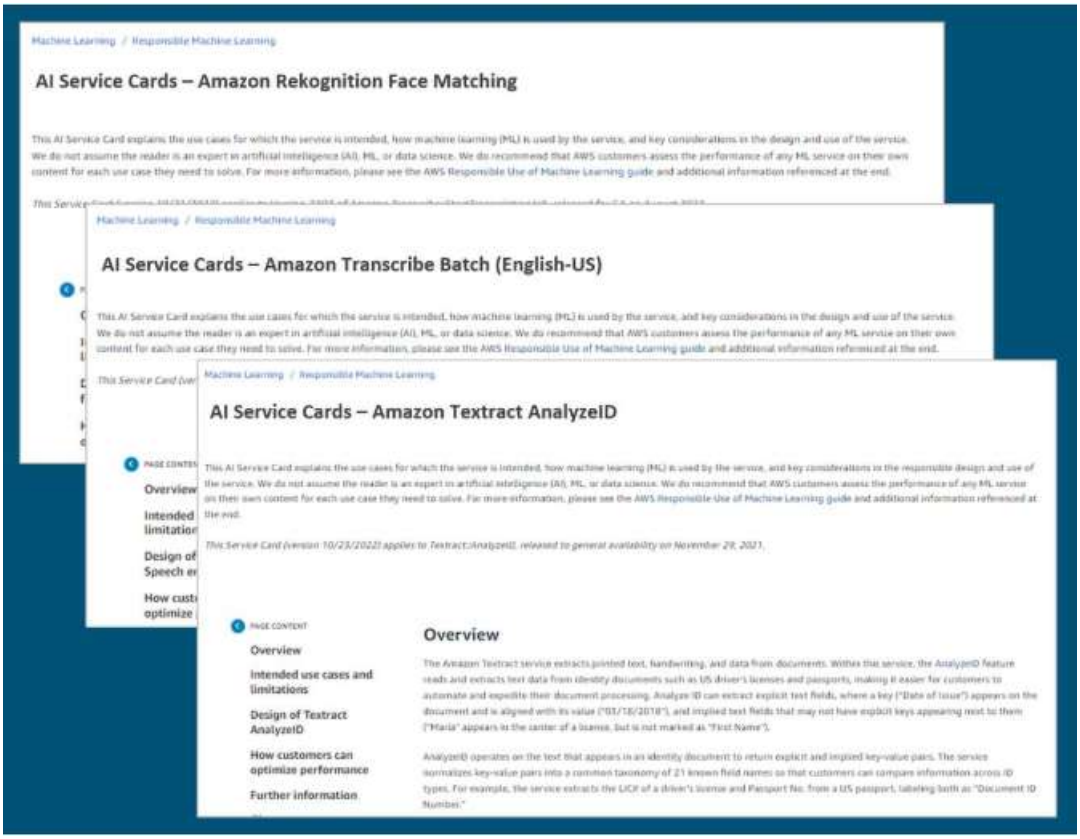
- **Amazon SageMaker Role Manager**: con esta herramienta, los administradores pueden definir los permisos mínimos en solo unos minutos.
- **Amazon SageMaker Model Cards**: con esta herramienta, puede capturar, recuperar y compartir información esencial del modelo, tal como los usos previstos, las clasificaciones de los riesgos y los detalles del entrenamiento, desde la concepción hasta la implementación.

- **Panel de modelos de Amazon SageMaker**: con esta herramienta, puede mantener a su equipo informado acerca del comportamiento de los modelos en producción, todo en un solo lugar.

Brindar transparencia:

Las fichas de servicio de IA de AWS son un nuevo recurso que ayuda a comprender mejor los servicios de IA de AWS. Las fichas de servicio de IA son una forma de documentación de IA responsable que proporciona un único lugar para encontrar información sobre los casos prácticos y las limitaciones previstos, las opciones de diseño de IA responsable y las prácticas recomendadas de implementación y optimización del rendimiento para los servicios de IA de AWS.

Forman parte de un proceso de desarrollo integral para crear servicios de AWS de manera responsable que aborde las dimensiones fundamentales de la IA responsable.



Tarjetas de modelos de IA de AWS

Cada tarjeta de servicio de IA contiene cuatro secciones que abarcan lo siguiente:

- Conceptos básicos para ayudar a los clientes a comprender mejor el servicio o sus características
- Casos prácticos previstos y limitaciones
- Consideraciones en el diseño de la IA responsable

- Orientación sobre la implementación y la optimización del rendimiento

El contenido de las tarjetas de servicio de IA está dirigido a una amplia audiencia de clientes, tecnólogos, investigadores y otras partes interesadas. Este contenido ayuda a estas audiencias a comprender mejor las consideraciones clave para el diseño y el uso responsables de un servicio de IA.

CONSIDERACIONES RESPONSABLES AL MOMENTO DE SELECCIONAR UN MODELO

La selección de un modelo es uno de los primeros y más importantes pasos para desarrollar un sistema de IA. La selección del modelo tiene implicaciones estratégicas sobre el rendimiento del sistema de IA. Todo, desde la experiencia del usuario y la comercialización hasta la contratación y la rentabilidad, puede verse afectado si se selecciona el modelo adecuado para su caso práctico.

Recuerde que puede usar la **Evaluación de modelos en Amazon Bedrock** o **SageMaker AI Clarify** para evaluar la exactitud, la robustez, la toxicidad o el contenido con matices de los modelos que requieren el juicio humano.

Definir el caso de uso de la aplicación de forma restringida:

Cuando se seleccione un modelo para su aplicación de IA, debe definir su caso práctico de forma restringida. Esto es importante porque puede ajustar su modelo para ese caso práctico específico.

Ejemplo: cómo definir el caso práctico de la aplicación de forma restringida para la IA tradicional

En este ejemplo, es posible que tenga una aplicación de IA que utilice el reconocimiento facial. El reconocimiento facial no es un caso práctico; es una tecnología. La forma en que su modelo aplica esa tecnología es un caso práctico.



Recuperación de la galería



Reconocimiento de celebridades



Supervisión virtual

Por ejemplo, se puede usar una aplicación de recuperación de galerías para ayudar a encontrar personas desaparecidas. En este caso, necesitará un modelo que pueda ajustarse para favorecer la exhaustividad o la precisión. Favorecer la exhaustividad arrojará muchos resultados que podrían beneficiar al caso práctico de la aplicación de IA utilizada para encontrar personas desaparecidas.

Sin embargo, si su aplicación de IA se utiliza para el reconocimiento de celebridades o la supervisión virtual, el modelo solo tendría que favorecer la precisión. Esto se debe a que el ajuste destinado a favorecer la exhaustividad podría proporcionar demasiados resultados como para beneficiar al caso práctico de la aplicación.

Ejemplo: cómo definir el caso práctico de una aplicación de forma restringida para la IA generativa

En este ejemplo, es posible que tenga una aplicación de IA destinada a ayudar a los clientes a comprar en su tienda en línea. El caso práctico puede consistir en proporcionar un catálogo de productos o convencer a los clientes de que compren productos. Sería necesario seleccionar un modelo apropiado en función del caso de uso definido de manera restringida.

Características	Catalogar un producto	Persuadir para comprar
Audiencia de destino	Demografía amplia	Demografía limitada
Posibles problemas	Veracidad	Veracidad, sesgo no deseado, toxicidad y detalle
Consecuencias	Daños a la marca, pérdida de ventas y devoluciones	Daños representativos, daños a la marca, pérdida de ventas y devoluciones
Ajuste	Favorece la neutralidad, la claridad y la integridad	Se enfoca en el problema de mayor interés y en el beneficio para el grupo.

En una aplicación de IA para catalogar un producto, querría tener un público objetivo demográfico amplio para que esté disponible para todos sus clientes.

En una aplicación de IA para persuadir a comprar, deberá tener un público objetivo reducido que capture a un grupo específico de personas. Por ejemplo, es posible que desee dirigirse a un público que vive en la costa si desea vender accesorios para atracar barcos.

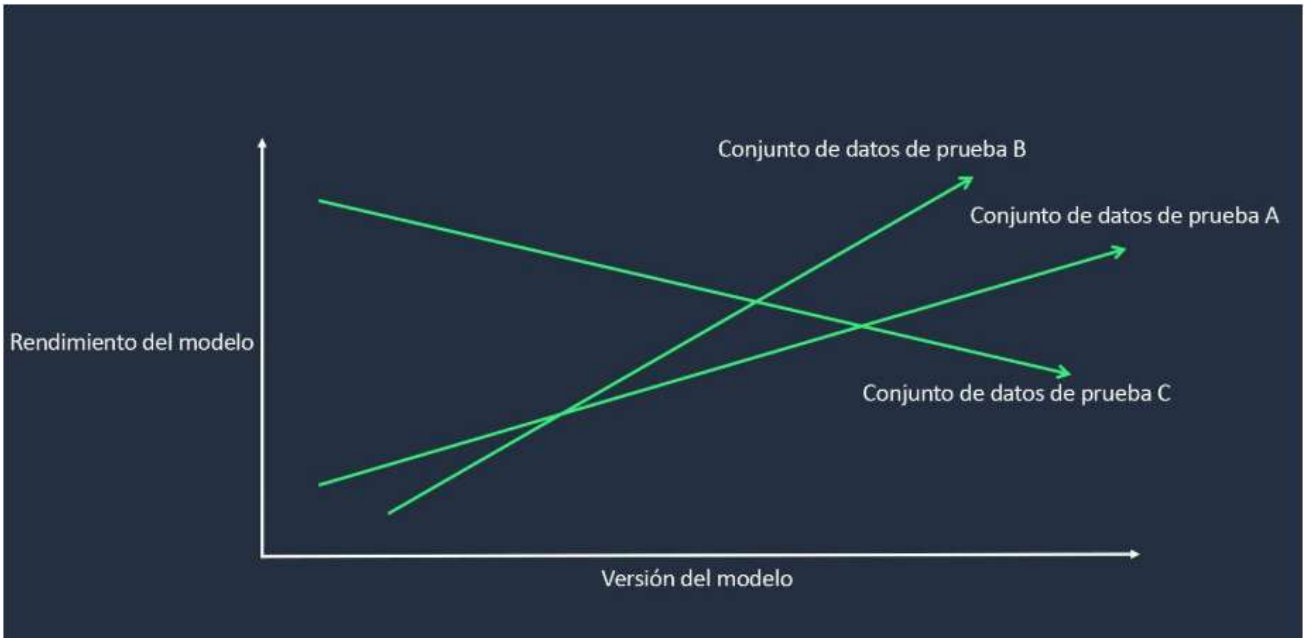
Elegir un modelo en función del rendimiento:

El rendimiento del modelo varía según varios factores, entre los que se incluyen los siguientes:

- Nivel de personalización: la capacidad de cambiar los resultados de un modelo con nuevos datos que van desde enfoques basados en peticiones hasta el reentrenamiento completo del modelo
- Tamaño del modelo: la cantidad de información que el modelo aprendió según lo definido por el recuento de parámetros
- Opciones de inferencia: desde la implementación autogestionada hasta las llamadas a la API
- Acuerdos de licencias: algunos acuerdos pueden restringir o prohibir el uso comercial
- Ventanas de contexto: la cantidad de información que cabe en un solo mensaje
- Latencia: la cantidad de tiempo que tarda un modelo en generar un resultado

Considere un modelo basado en el rendimiento con conjuntos de datos de prueba

Un error común al momento de elegir un modelo es suponer que el modelo, en sí mismo, es bueno o malo. Este no es el caso. El rendimiento es una función del modelo y de un conjunto de datos de prueba, no solo del modelo. Por lo tanto, cuando se evalúa un modelo, debe determinar qué tan bien funciona el modelo en un conjunto de datos en particular.



Modelo que funciona de manera diferente en distintos conjuntos de datos

Por ejemplo, un modelo puede funcionar bien en el conjunto de datos de prueba A durante un tiempo. Es posible que el modelo funcione incluso mejor en el conjunto de datos de prueba B. Sin embargo, el modelo podría empeorar progresivamente en el conjunto de datos de prueba C.

Esto significa que debe considerar dos trayectorias de desarrollo: la trayectoria de desarrollo del modelo y la trayectoria de desarrollo de los conjuntos de datos. Recuerde que el conjunto de datos no es necesariamente constante. A menudo se encuentra en evolución.

Elegir un modelo según las inquietudes por la sostenibilidad:

La sostenibilidad en el contexto de la IA responsable se refiere a la capacidad de los sistemas de IA para desarrollarse e implementarse de una manera que sea social, ambiental y económicamente sostenible a largo plazo.

Consideraciones de la agencia responsable a la hora de seleccionar un modelo

La agencia responsable en la IA responsable se refiere a la capacidad de un sistema de IA para emitir buenos juicios y actuar de manera socialmente responsable. A continuación, se mencionan los aspectos clave de la agencia moral de la IA.

- **Alineación de valores:**

  La alineación de valores consiste en poder comprender, evaluar y tomar decisiones basadas en principios morales y no en la pura maximización de la utilidad. Para ello, es necesario alinear los objetivos y valores del sistema de IA con los valores humanos responsables.

- **Habilidades de razonamiento responsable:**

  Las habilidades de razonamiento responsable consisten en ser capaz de reflexionar lógicamente sobre los dilemas morales y sopesar varias consideraciones responsables al momento de tomar decisiones. La IA necesita capacidades de lógica y de razonamiento para aplicar los principios responsables a situaciones novedosas.

  El sistema de IA debe tener la capacidad de participar en un razonamiento responsable y comprender los conceptos, los principios y los marcos de trabajo morales. Debería poder aplicarlos en el contexto de situaciones específicas.

- **Nivel adecuado de autonomía:**

  El sistema de IA debe tener el nivel adecuado de autonomía, con límites y mecanismos claros para la supervisión y la intervención humanas, especialmente en ámbitos delicados o de alto riesgo.

- **Transparencia y rendición de cuentas:**

  El sistema de IA debe ser transparente en cuanto a su proceso de toma de decisiones. Debe permitir la supervisión y la rendición de cuentas externas para garantizar que sus acciones estén justificadas de manera responsable.

En general, la agencia responsable exige que la IA tenga una inteligencia sofisticada a la altura de la cognición humana para aplicar correctamente el razonamiento ético en el mundo real. Esto sigue siendo un inmenso desafío para la IA actual.

Consideraciones relacionadas con el medioambiente a la hora de seleccionar un modelo

Cuando desarrolle e implemente sistemas de IA, tenga en cuenta las consideraciones relacionadas con el medioambiente a la hora de implementar una IA responsable.



A continuación, se mencionan los principales desafíos relacionados con el medioambiente y las soluciones que se deben tener en cuenta al momento de elegir un modelo.

- **Consumo de energía:**

Desafío	Solución
Entrenar grandes modelos de IA y ejecutarlos a escala puede consumir cantidades significativas de energía y contribuir a las emisiones de gases de efecto invernadero y al impacto ambiental.	La solución consiste en optimizar la eficiencia energética de los sistemas de IA, utilizar fuentes de energía renovables siempre que sea posible y tener en cuenta la huella de carbono general de las operaciones de IA.

- **Uso de los recursos:**

Desafío	Solución
Los sistemas de IA a menudo requieren importantes recursos computacionales, incluido hardware especializado, como la unidad de procesamiento gráfico (graphics processing unit, GPU) y la unidad de procesamiento tensorial (tensor processing unit, TPU), e infraestructura de centros de datos. La fabricación y eliminación de estos recursos pueden tener impactos ambientales.	La IA responsable debe tener como objetivo maximizar la eficiencia de los recursos, promover la reutilización y reciclaje del hardware, y minimizar los residuos electrónicos.

- **Evaluación del impacto ambiental:**

Desafío	Solución
Antes de implementar los sistemas de IA, es importante evaluar sus posibles impactos ambientales, tanto directos (por ejemplo, el consumo de energía y el uso de recursos) como indirectos (por ejemplo, permitir o promover actividades dañinas para el medioambiente).	Se deben realizar evaluaciones de impacto ambiental y, si es necesario, se deben implementar estrategias de mitigación.

Consideraciones económicas a la hora de seleccionar un modelo

Las consideraciones económicas de la IA responsable incluyen los posibles beneficios y costos de las tecnologías de IA y el impacto en los empleos y en la economía.

Por ejemplo, la IA permite automatizar ciertas tareas y mejorar la eficiencia, pero también puede provocar el desplazamiento laboral y la desigualdad. Además, preocupa la concentración de poder y datos en manos de unas pocas empresas, lo que podría dar lugar a monopolios y a una mayor desigualdad.



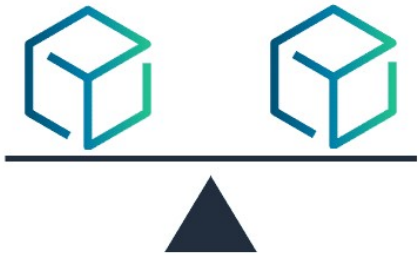
PREPARACIÓN RESPONSABLE DE LOS CONJUNTOS DE DATOS

Uno de los requisitos esenciales para una IA responsable es la preparación de sus conjuntos de datos de manera responsable. Esto significa que es necesario tener conjuntos de datos equilibrados para entrenar sus modelos. Recuerde que puede utilizar **SageMaker AI Clarify** y **SageMaker Data Wrangler** para ayudar a equilibrar sus conjuntos de datos.

Equilibrar los conjuntos de datos:

Los conjuntos de datos equilibrados son importantes, ya que permiten crear modelos de IA responsable que no discriminen injustamente ni muestren sesgos no deseados.

Los conjuntos de datos equilibrados deben representar a todos los grupos de personas o temas de datos. Esto significa que el conjunto de datos debe contener una cantidad adecuada de ejemplos o instancias de cada grupo para garantizar que el modelo no esté sesgado hacia ningún grupo o factor en particular. El concepto de conjuntos de datos equilibrados es particularmente importante en aplicaciones como la contratación, los préstamos o la justicia penal, donde la imparcialidad y la equidad son esenciales.

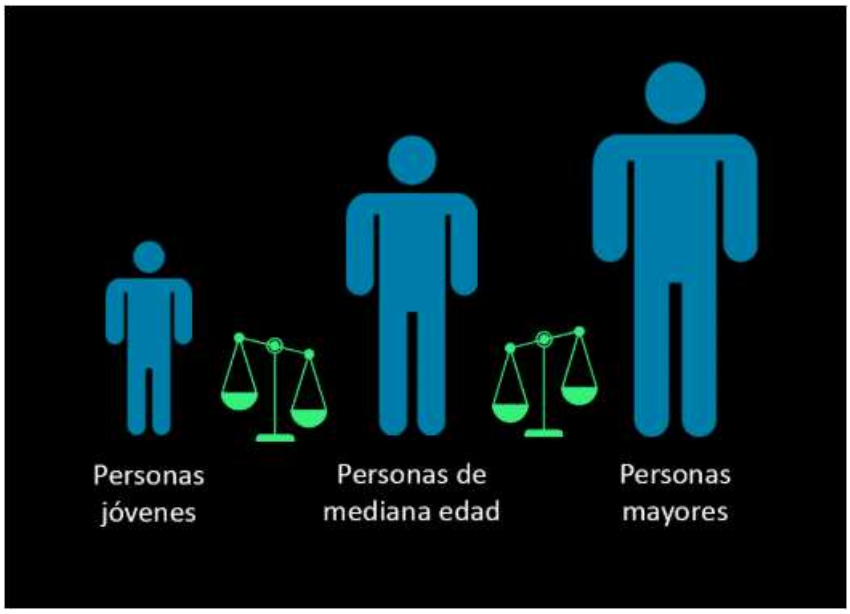


Para lograr conjuntos de datos equilibrados, los datos recopilados deben ser inclusivos y diversos, y los datos también deben seleccionarse con el fin de optimizarlos para su entrenamiento.

Recopilación de datos inclusiva y diversa

La inclusión y la diversidad en la recopilación de datos garantizan que los procesos de recopilación de datos sean justos e imparciales. La recopilación de datos debe reflejar con precisión las diversas perspectivas y las

experiencias necesarias para el caso práctico del sistema de IA. Esto incluye una amplia variedad de fuentes, puntos de vista y datos demográficos. De este modo, el sistema de IA puede trabajar para garantizar que las decisiones sean imparciales en su rendimiento.



Ejemplo que muestra un sesgo hacia las personas de mediana edad

Por ejemplo, si un modelo de ML se entrena principalmente con datos de personas de mediana edad, es posible que sea menos preciso a la hora de hacer predicciones que involucren a personas jóvenes y mayores. Por lo tanto, los conjuntos de datos deben recopilarse para que los grupos de edad estén representados de forma equitativa.

La inclusión y la diversidad en la recopilación de datos son una inquietud importante para los datos que se enfocan en las personas. Esto se debe a que la alienación de grupos de personas en los datos de entrenamiento puede provocar daños sociales y tener repercusiones legales. Sin embargo, la inclusión y la diversidad en la recopilación de datos deben ser un objetivo primordial, independientemente del tema. Por ejemplo, la recopilación de datos sobre las personas, las investigaciones científicas, la geografía, el clima, los productos y otros temas debe centrarse en la diversidad de cada uno de ellos.



Cuando se promueven la inclusión y la diversidad dentro de la IA, las organizaciones pueden promover la equidad, la transparencia y la rendición de cuentas en sus sistemas de IA y, a la vez, contribuir al desarrollo responsable de la tecnología de IA.

Selección de datos

La segunda parte del equilibrio de los conjuntos de datos consiste en su selección. La selección de los conjuntos de datos es el proceso de etiquetado, organización y procesamiento previo de los datos para que puedan funcionar con precisión en el modelo. La selección puede ayudar a garantizar que los datos sean representativos del problema en cuestión y estén libres de sesgos u otros problemas que puedan afectar a la exactitud del modelo de IA. La selección ayuda a garantizar que los modelos de IA se entrenen y evalúen a partir de datos confiables y de alta calidad que sean relevantes para la tarea que están destinados a realizar.

Los pasos principales de la selección de datos incluyen el procesamiento previo de datos, el aumento de datos y las auditorías periódicas.



- **Procesamiento previo de los datos:**
  Procese previamente los datos para garantizar que estén completos y sean exactos e imparciales. Algunas técnicas como la limpieza de datos, la normalización y la selección de características pueden ayudar a eliminar los sesgos en el conjunto de datos.
- **Aumento de datos:**
  Utilice técnicas de aumento de datos para generar nuevas instancias de grupos subrepresentados. Esto puede ayudar a equilibrar el conjunto de datos y evitar sesgos hacia grupos más representados.
- **Auditorías periódicas:**
  Audite periódicamente el conjunto de datos para garantizar que se mantenga equilibrado y equitativo. Compruebe si hay sesgos y tome medidas correctivas si es necesario.

Equilibre sus datos para el caso práctico previsto

El caso práctico del sistema de IA determinará cómo se deben equilibrar los datos. Por ejemplo, si está creando un sistema de inteligencia artificial sobre el cáncer infantil, deberá recopilar los datos y seleccionarlos para que se enfoquen en los niños y no incluyan conjuntos de datos sobre adultos.

MODELOS TRANSPARENTES Y EXPLICABLES

Para promover la confianza y la rendición de cuentas en un sistema de IA, el modelo debe ser transparente y explicable.

Los modelos deben ser transparentes y explicables:

Transparencia y explicabilidad:

Actualmente, los sistemas de IA son comunes en muchos campos que afectan a las empresas y a la sociedad. Algunos de estos campos incluyen la sanidad, la seguridad y las instituciones financieras. Debe existir la confianza y la rendición de cuentas en estos sistemas de IA. Por lo tanto, la inclusión de modelos transparentes y explicables es fundamental para desarrollar estos sistemas.



La transparencia responde a la pregunta del **CÓMO**, mientras que la explicabilidad responde a la del **POR QUÉ**. Ambos aspectos son necesarios para desarrollar sistemas de IA responsable.

- **Transparencia:**

  La transparencia permite entender **CÓMO** un modelo toma decisiones.

  De este modo, se garantiza la rendición de cuentas y se genera confianza en el sistema de IA. La transparencia también facilita la auditoría de un sistema.

- **Explicabilidad:**

  La explicabilidad permite entender **POR QUÉ** el modelo tomó una decisión determinada. Brinda información acerca de las limitaciones de un modelo.

  Esto ayuda a los desarrolladores a depurar y solucionar los problemas del modelo. También permite a los usuarios tomar decisiones informadas sobre cómo usarlo.

Modelos transparentes y explicables en comparación con los modelos de caja negra:

Los modelos que carecen de transparencia y explicabilidad suelen denominarse modelos de caja negra. Estos modelos utilizan algoritmos complejos y numerosas capas de redes neuronales para hacer predicciones, pero no proporcionan información sobre su funcionamiento interno.

Los modelos transparentes y explicables tienen varias ventajas frente a los modelos de caja negra.

Mayor confianza

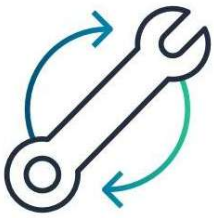
Los modelos transparentes y explicables pueden aumentar la confianza en los modelos y ayudar a los usuarios a entender por qué los modelos hacen ciertas predicciones. Esto puede ser particularmente importante en aplicaciones de alto riesgo, como la sanidad, los servicios financieros y el transporte, donde es crucial entender el razonamiento detrás de las decisiones de los modelos.



Más fácil de depurar y optimizar para obtener mejoras

Los modelos transparentes y explicables pueden ser más fáciles de depurar y mejorar que los modelos de caja negra. Al proporcionar información sobre el funcionamiento interno de los modelos, los desarrolladores pueden identificar los problemas y realizar mejoras específicas para optimizar su rendimiento.

Por el contrario, los modelos de caja negra pueden ser más difíciles de depurar y mejorar porque su funcionamiento interno no es transparente. Los desarrolladores pueden tener dificultades para identificar los problemas y realizar mejoras específicas. Como consecuencia, el ciclo de desarrollo podría ser más largo y los modelos podrían ser menos óptimos.



Mejor comprensión de los datos y del proceso de toma de decisiones del modelo

En términos de rendimiento, es posible que los modelos transparentes y explicables no siempre superen a los modelos de caja negra.

Sin embargo, pueden proporcionar una comprensión más completa de los datos y del proceso de toma de decisiones del modelo. Esto puede ser particularmente importante en aplicaciones en las que la explicabilidad es una consideración clave, como en la sanidad, donde los pacientes necesitan entender por qué se recomendó un tratamiento en particular.



Soluciones para los modelos transparentes y explicables:

No existe una solución estándar para crear modelos transparentes y explicables. Según el caso práctico del modelo, se pueden utilizar diferentes técnicas.

A continuación, se mencionan algunas soluciones posibles que permitirán aumentar la transparencia y la explicabilidad en los sistemas de IA a fin de ayudar a garantizar un desarrollo responsable de la IA.

- **Marcos de trabajo de explicabilidad:**

  Existen varios marcos de trabajo de explicabilidad disponibles, como el valor agregado de Shapley (Shapley Value Added, SHAP), la factorización matricial independiente del diseño (Layout-Independent Matrix Factorization, LIME) y las explicaciones contrafácticas, que pueden ayudar a resumir e interpretar las decisiones tomadas por los sistemas de IA. Estos marcos de trabajo pueden proporcionar información sobre los factores que influyeron en una decisión en particular y ayudar a evaluar la imparcialidad y la coherencia del sistema de IA.

- **Documentación transparente:**
  Mantenga una documentación clara y completa sobre la arquitectura, los orígenes de datos, los procesos de entrenamiento y las suposiciones subyacentes del sistema de IA, para que se pueda poner a disposición de las partes interesadas y los auditores pertinentes.

  Esto puede incluir guías del usuario, documentación técnica y visualizaciones que ayuden a los usuarios a comprender los algoritmos subyacentes y sus entradas y salidas.

- **Supervisión y auditoría:**
  Los sistemas de IA deben supervisarse y auditarse para garantizar que funcionan según lo previsto y no muestran sesgos o comportamientos discriminatorios. Esto puede incluir pruebas y supervisión periódicas por parte de humanos y herramientas automatizadas para identificar patrones o decisiones inusuales.

- **Supervisión y participación humana:**
  Incorpore la supervisión y la participación humana en los procesos críticos de toma de decisiones en los que los humanos puedan revisar y validar los resultados y las decisiones del sistema de IA, especialmente en situaciones de alto riesgo.

- **Explicaciones contrafácticas:**
  Proporcione explicaciones contrafácticas que muestren cómo cambiaría los resultados si ciertas características de entrada fueran diferentes para ayudar a los usuarios a comprender el comportamiento y el razonamiento del modelo.

- **Explicaciones de la interfaz de usuario:**
  Diseñe interfaces de usuario que proporcionen a los usuarios finales explicaciones claras y comprensibles de los resultados, la justificación y las limitaciones del sistema de IA, para que puedan tomar decisiones informadas.

Riesgos de los modelos transparentes y explicables:

Así como los modelos transparentes y explicables ofrecen muchas ventajas, también conllevan algunos riesgos. Algunos de esos riesgos son los siguientes:

- Un incremento en la complejidad del desarrollo y el mantenimiento del modelo puede dar como resultado el aumento de los costos.

- La creación de vulnerabilidades del modelo, los datos y los algoritmos puede estar sujeta a la explotación de parte de actores malintencionados.
- Presentar expectativas poco realistas de que el modelo es perfectamente transparente y explicable. En algunas situaciones, es posible que esto no se pueda lograr o no se pretenda hacerlo.
- Proporcionar demasiada información puede crear problemas de privacidad y seguridad. También podría comprometer la ventaja competitiva del modelo.

Herramientas de AWS para la transparencia y explicabilidad:

Herramientas de AWS para la transparencia:

Para contribuir a la transparencia, Amazon ofrece fichas de servicio de IA de AWS y tarjetas de modelos de Amazon SageMaker. La diferencia entre ellas es que, con las tarjetas de servicio de IA, Amazon proporciona documentación transparente sobre los servicios de Amazon que ayudan a crear sus servicios de IA. Con las tarjetas de modelos de SageMaker, puede catalogar y proporcionar documentación sobre los modelos que cree o desarrolle usted mismo.

- **Fichas de servicio de IA de AWS:**

  Las fichas de servicio de IA son un recurso que permite aumentar la transparencia y ayudar a los clientes a entender mejor los servicios de IA de AWS, incluido cómo usarlos de forma responsable. Las fichas de servicio de IA son una forma de documentación de IA responsable que proporciona a los clientes un único lugar donde encontrar información sobre los casos prácticos y las limitaciones previstos, las opciones de diseño de IA responsable y las prácticas recomendadas de implementación y operación de nuestros servicios de IA.

- **Amazon SageMaker Model Cards:**

  Utilice las **Tarjetas de modelos de SageMaker** para documentar los detalles críticos de sus modelos de machine learning en un solo lugar a fin de simplificar la gobernanza y la elaboración de informes.

  Los detalles del catálogo incluyen información como el uso previsto y la clasificación de riesgo de un modelo, los detalles y las métricas del entrenamiento, los resultados y las observaciones de la evaluación y otras notas adicionales, como consideraciones, recomendaciones e información personalizada.

Herramientas de AWS para una mejor explicabilidad:

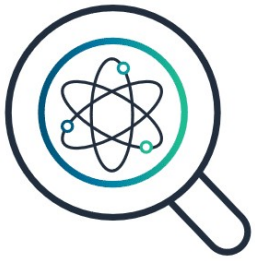
SageMaker AI Clarify

SageMaker AI Clarify está integrado con SageMaker AI Experiments para proporcionar puntuaciones que detallan qué características tienen una mayor contribución a la predicción del modelo en una entrada en particular para los modelos tabulares, de NLP y de visión artificial. Para los conjuntos de datos tabulares, SageMaker AI Clarify también puede generar un gráfico de importancia de las características agregadas, en el cual se proporciona información sobre el proceso de predicción general del modelo. Estos detalles pueden ayudar a determinar si una entrada del modelo en particular tiene más influencia de la esperada en el comportamiento general del modelo.



SageMaker Autopilot

Amazon SageMaker Autopilot utiliza las herramientas de SageMaker AI Clarify para ayudar a proporcionar información sobre cómo los modelos de ML realizan predicciones. Estas herramientas pueden ayudar a los ingenieros de ML, a los directores de productos y a otras partes interesadas internas a comprender las características del modelo. Para confiar e interpretar las decisiones tomadas a partir de las predicciones de los modelos, tanto los consumidores como los reguladores confían en la transparencia del machine learning.



La funcionalidad explicativa del SageMaker Autopilot determina la contribución de las características o entradas individuales al resultado del modelo y proporciona información sobre la relevancia de las diferentes características. Se puede utilizar para comprender por qué un modelo hizo una predicción después del entrenamiento o para proporcionar una explicación por instancia durante la inferencia.

VENTAJAS Y DESVENTAJAS DEL MODELO

Ventajas y desventajas de la interpretabilidad:

La interpretabilidad es una característica de la transparencia del modelo. Es el grado en que un ser humano puede entender la causa de una decisión. Esto puede sonar muy parecido a la explicabilidad, pero hay una diferencia distintiva.

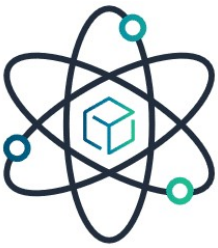
- **Interpretabilidad:**

  La interpretabilidad es el acceso a un sistema para que un humano pueda interpretar el resultado del modelo en función de las ponderaciones y las características. Por ejemplo, si una empresa desea que el modelo cuente con un alto grado de transparencia y quiere entender exactamente por qué y cómo el modelo está generando predicciones, necesita observar la mecánica interna del método de IA o ML.



- **Explicabilidad:**

  La explicabilidad se refiere a cómo tomar un modelo de ML y explicar el comportamiento en términos humanos. Con los modelos complejos (por ejemplo, las cajas negras), no se puede entender completamente cómo y por qué la mecánica interna afecta a la predicción. Sin embargo, mediante los métodos independientes del modelo (por ejemplo, gráficas de dependencia parcial, gráficas de dependencia SHAP o modelos sustitutos), se puede descubrir el significado entre las atribuciones de los datos de entrada y los resultados del modelo. Con esa comprensión, se puede explicar la naturaleza y el comportamiento del modelo de IA o ML.



- **Ejemplo de interpretabilidad:**

  Un economista quiere construir un modelo de regresión multivariante para predecir una tasa de inflación. Podrá ver los parámetros estimados de las variables del modelo para medir el resultado esperado a partir de diferentes ejemplos de datos. En este caso, se brinda total transparencia y el economista puede responder exactamente el por qué y el cómo del comportamiento del modelo.

- **Ejemplo de explicabilidad:**

  Un medio de comunicación utiliza una red neuronal para asignar categorías a diferentes artículos. El medio de comunicación no puede interpretar el modelo en profundidad. Sin embargo, puede usar un enfoque independiente del modelo para evaluar los datos de entrada del artículo en comparación con las predicciones del modelo. Con este enfoque, se descubre que el modelo asigna la categoría de deportes a los artículos de negocios que mencionan a las organizaciones deportivas. Aunque el medio de comunicación no utilizó la interpretabilidad del modelo, aun así pudo obtener una respuesta explicable para revelar su comportamiento.

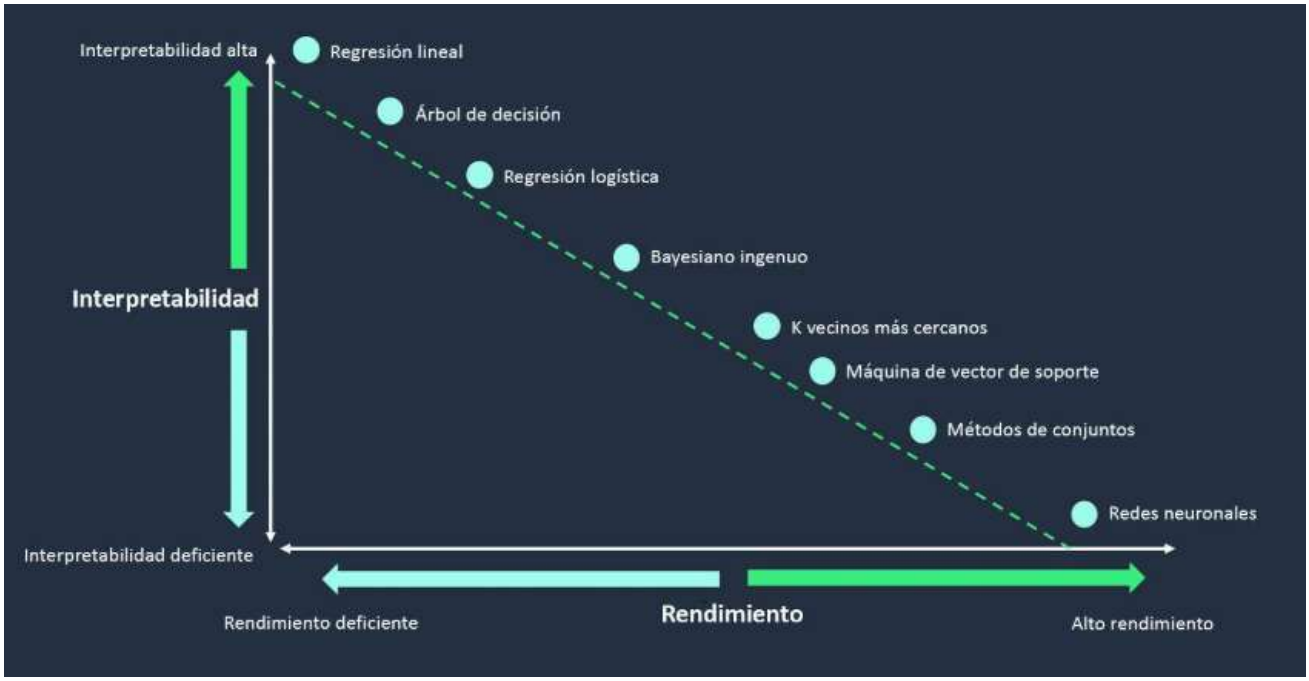


Diagrama que muestra cómo la interpretabilidad de un modelo puede afectar al rendimiento.

Si una empresa desea que el modelo tenga un alto grado de transparencia y quiere entender exactamente por qué y cómo el modelo genera las predicciones, entonces necesita un modelo que ofrezca capacidad de interpretabilidad. Sin embargo, la alta capacidad de interpretabilidad suele ir en detrimento del rendimiento, como se ve en el diagrama.

Si una empresa quiere lograr un alto rendimiento, pero aun así quiere tener una comprensión general del comportamiento del modelo, la explicabilidad del modelo comienza a desempeñar un papel más importante.

Cuando inicia un nuevo proyecto de IA o ML, debe considerar si es necesaria la interpretabilidad. La explicabilidad del modelo se puede usar en cualquier caso práctico de IA o ML, pero si se requiere una transparencia detallada, la selección de métodos de IA o ML se vuelve limitada.

Ventajas y desventajas de la seguridad y la transparencia:

Seguridad del modelo:

La seguridad de los modelos es la capacidad de un sistema de IA para evitar causar daños en sus interacciones con el mundo. Esto incluye evitar el daño social, como el sesgo en los algoritmos de toma de decisiones y evitar la exposición a vulnerabilidades de privacidad y seguridad. La seguridad de los modelos es importante para garantizar que los sistemas de IA se utilicen de manera tal que beneficien a la sociedad y no causen daño a individuos o grupos.



Ventajas y desventajas de la seguridad y de la transparencia del modelo:

Dado que la seguridad de los modelos se enfoca en la protección de la información y la transparencia de los modelos en la exposición de la información, es comprensible que exista un equilibrio frágil entre ambas.

- **Exactitud:**
  Los modelos complejos, como las grandes redes neuronales, tienden a ser más precisos, pero menos interpretables que los modelos lineales más simples, que son más transparentes.
- **Privacidad:**
  Las técnicas de preservación de la privacidad, como la privacidad diferencial, pueden mejorar la seguridad, pero dificultan la inspección de los modelos. Esto puede hacer que los modelos sean menos transparentes.
- **Seguridad:**
  Restringir o filtrar los resultados del modelo por motivos de seguridad puede reducir la transparencia del razonamiento del modelo original.
- **Protección:**
  Los modelos de entrenamiento altamente protegidos (modelos que se entrenan en redes que son privadas y no tienen acceso a datos externos) podrían estar menos abiertos a auditorías externas.

Capacidad de control del modelo:

Control del modelo:

Un modelo controlable es aquel en el que se puede influir en sus predicciones y el comportamiento con el cambio de los aspectos de los datos de entrenamiento. Una mayor capacidad de control proporciona más transparencia en el modelo y permite corregir sesgos y resultados no deseados.

La capacidad de control del modelo se mide por el grado de control que se tiene sobre el modelo al momento de cambiar los datos de entrada. Los modelos que son más controlables son más fáciles de orientar hacia los comportamientos deseados. Esto es importante para la equidad, ya que se busca que se pueda comprender y controlar el sesgo en el modelo. La capacidad de control de un modelo también es importante para su transparencia y depuración.



La capacidad de control depende de la arquitectura del modelo. Los modelos lineales tienden a ser más controlables que los modelos neuronales complejos. Se puede comprobar la capacidad de control evaluando si la manipulación de los datos, como agregar o eliminar ejemplos, provoca los cambios esperados en los resultados y predicciones del modelo. La capacidad de control se puede mejorar con las técnicas de aumento de datos y agregando restricciones al proceso de entrenamiento de modelos.



PRINCIPIOS DEL DISEÑO ENFOCADO EN EL SER HUMANO PARA UNA IA EXPLICABLE

El diseño enfocado en el ser humano (human-centered design, HCD) es un enfoque que permite crear productos y servicios intuitivos y fáciles de usar que satisfagan las necesidades de los usuarios. Cuando se aplica a la IA explicable, el HCD ayuda a garantizar que las explicaciones e interfaces proporcionadas sean claras, comprensibles y útiles para las personas a las que están destinadas. Esto incluye ser preciso y justo.

A continuación, se mencionan los principios clave del diseño enfocado en el ser humano para una IA explicable:

- Un diseño que permita una toma de decisiones amplificada.
- Un diseño que permita una toma de decisiones imparcial.
- Un diseño que permita el aprendizaje humano y de la IA.

Un diseño que permite una toma de decisiones amplificada:

El principio de diseño que permita una toma de decisiones amplificada apoya a los responsables de la toma de decisiones en situaciones de alto riesgo. Este principio busca maximizar los beneficios del uso de la tecnología y minimizar los posibles riesgos y errores, especialmente aquellos que pueden ocurrir cuando los humanos toman decisiones bajo estrés o en entornos de alta presión. Esto puede conducir a mejores resultados para las personas, las organizaciones y la sociedad en su conjunto.



Aspectos clave del diseño que permita una toma de decisiones amplificada:

Cuando realiza un diseño que permita una toma de decisiones amplificada, usted puede ayudar a mitigar los errores delicados. Algunos aspectos clave del diseño que permite una toma de decisiones amplificada incluyen el diseño orientado a la claridad, la simplicidad, la usabilidad, la reflexividad y la rendición de cuentas.

- **Claridad:**

  Diseñar pensando en la claridad garantiza que la información se presente de manera tal que sea fácil de entender e interpretar sin introducir sesgos o malentendidos.
- **Simplicidad:**

  Diseñar pensando en la simplicidad minimiza la cantidad de información que debe procesar el usuario y, al mismo tiempo, proporciona toda la información necesaria para tomar una decisión.
- **Usabilidad:**

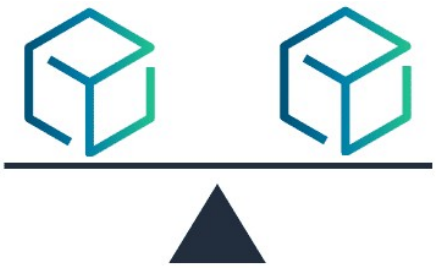
  Diseñar para la usabilidad significa diseñar tecnología que sea fácil de usar y navegar independientemente del nivel de experiencia o las habilidades técnicas del usuario.
- **Reflexividad:**

  Diseñar para la reflexividad significa diseñar tecnología que incite a los usuarios a reflexionar sobre su proceso de toma de decisiones y los aliente a asumir la responsabilidad de sus elecciones.
- **Rendición de cuentas:**

  El diseño orientado a la rendición de cuentas atribuye consecuencias a las decisiones tomadas con tecnología amplificada, por lo que los usuarios son responsables de sus acciones.

Un diseño que permita una toma de decisiones imparcial:

El diseño de principios y prácticas que permita una toma de decisiones imparcial tiene como objetivo garantizar que el diseño de los procesos, los sistemas y las herramientas de toma de decisiones estén libres de sesgos que puedan influir en los resultados. Esto puede tener un impacto significativo en los resultados de la toma de decisiones y ayudar a promover la equidad y el uso eficiente de los recursos.



El diseño que permite una toma de decisiones imparcial implica los siguientes pasos:

- Identificar y evaluar los posibles sesgos.
- Diseñar procesos y herramientas de toma de decisiones que sean transparentes y equitativos.
- Capacitar a los responsables de la toma de decisiones para que reconozcan y mitiguen los sesgos.

Aspectos clave del diseño que permite una toma de decisiones imparcial:

Cuando se realiza un diseño que permite una toma de decisiones imparcial, se pueden crear procesos de toma de decisiones más efectivos. Algunos de los aspectos clave que se deben incorporar en el diseño que permita una toma de decisiones imparcial incluyen la transparencia, la equidad y la capacitación.

- **Transparencia:**

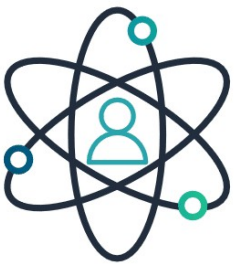
  Los procesos y las herramientas de toma de decisiones deben diseñarse de manera clara y accesible para todas las partes interesadas. Estos procesos deberían facilitar el escrutinio y la identificación de los posibles sesgos. Esto puede conllevar el uso de técnicas de visualización de datos para hacer que la información compleja sea más accesible e intuitiva y proporcionar explicaciones claras del proceso de toma de decisiones y lo que implica.
- **Equidad:**

  Los procesos y las herramientas de toma de decisiones deben diseñarse para minimizar la injusticia y la discriminación. Deben ayudar a garantizar que todas las partes interesadas tengan las mismas oportunidades de participar e influir en los resultados. Esto puede implicar el diseño de procesos de toma de decisiones que incluyan diversas perspectivas y experiencias. También implica evitar el uso de criterios o métricas sesgados que puedan perpetuar los estereotipos.
- **Formación:**

  Los responsables de la toma de decisiones, incluidos los responsables políticos, los jueces y los líderes empresariales, deben estar capacitados para reconocer y mitigar los sesgos. Esto puede implicar proporcionar formación para ayudar a los responsables de la toma de decisiones a desarrollar estrategias que los ayuden a gestionar y superar los sesgos.

Un diseño que permita el aprendizaje humano y de la IA:

El diseño que permite el aprendizaje humano y de la IA es un proceso que tiene como objetivo crear entornos y herramientas de aprendizaje beneficiosos y eficaces tanto para los seres humanos como para la IA. Abarca una variedad de estrategias y enfoques que tienen en cuenta las fortalezas y limitaciones únicas de cada estudiante y los objetivos y propósitos de la experiencia de aprendizaje.



Aspectos clave del diseño que permite el aprendizaje humano y de la IA:

Cuando diseña para el aprendizaje humano y de la IA, puede crear sistemas de IA más eficaces. Algunos de los aspectos clave que se deben incorporar al diseñar para el aprendizaje humano y de la IA incluyen el aprendizaje cognitivo, la personalización y el diseño enfocado en el usuario.

- **Aprendizaje cognitivo:**

  El aprendizaje cognitivo se refiere al proceso en el que los seres humanos aprenden nuevas habilidades y conocimientos mediante la observación y la interacción con personas más capacitadas y conocedoras, como maestros o mentores. En el aprendizaje de la IA, esto implica la creación de entornos de aprendizaje en los que los sistemas de IA aprendan de instructores y expertos humanos, y adquieran experiencia y conocimientos a través de escenarios simulados o del mundo real.

- **Personalización:**

  La personalización se refiere al proceso de adaptar las experiencias y las herramientas de aprendizaje para satisfacer las necesidades y las preferencias específicas de cada estudiante. Mediante el uso de algoritmos de ML y el análisis de datos, los desarrolladores pueden crear recomendaciones y algoritmos de aprendizaje personalizados que se adapten al estilo de aprendizaje y las necesidades únicas de cada estudiante.

- **Diseño enfocado en el usuario:**

  El diseño enfocado en el usuario implica diseñar entornos y herramientas de aprendizaje que sean intuitivos y accesibles para una amplia gama de estudiantes, incluidos aquellos con discapacidades o barreras lingüísticas. Cuando se priorizan la experiencia del usuario y la usabilidad, los diseñadores pueden garantizar que los entornos de aprendizaje sean efectivos y atractivos para todos los usuarios.

Aprendizaje por refuerzo a partir de la retroalimentación humana:

El aprendizaje por refuerzo a partir de la retroalimentación humana (reinforcement learning from human feedback, RLHF) es una técnica de ML que utiliza la retroalimentación humana para optimizar los modelos de ML a fin de que el autoaprendizaje sea más eficiente. Las técnicas de aprendizaje por refuerzo (reinforcement learning, RL) entrenan al software para que tome decisiones que maximicen las recompensas, lo que hace que sus resultados sean más precisos. El RLHF incorpora la retroalimentación humana en la función de recompensas, por lo que el modelo de ML puede realizar tareas alineadas con los objetivos, deseos y necesidades humanos. El RLHF se utiliza tanto en aplicaciones de IA tradicional como de IA generativa.

Beneficios del RLHF:

A continuación, se mencionan algunos de los beneficios del RLHF:

- Mejora el rendimiento de la IA.
- Proporciona parámetros de entrenamiento complejos.
- Aumenta la satisfacción de los usuarios.

Amazon SageMaker Truth:

SageMaker Ground Truth ofrece el conjunto más completo de capacidades de interacción humana en bucle para incorporar la retroalimentación humana a través del ciclo de vida del ML para mejorar la exactitud y relevancia del modelo. SageMaker Ground Truth incluye un anotador de datos para las funciones de RLHF. Se puede proporcionar retroalimentación directa y orientación sobre el resultado que un modelo generó clasificando, ordenando o haciendo ambas cosas con las respuestas en los resultados del RL. Los datos, denominados datos de comparación y clasificación, son, en efecto, un modelo o una función de recompensa que luego se utiliza para entrenar al modelo. Puede utilizar los datos de comparación y clasificación para personalizar un modelo existente destinado a su caso práctico o para ajustar un modelo que va a crear desde cero.



Amazon SageMaker Ground Truth