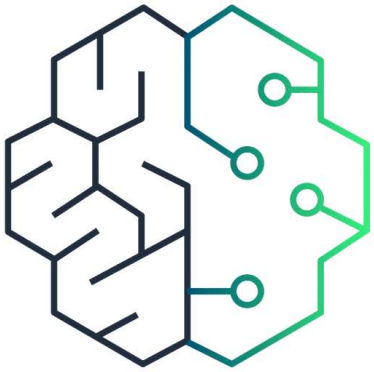
DEVELOPING GENERATIVE AI SOLUTIONS

INTRODUCCIÓN.

En este curso, explorará el ciclo de vida de las aplicaciones de inteligencia artificial generativa (IA generativa), que incluye lo siguiente:

- Definición de un caso práctico empresarial
- Selección de un modelo fundacional (FM)
- Mejora del rendimiento de un FM
- Evaluación del rendimiento de un FM
- Implementación e impacto en los objetivos empresariales

Este curso es una introducción a los cursos de IA generativa, que profundizan en los conceptos relacionados con la personalización de un FM mediante la ingeniería de peticiones, la generación mejorada por recuperación (RAG) y las operaciones de ajuste.



CICLO DE VIDA DE LAS APLICACIONES DE IA GENERATIVA

Capacidades y desafíos del uso de la IA generativa:

Antes de explorar el ciclo de vida de las aplicaciones de IA generativa, es importante comprender algunas de las capacidades y desafíos del uso de esta tecnología.

- **Capacidad de la IA generativa:**
  - ✓ Adaptabilidad
  - ✓ Capacidad de respuesta
  - ✓ Simplicidad
  - ✓ Creatividad y exploración

- ✓ Eficiencia de datos
- ✓ Personalización
- ✓ Escalabilidad

- **Desafíos de la IA generativa:**
  - ✓ Infracciones normativas
  - ✓ Riesgos sociales
  - ✓ Inquietudes relativas a la seguridad y privacidad de los datos
  - ✓ Toxicidad
  - ✓ Alucinaciones
  - ✓ Interpretabilidad
  - ✓ Indeterminismo

Ciclo de vida de las aplicaciones de IA generativa:

El ciclo de vida de las aplicaciones de IA generativa se refiere al proceso de uso de modelos de IA generativa en aplicaciones o sistemas.



1. **Definir un caso práctico:**

   En la primera etapa, se identifican los requisitos para incorporar capacidades de IA generativa en una aplicación. Esto podría implicar el análisis de las funcionalidades de la aplicación, las necesidades de los usuarios y los objetivos empresariales para determinar dónde puede agregar valor la IA generativa.

2. **Seleccionar un modelo fundacional:**

   En función de los requisitos identificados, se selecciona un modelo de IA generativa adecuado a partir de los modelos existentes previamente entrenados o se desarrolla desde cero. Esta decisión depende de factores como la disponibilidad de modelos previamente entrenados adecuados, la complejidad del caso práctico y la disponibilidad de datos específicos del dominio para el entrenamiento.

3. **Mejorar el rendimiento:**

   El modelo de IA generativa seleccionado o desarrollado se integra en la infraestructura o base de código de la aplicación. Esto puede implicar la adaptación de los formatos de entrada y salida del modelo, el ajuste del modelo con datos específicos de la aplicación y la implementación de las personalizaciones u optimizaciones necesarias.

4. **Evaluar resultados:**

   Se realizan pruebas y evaluaciones exhaustivas de las capacidades de IA generativa integradas para garantizar que cumplen con los requisitos especificados y funcionan según lo esperado. Esto puede implicar la ejecución de pruebas con diversas entradas, casos extremos y situaciones del mundo real, así como la evaluación de la calidad, la coherencia y la relevancia del contenido generado.

5. **Implementación:**

   Tras un resultado satisfactorio de las pruebas, la aplicación con capacidades de IA generativa integradas se implementa en el entorno de producción. Los mecanismos de supervisión se establecen para rastrear el rendimiento, el uso y los posibles problemas o sesgos asociados con los resultados del modelo de IA generativa.

Tras la implementación, se recopilan y analizan continuamente los comentarios de los usuarios, los datos de uso y las métricas de rendimiento para identificar áreas de mejora o nuevos requisitos. En función de estos comentarios, el modelo de IA generativa podría volver a entrenarse, ajustarse o actualizarse para mejorar su rendimiento y abordar cualquier problema identificado.

Es importante tener en cuenta que el ciclo de vida de las aplicaciones de IA generativa es un proceso iterativo, y es posible que sea necesario revisar o repetir diferentes etapas a medida que la aplicación evoluciona, las necesidades de los usuarios cambian o surgen nuevos avances en las tecnologías de IA generativa.

DEFINICIÓN DE UN CASO PRÁCTICO

Capacidades y desafíos del uso de la IA generativa:

Antes de explorar el ciclo de vida de las aplicaciones de IA generativa, es importante comprender algunas de las capacidades y desafíos del uso de esta tecnología.



La primera etapa del ciclo de vida de las aplicaciones de IA generativa consiste en definir un caso práctico. Esta fase es la base que establece el camino para todo el proyecto haciendo lo siguiente:

- Definir el problema a resolver

- Recopilar los requisitos pertinentes
- Alinear las expectativas de las partes interesadas

Es imprescindible completar bien esta etapa, ya que informa todos los pasos posteriores y, en última instancia, determina el éxito o el fracaso de la aplicación de IA generativa. Durante esta fase crucial, los equipos deben analizar cuidadosamente el espacio problemático, consultar con expertos en la materia y traducir las necesidades empresariales en especificaciones técnicas que puedan guiar el proceso de desarrollo.

Es importante identificar desde el principio qué información incluir en su caso de uso empresarial.

Casos prácticos empresariales:

Un caso práctico empresarial es una narración estructurada que describe cómo debe comportarse un sistema o proceso desde la perspectiva de un actor o parte interesada. Ayuda a comunicar los requisitos funcionales de un sistema o proceso.

Partes de un caso práctico:

Un caso práctico empresarial bien definido suele constar de las siguientes partes:

- **Nombre del caso práctico:**
  Un nombre breve y descriptivo que identifique el caso práctico
- **Breve descripción:**
  Un resumen de alto nivel del propósito y el objetivo del caso práctico
- **Actores:**
  Las entidades o partes interesadas que interactúan con el sistema o proceso
  Estas pueden ser actores humanos (por ejemplo, clientes o empleados) o sistemas externos.
- **Condiciones previas:**
  Las condiciones que deben cumplirse antes de que se pueda iniciar el caso práctico
- **Flujo básico (situación de éxito principal):**
  Una descripción paso a paso de las acciones e interacciones que se producen cuando el caso de uso se completa correctamente, de principio a fin
  Este es el camino principal o la "ruta correcta"; por ejemplo, una lista de cada paso necesario para lograr el éxito.

- **Flujos alternativos (extensiones):**
  Escenarios o rutas adicionales que pueden ocurrir debido a condiciones excepcionales, errores o elecciones alternativas del usuario
  En ellas se describe cómo el sistema debe gestionar estas situaciones, por ejemplo, los planes de contingencia.
- **Condiciones posteriores:**
  El estado o las condiciones que deben cumplirse después de completar con éxito el caso práctico
- **Reglas empresariales:**
  Cualquier política, restricción o regulación empresarial que rija el comportamiento del sistema o proceso en el contexto del caso práctico
- **Requisitos no funcionales:**
  Cualquier requisito no funcional, como consideraciones de rendimiento, seguridad o usabilidad, que sea relevante para el caso práctico
- **Suposiciones:**
  Cualquier suposición hecha sobre el sistema, el entorno o el contexto que sea necesaria para que el caso práctico sea válido o aplicable
- **Notas o información adicional:**
  Cualquier nota, explicación o información complementaria adicional que pueda ser útil para comprender o implementar el caso práctico

Planteamiento de casos prácticos empresariales con IA generativa:

Cuando se trata de resolver problemas empresariales mediante la IA generativa, hay varias métricas y enfoques que se pueden emplear.

Métricas clave:

- **Ahorro de costos:**
  Una de las métricas principales son los posibles ahorros de costos que se pueden lograr mediante el uso de la IA generativa. Esto incluye la reducción de los costos laborales, la optimización de los procesos y el aumento de la eficiencia.



- **Ahorro de tiempo:**

  La IA generativa puede automatizar y agilizar varias tareas, lo que supone un importante ahorro de tiempo. Medir la reducción del tiempo requerido para procesos o actividades específicos puede ser una métrica valiosa.



- **Mejora de la calidad:**

  La IA generativa puede mejorar la calidad de los resultados, como el contenido escrito, los diseños creativos o la información analítica. Las métricas como la precisión, la coherencia y la creatividad se pueden utilizar para medir las mejoras de calidad.



- **Satisfacción del cliente:**

  Si la IA generativa se utiliza para mejorar las interacciones o las experiencias de los clientes, las métricas, como las puntuaciones de satisfacción del cliente, la puntuación neta del promotor (Net Promoter Scores, NPS) o el análisis de sentimiento, pueden ser indicadores valiosos.



- **Ganancia de productividad:**

  La IA generativa puede aumentar las capacidades humanas, lo que lleva a un aumento de la productividad. Métricas como el volumen de producción, las tasas de error o los tiempos de finalización de las tareas pueden medir las mejoras en la productividad.



Enfoques:

- **Automatización de procesos:**

  La IA generativa se puede utilizar para automatizar tareas repetitivas o que consumen mucho tiempo, como la generación de contenido, el análisis de datos o las interacciones del servicio de atención al cliente. Este enfoque puede generar importantes ganancias de eficiencia y ahorros de costos.

- **Optimización de la toma de decisiones:**
  La IA generativa se puede utilizar para mejorar los procesos de toma de decisiones al proporcionar información, recomendaciones y apoyo para dichos procesos. Al analizar conjuntos de datos grandes y complejos, los modelos de IA generativa pueden descubrir patrones, tendencias e información procesable que pueden informar y mejorar las decisiones empresariales y, en última instancia, generar mejores resultados.

- **Personalización:**
  La IA generativa se puede utilizar para crear contenido, productos o experiencias personalizados para los clientes o las partes interesadas. Este enfoque puede mejorar la satisfacción, el compromiso y la lealtad del cliente.

- **Generación de contenido creativo:**
  La IA generativa se puede emplear para generar contenido creativo, como texto escrito, imágenes, videos o audio. Este enfoque puede ser valioso para fines de marketing, publicidad, entretenimiento o educativos.

- **Análisis exploratorio e innovación:**
  La IA generativa se puede utilizar para explorar nuevas ideas, conceptos o soluciones mediante la generación de combinaciones o variaciones novedosas. Este enfoque puede fomentar la innovación y ayudar a las empresas a mantenerse a la vanguardia de la tecnología.

Es importante tener en cuenta que las métricas y los enfoques específicos dependerán del problema empresarial en cuestión, del sector y de los objetivos y prioridades de la organización.

DEFINICIÓN DE UN CASO PRÁCTICO



Una vez que se define el caso práctico, la siguiente fase es la selección de un modelo fundacional apropiado. Esta elección sienta las bases para el proceso de entrenamiento iterativo y tiene profundas implicaciones para

el rendimiento, la eficiencia y la solidez de la aplicación final. Una consideración clave es si usar modelos previamente entrenados o desarrollar un modelo desde cero.

Criterios de selección de modelos previamente entrenados:

Los modelos previamente entrenados ofrecen una valiosa ventaja al encapsular el conocimiento extraído de grandes cantidades de datos. Estos modelos se pueden ajustar con datos específicos de tareas, lo que podría conducir a una convergencia más rápida y a una mejor generalización. Sin embargo, los modelos previamente entrenados pueden tener sesgos no deseados o no captar completamente los matices del dominio de destino.

Los criterios de selección para elegir un modelo previamente entrenado dependen de los requisitos del caso de uso empresarial.

Algunos criterios a tener en cuenta son los siguientes:

- **Asignaciones:**

  Los modelos previamente entrenados pueden ser costosos, especialmente para los modelos más grandes y complejos. El costo puede incluir las tarifas de licencia, los recursos computacionales para la inferencia y los posibles costos de personalización o ajuste. Es esencial evaluar las restricciones presupuestarias y sopesar el costo con los beneficios esperados.



- **Modalidad:**

  Los modelos de IA generativa se pueden diseñar para diferentes modalidades, como la generación de texto, la generación de imágenes, la generación de audio o la generación multimodal (que combina múltiples modalidades). La elección de la modalidad depende del formato de salida deseado y de la aplicación de destino.



- **Latencia:**

  Algunas aplicaciones requieren una generación en tiempo real o de baja latencia, y otras pueden tolerar tiempos de procesamiento más prolongados. La velocidad de inferencia del modelo y los recursos computacionales disponibles deben evaluarse para garantizar una latencia aceptable para el caso práctico objetivo.



- **Soporte multilingüe:**

  Si la aplicación requiere generar contenido en varios idiomas, es crucial seleccionar un modelo que admita los idiomas deseados o que pueda adaptarse a nuevos idiomas mediante técnicas como el aprendizaje por transferencia.



- **Tamaño del modelo:**

  Los modelos más grandes generalmente tienen requisitos computacionales más altos y pueden consumir más recursos durante la inferencia. Sin embargo, a menudo se desempeñan mejor en tareas complejas. El tamaño del modelo debe equilibrarse con los recursos computacionales disponibles y los requisitos de rendimiento.



- **Complejidad del modelo:**

  Los modelos más complejos, como los basados en arquitecturas transformadoras o modelos de lenguaje grandes, pueden gestionar tareas más avanzadas, pero pueden ser más difíciles de implementar y optimizar. Es posible que se prefieran modelos más simples para entornos con recursos limitados o casos prácticos más simples.



- **Personalización:**

  Algunos modelos previamente entrenados ofrecen la posibilidad de ajustarse o adaptarse a dominios o tareas específicos. Esta personalización puede mejorar el rendimiento, pero puede requerir recursos computacionales adicionales y datos etiquetados.



- **Longitud de entrada/salida:**

  Los modelos generativos pueden tener limitaciones en cuanto a las longitudes máximas de secuencia de entrada o salida que pueden manejar. Las aplicaciones que requieren la generación de formatos prolongados o el procesamiento de datos de entrada extensos deben considerar modelos capaces de manejar las longitudes de entrada/salida deseadas.



- **Consideraciones sobre la responsabilidad:**

  Es importante evaluar las implicaciones de responsabilidad del uso de modelos de IA generativa previamente entrenados, como los posibles sesgos, los riesgos de desinformación o el uso indebido. Los modelos deben ser examinados por sus orígenes de datos de entrenamiento y sus posibles efectos sociales.



- **Implementación e integración:**

  Se debe considerar la facilidad de implementación, la compatibilidad con la infraestructura existente y la disponibilidad de herramientas o bibliotecas para integrar el modelo en la aplicación de destino.



Es esencial evaluar cuidadosamente estos criterios y priorizar los factores más críticos en función del caso práctico empresarial específico, incluidas las restricciones y las compensaciones involucradas.

Elección de un modelo previamente entrenado en función de los criterios de selección:

Comparar modelos de IA generativa previamente entrenados en función de criterios de selección puede ser una tarea compleja. Hay muchos factores a tener en cuenta y la importancia relativa de cada uno de ellos puede variar según el caso práctico empresarial específico.

1. **AI21 Labs (Serie Jurassic-2):**

   Jurassic-2 (J2) es el modelo de lenguaje grande (Large Language Model, LLM) de última generación de AI21 Labs. Las empresas utilizan la familia AI21 Jurassic para crear aplicaciones y servicios generativos impulsados por la IA utilizando los datos organizacionales existentes. Jurassic admite casos prácticos intersectoriales, incluida la generación de texto de formato largo y corto, la respuesta contextual a preguntas, el resumen y la clasificación.

2. **Amazon (Titan):**

   Los modelos fundacionales de Amazon Titan son una familia de modelos creados por Amazon Web Services (AWS) que están entrenados previamente con grandes conjuntos de datos, lo que los convierte en modelos potentes y de uso general. Úselos tal cual o personalícelos mediante el ajuste de los modelos con sus propios datos para una tarea en particular sin anotar grandes volúmenes de datos.

   Existen tres tipos de modelos Amazon Titan: incrustaciones, de generación de texto y de generación de imágenes.

3. **ANTHROP\C (Claude):**

   Claude 3 es la familia de modelos de IA de visión y texto de última generación de Anthropic. Los tres modelos de la familia (Haiku, Sonnet y Opus) permiten a los clientes elegir la combinación exacta de inteligencia, velocidad y costo que se adapte a sus necesidades empresariales.

4. **Cohere (Command XL):**

   Cohere proporciona un LLM generativo, Command, que puede generar respuestas basadas en texto a partir de indicaciones. Los modelos de Cohere se basan en datos que admiten aplicaciones empresariales fiables, como la generación de texto, el resumen, la redacción de textos, el diálogo, la extracción y la respuesta a preguntas.

5. **Meta (Llama 3):**

   Llama es una familia de modelos de lenguaje grandes que utiliza datos disponibles públicamente para el entrenamiento. Estos modelos se basan en la arquitectura del transformador, que les permite procesar secuencias de entrada de longitud arbitraria y generar secuencias de salida de longitud variable. Una de las características clave de los modelos Llama es su capacidad para generar textos coherentes y contextualmente relevantes.

6. **Mistral AI (Mistral Large):**

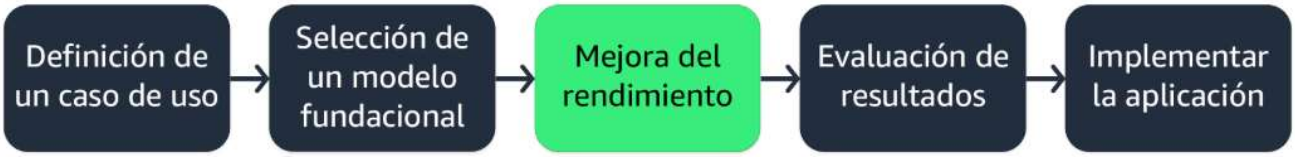
   Mistral AI es un pequeño equipo creativo con altos estándares científicos. Crean modelos de IA eficientes, útiles y confiables a través de innovaciones revolucionarias. Mistral Large es ideal para tareas complejas que requieren grandes capacidades de razonamiento o son altamente especializadas, como la

generación de texto sintético, la generación de código, Generación aumentada de recuperación (Retrieval Augmented Generation, RAG) o agentes.

7. **Stability AI (Stable Diffusion):**
   Stable Diffusion es un modelo de generación de imágenes líder en la industria. Stable Diffusion puede generar imágenes a partir de la entrada de texto.

La compatibilidad de cada uno de estos modelos podría analizarse en función de los criterios de selección y el caso práctico empresarial. Se recomienda revisar y actualizar periódicamente los criterios de selección a medida que surjan nuevos modelos y técnicas, ya que el panorama de la IA generativa está evolucionando rápidamente.

MEJORA DEL RENDIMIENTO DE UN FM



Después de seleccionar un modelo fundacional previamente entrenado adecuado que se alinee con el caso práctico empresarial, el siguiente paso es centrarse en mejorar su rendimiento. Esto se puede lograr mediante diversas técnicas, como la ingeniería de peticiones, el RAG, las operaciones de ajuste o los agentes de automatización.

Ingeniería de peticiones:

La ingeniería de peticiones es la forma más rápida de aprovechar el poder de los modelos de lenguaje grande (LLM). Cuando interactúa con un LLM a través de peticiones (una serie de preguntas, enunciados o instrucciones), puede ajustar el comportamiento de los resultados del LLM en función del contexto específico del resultado que desea lograr.

La ingeniería de peticiones se refiere al proceso de elaborar cuidadosamente las peticiones de entrada o las instrucciones que se dan al modelo para generar los resultados o comportamientos deseados. La redacción, la estructura y el contenido de la petición pueden influir significativamente en la calidad, la relevancia y las características de los resultados generados. La ingeniería de peticiones tiene como objetivo optimizar las peticiones para dirigir la generación del modelo en la dirección deseada, utilizando las capacidades del modelo y, al mismo tiempo, mitigando los posibles sesgos o los resultados no deseados.

Algunos aspectos clave de la ingeniería de peticiones son los siguientes:

- **Diseño:** elaboración de peticiones claras, inequívocas y ricas en contexto que comuniquen la tarea o el resultado deseado al modelo de forma eficaz
- **Aumento:** incorporación de información o restricciones adicionales en las peticiones, tales como ejemplos, demostraciones o instrucciones específicas de cada tarea a fin de guiar el proceso de generación del modelo
- **Ajuste:** refinación y ajuste iterativos de las peticiones en función de los resultados y el rendimiento del modelo, a menudo por medio de evaluaciones humanas o métricas automatizadas
- **Ensamblaje:** combinación de varias peticiones o estrategias de generación a fin de mejorar la calidad general y la solidez de los resultados
- **Minería:** exploración e identificación de peticiones eficaces por medio de técnicas como la búsqueda, la generación o la recuperación de peticiones de bibliotecas de peticiones de gran tamaño

La ingeniería de peticiones es particularmente importante para los modelos de IA generativa. Estos modelos se entrenan con grandes cantidades de datos y pueden mostrar comportamientos no deseados o generar resultados inconsistentes con la tarea o el contexto previstos. Al diseñar cuidadosamente las peticiones, los desarrolladores pueden controlar y dirigir mejor el proceso de generación del modelo, mejorando la calidad, la seguridad y la fiabilidad de los resultados.

Técnica de petición:

Las técnicas de ingeniería de peticiones son estrategias utilizadas para guiar los modelos de IA generativa. Algunas técnicas comunes de ingeniería de peticiones son las siguientes:

- Peticiones sin entrenamiento previo
- Peticiones a partir de algunos ejemplos
- Peticiones en cadena de pensamiento (Chain-of-Thought, CoT)
- Coherencia propia
- Árbol de pensamientos (Tree of Thoughts, ToT)
- Generación mejorada de recuperación (RAG)
- Razonamiento automático y uso de herramientas (ART)
- Peticiones de ReAct

Para los fines de este curso, centrémonos en la generación aumentada de recuperación (Retrieval Augmented Generation, RAG).

RAG:

RAG es una técnica de procesamiento del lenguaje natural (Natural Language Processing, PNL) que combina las capacidades de los sistemas de recuperación y los modelos de lenguaje generativo para producir resultados de texto informativos y de alta calidad.

RAG incorpora dos componentes principales.

- **Un sistema de recuperación:**
  Este componente recupera información relevante de un gran corpus de datos de texto, como una base de conocimientos, páginas web u otras fuentes textuales. El sistema de recuperación utiliza técnicas como la recuperación de información, la indexación dispersa o la recuperación densa para identificar los pasajes o documentos más relevantes para una consulta o contexto de entrada determinado.
- **Un modelo de lenguaje generativo:**
  Este componente es un gran modelo de lenguaje previamente entrenado, como GPT-3, BART o T5, que puede generar texto en lenguaje natural. El modelo de lenguaje toma la consulta o el contexto de entrada, junto con la información relevante recuperada. A partir de esto, genera una salida de texto coherente y fluida que combina el conocimiento recuperado con sus propias capacidades de comprensión y generación de lenguaje.

El enfoque de las técnicas de peticiones de RAG utiliza sistemas de recuperación y modelos de lenguaje generativo. El sistema de recuperación proporciona acceso a una gran cantidad de conocimientos e información fácticos. El modelo de lenguaje generativo puede sintetizar y presentar esta información de una manera natural y coherente, adaptada a la entrada o al contexto específicos.

Aplicaciones empresariales de RAG:

RAG tiene varias aplicaciones empresariales, incluidas las siguientes:

- **Creación de sistemas inteligentes de preguntas y respuestas.**
  RAG se puede utilizar para crear sistemas inteligentes de preguntas y respuestas que puedan recuperar información relevante de grandes bases de conocimientos y generar respuestas en lenguaje natural. Esto puede resultar útil en la atención al cliente, los asistentes virtuales o cualquier dominio en el que los usuarios necesiten información rápida y precisa.



- **Ampliación y enriquecimiento de las bases de conocimientos existentes.**
  RAG también puede ampliar y enriquecer las bases de conocimientos existentes a través de la generación de nuevos conocimientos o la reformulación de la información existente de una manera más natural y comprensible. Esto puede mejorar la accesibilidad y la usabilidad de las bases de conocimientos para varias aplicaciones.



- **Generación de contenido de alta calidad.**
  RAG también genera contenido de alta calidad, como artículos, informes o resúmenes, a través de la combinación de la información recuperada de varias fuentes con las capacidades de generación de lenguaje del modelo. Esto puede resultar útil en ámbitos como el periodismo, la investigación o el marketing de contenidos.



Ejemplos de bases de conocimientos de Amazon Bedrock:

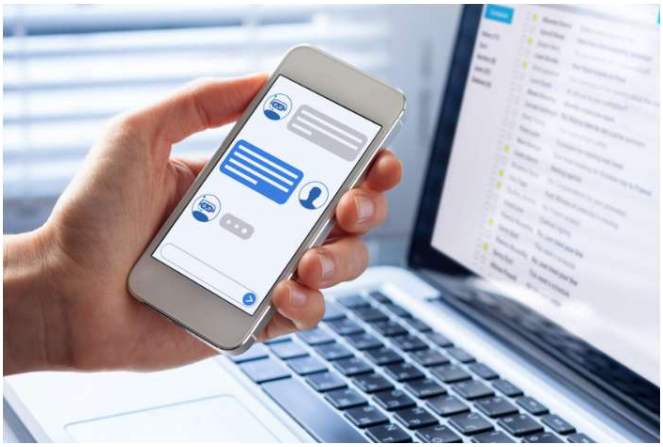
Las bases de conocimientos de Amazon Bedrock le brindan la capacidad de acumular orígenes de datos en un repositorio de información. RAG puede usar bases de conocimientos en varios dominios para proporcionar respuestas, recomendaciones o análisis inteligentes y contextuales mediante la combinación de capacidades de recuperación de información y generación de lenguaje natural. Estos son algunos ejemplos de bases de

conocimientos de Amazon Bedrock que podrían aplicarse a casos prácticos empresariales de generación mejorada por recuperación (RAG):

- **Chatbot de atención al cliente:**

  Base de conocimientos: una base de conocimientos completa del producto que contiene información acerca de los productos, las características, las especificaciones, las guías de solución de problemas y las preguntas frecuentes

  Aplicación de RAG: un chatbot de servicio al cliente que puede responder a las consultas de los clientes por medio de la recuperación de información relevante de la base de conocimientos del producto y la generación de respuestas en lenguaje natural



- **Investigación y análisis jurídicos:**

  Base de conocimientos: una amplia base de conocimientos legales que contiene leyes, reglamentos, precedentes de casos, opiniones legales y análisis por parte de expertos

  Aplicación de RAG: un asistente de investigación legal que puede brindar información y análisis relevantes para consultas legales específicas por medio de la recuperación de información de la base de conocimientos legales y la generación de resúmenes o ideas



- **Preguntas y respuestas sobre atención médica:**

  Base de conocimientos: una base de conocimientos médicos que contiene información acerca de enfermedades, tratamientos, pautas clínicas, artículos de investigación y materiales educativos para pacientes

  Aplicación de RAG: un asistente de salud virtual que puede responder consultas médicas complejas por medio de la recuperación de información relevante de la base de conocimientos y la generación de respuestas concisas y precisas



En general, RAG es una técnica poderosa que combina las fortalezas de los sistemas de recuperación y los modelos de lenguaje generativo. Facilita la creación de sistemas inteligentes que pueden recuperar información pertinente y presentarla de manera natural y coherente. Esto la convierte en una herramienta valiosa para

diversas aplicaciones empresariales relacionadas con la administración del conocimiento, la generación de contenido y los asistentes inteligentes.

Ajuste:

Las operaciones de ajuste son otra forma de mejorar aún más el rendimiento de un modelo fundacional. Las operaciones de ajuste se refieren al proceso de tomar un modelo lingüístico previamente entrenado y seguir entrenándolo en una tarea específica o un conjunto de datos de dominio específico. Las operaciones de ajuste permiten que el modelo ajuste sus conocimientos y capacidades para adaptarse mejor a los requisitos del caso práctico empresarial. Si bien los FM se entrenan previamente mediante un aprendizaje autosupervisado y tienen la capacidad inherente de comprender la información, ajustar el modelo base del FM puede mejorar el rendimiento.

Existen las siguientes dos maneras de ajustar un modelo:

1. El ajuste de las instrucciones utiliza ejemplos de cómo el modelo debe responder a una instrucción específica. El ajuste de las peticiones es un tipo de ajuste de las instrucciones.
2. El aprendizaje por refuerzo a partir de retroalimentación humana (RLHF) proporciona datos de comentarios humanos. El resultado es un modelo que se articula mejor con las preferencias humanas.

Consideremos un caso práctico para realizar ajustes. Si está trabajando en una tarea que requiere conocimientos del sector, puede tomar un modelo previamente entrenado y ajustarlo con los datos del sector. Si la tarea implica investigación médica, por ejemplo, el modelo previamente entrenado se puede ajustar con artículos de publicaciones médicas para lograr resultados más contextualizados.

Cómo funcionan las operaciones de ajuste:

- **Paso 1: Comience con un modelo de lenguaje previamente entrenado.**
  Los modelos de lenguaje grande se entrenan con grandes cantidades de datos de texto de uso general. Esto les ayuda a desarrollar una comprensión amplia del lenguaje y a adquirir conocimientos generales.
- **Paso 2: Prepare un conjunto de datos para tareas específicas.**
  Recopile un conjunto de datos que sea pertinente para la tarea o el dominio en el que desea que se especialice el modelo. Este conjunto de datos debe contener ejemplos de entradas y salidas deseadas para la tarea específica.

- **Paso 3: Agregue capas específicas para cada tarea.**
  La arquitectura del modelo previamente entrenado a menudo se modifica agregando capas o componentes adicionales específicos para la tarea objetivo. Por ejemplo, se puede agregar una capa de clasificación para las tareas de clasificación de texto o un componente decodificador para las tareas de generación de texto.
- **Paso 4: Ajuste el modelo.**
  Luego, el modelo previamente entrenado, con las capas específicas de la tarea agregadas, se ajusta con precisión en el conjunto de datos específico de la tarea. Durante el proceso de ajuste, los parámetros del modelo se actualizan para capturar mejor los patrones y matices presentes en los datos específicos de la tarea.
- **Paso 5: Evalúe e itere.**
  Tras el ajuste, el rendimiento del modelo se evalúa en un conjunto de pruebas para la tarea objetivo. Si el rendimiento no es satisfactorio, el proceso de ajuste se puede repetir con diferentes hiperparámetros, más datos o diferentes arquitecturas específicas de la tarea.

Creación de un modelo fundacional desde cero:

En el contexto del ciclo de vida de las aplicaciones de IA generativa, crear un modelo desde cero implica entrenar una arquitectura de modelo completamente nueva en un conjunto de datos personalizado, sin utilizar ningún modelo o peso preexistente. Por lo general, este enfoque se lleva a cabo cuando no hay modelos previamente entrenados adecuados disponibles para la tarea o el dominio específico, o cuando los requisitos de precisión, rendimiento o personalización son excepcionalmente altos.

El proceso de creación de un modelo desde cero comienza con la definición de la arquitectura del modelo, lo que implica seleccionar la arquitectura, las capas y los hiperparámetros de la red neuronal adecuados en función del problema en cuestión. Este paso requiere un conocimiento profundo de los conceptos y técnicas de machine learning, así como experiencia en el campo para garantizar que el modelo esté diseñado para capturar los patrones y las características relevantes de los datos.

A continuación, se debe seleccionar, limpiar y preprocesar un conjunto de datos grande y diverso para que sirva como datos de entrenamiento para el modelo. Este conjunto de datos debe ser representativo de los datos del mundo real que encontrará el modelo y debe cubrir una amplia gama de escenarios y variaciones.
Una vez preparado el conjunto de datos, el modelo se inicializa con ponderaciones aleatorias y se entrena con varios algoritmos de optimización en un proceso iterativo. Durante el entrenamiento, los pesos del modelo se

ajustan en función de los datos de entrada y los resultados objetivo correspondientes, con la finalidad de minimizar la función de pérdida y mejorar el rendimiento del modelo en función de los datos de entrenamiento. La creación de un modelo desde cero permite una completa personalización y adaptación al problema específico.

Sin embargo, tiene un costo significativo en términos de recursos computacionales, tiempo y experiencia requeridos. Suele ser un enfoque más adecuado para aplicaciones de investigación o altamente especializadas en las que los modelos previamente entrenados existentes son inadecuados o no están disponibles.

Compensaciones de costos de varios enfoques para la personalización del modelo fundacional:

Cuando se desarrolla una aplicación de IA generativa, a menudo hay un equilibrio entre el costo y la precisión a la hora de decidir si utilizar un modelo fundacional previamente entrenado o seguir un enfoque más personalizado.



Los modelos previamente entrenados, como los modelos de lenguaje grande o los modelos de visión artificial, ofrecen una solución rentable. Ya han recibido un entrenamiento vasto sobre grandes cantidades de datos, por lo que requieren menos recursos computacionales y tiempo para ajustar o transferir el aprendizaje. Sin embargo, es posible que estos modelos previamente entrenados no siempre logren el nivel deseado de precisión o rendimiento para tareas o dominios específicos.

La adopción de un enfoque más personalizado, como entrenar un modelo desde cero o ajustar en gran medida un modelo previamente entrenado, puede generar una mayor precisión y un mejor rendimiento adaptados al caso práctico específico. Sin embargo, esta personalización tiene un costo mayor en términos de recursos

computacionales, adquisición de datos y experiencia especializada requerida para la capacitación y la optimización.

A la hora de decidir cuál es la técnica de personalización adecuada para su aplicación de IA generativa, las organizaciones deben evaluar cuidadosamente la relación costo-exactitud. Deben equilibrar sus restricciones presupuestarias, los requisitos de rendimiento y la disponibilidad de datos de alta calidad específicos del dominio.

Tareas automatizadas de varios pasos con agentes:

Los agentes son otro componente de las soluciones de IA generativa que pueden mejorar el rendimiento y las capacidades del modelo fundacional. A medida que los modelos de IA generativa se vuelven más avanzados y capaces, aumenta la necesidad de emplear agentes y la automatización para agilizar y optimizar las distintas fases del ciclo de vida de las aplicaciones. Los agentes desempeñan un papel crucial a la hora de desglosar los procesos complejos en pasos más pequeños y manejables, y de organizar su finalización. Los agentes son componentes o entidades de software diseñados para realizar acciones o tareas específicas de forma autónoma o semiautónoma, en función de reglas o algoritmos predefinidos.

En el caso de Amazon Bedrock, los agentes se utilizan para gestionar y llevar a cabo diversas tareas de varios pasos relacionadas con el aprovisionamiento de infraestructuras, la implementación de aplicaciones y las actividades operativas.

Estos son algunos ejemplos de las tareas que pueden realizar los agentes:

- **Coordinación de tareas:** Los agentes coordinan que las subtareas finalicen en el orden correcto y se aseguran de que se cumplan las dependencias y los requisitos previos antes de continuar con el siguiente paso. Administran el flujo de información y datos entre las diferentes subtareas y se aseguran de que la tarea general avance sin problemas.
- **Informes y registros:** Los agentes pueden brindar registros e informes detallados acerca del progreso y el estado de las tareas de varios pasos, incluidas las métricas, los datos de rendimiento y la información de diagnóstico. Esto ayuda a solucionar problemas, auditar y analizar el proceso general.
- **Escalabilidad y simultaneidad:** Los agentes se pueden diseñar para gestionar varias instancias de tareas de varios pasos de forma simultánea. Esto permite la implementación en paralelo y mejora el rendimiento y la escalabilidad en general.

- **Integración y comunicación:** Los agentes a menudo deben integrarse con otros sistemas, servicios o componentes a fin de intercambiar datos, iniciar acciones o recibir notificaciones. Es posible que se comuniquen a través de API, colas de mensajes u otros canales de comunicación.

En el caso de Amazon Bedrock, los agentes pueden ser responsables de tareas como el aprovisionamiento y la configuración de los recursos de la nube (por ejemplo, instancias de EC2, equilibradores de carga o bases de datos). También pueden implementar aplicaciones o servicios en varios entornos, automatizar las tareas operativas, como las copias de seguridad o el escalado, y supervisar el estado y el rendimiento generales de la infraestructura.

Al utilizar agentes para tareas de varios pasos, las organizaciones pueden lograr niveles más altos de automatización, coherencia y eficiencia en sus operaciones en la nube y, al mismo tiempo, mejorar la visibilidad, el control y la auditabilidad de los procesos involucrados.

EVALUACIÓN DE UN FM.

Evaluación del rendimiento de un modelo fundacional:

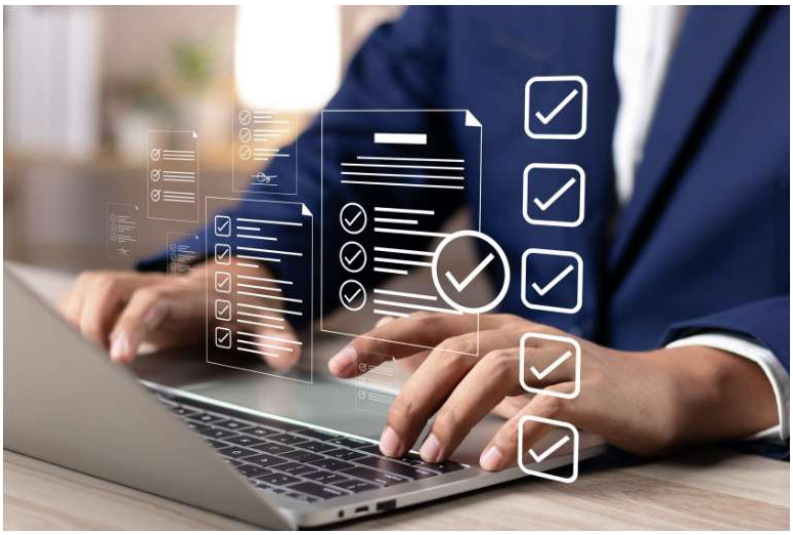


Para determinar si un modelo fundacional cumple eficazmente los objetivos empresariales, es esencial alinear las capacidades del modelo con los requisitos y objetivos específicos de la organización.

Tipos de métodos de evaluación:

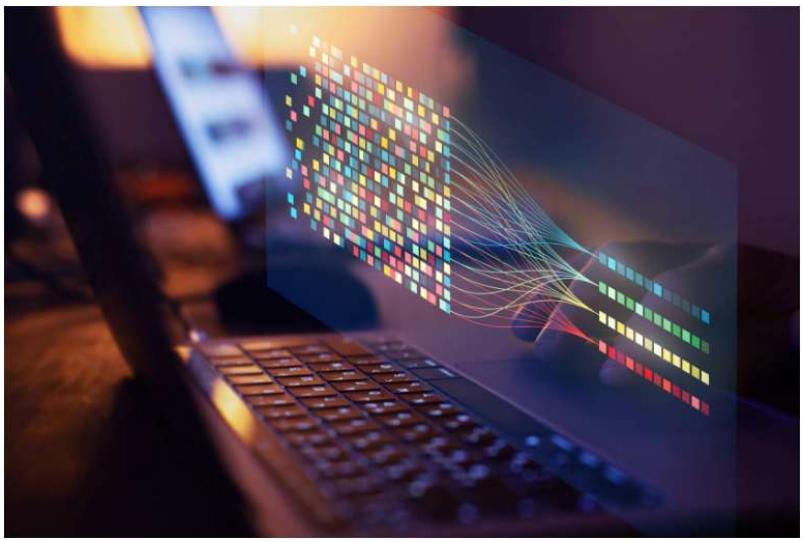
Evaluación humana:

La evaluación humana implica que los humanos interactúen con el modelo fundacional y evalúen su rendimiento en función de criterios específicos. Esto puede incluir tareas como conversaciones abiertas, preguntas y respuestas, generación de texto u otros casos de uso específicos. Los evaluadores humanos pueden proporcionar comentarios cualitativos sobre factores como la coherencia, la relevancia, la factibilidad y la calidad general de los resultados del modelo. Si bien la evaluación humana a menudo se considera el estándar de referencia, puede llevar mucho tiempo y ser costosa, especialmente para las evaluaciones a gran escala.



Conjunto de datos de referencia:

Los conjuntos de datos de referencia son colecciones de datos seleccionadas diseñadas específicamente para evaluar el rendimiento de los modelos de lenguaje u otros sistemas de IA. Estos conjuntos de datos suelen consistir en ejemplos o tareas cuidadosamente seleccionados que cubren una amplia gama de temas, complejidades y fenómenos lingüísticos. Los modelos se evalúan ejecutándolos en estos conjuntos de datos de referencia y midiendo su rendimiento mediante métricas o tareas predefinidas.



Algunos conjuntos de datos de referencia populares para las tareas de procesamiento del lenguaje natural incluyen los siguientes:

- El punto de referencia de la evaluación general de la comprensión del lenguaje (General Language Understanding Evaluation, GLUE) es una colección de conjuntos de datos para evaluar las tareas de

comprensión del lenguaje, como la clasificación de textos, la respuesta a preguntas y la inferencia del lenguaje natural.

- SuperGLUE es una extensión de GLUE con tareas más desafiantes y un enfoque en la comprensión del lenguaje compositivo.
- El conjunto de datos de respuestas a preguntas de Stanford (Stanford Question Answering Dataset, sQuAD) es un conjunto de datos para evaluar las capacidades de respuesta a preguntas.
- El taller sobre traducción automática (Workshop on Machine Translation, WMT) es una serie de conjuntos de datos y tareas para evaluar los sistemas de traducción automática.

Estos conjuntos de datos de referencia proporcionan una forma estandarizada de comparar el rendimiento de los diferentes modelos fundacionales y hacer un seguimiento del progreso a lo largo del tiempo.

Métricas automatizadas:

Si bien la evaluación humana se considera el estándar de referencia, las métricas automatizadas pueden proporcionar una forma rápida y escalable de evaluar el rendimiento del modelo fundacional. Estas métricas suelen medir aspectos específicos de los resultados del modelo, como los siguientes:

- Perplexity (mide qué tan bien el modelo predice el siguiente token)
- Puntuación BLEU (evalúa la traducción automática)
- Puntuación F1 (evalúa tareas de clasificación o reconocimiento de entidades)



Las métricas automatizadas pueden ser útiles para iteraciones rápidas y ajustes precisos durante el desarrollo del modelo, pero a menudo no captan los matices y las complejidades del lenguaje humano y es posible que no se alineen perfectamente con los juicios humanos.

Métricas pertinentes:

Métricas como ROUGE, BLEU y BERTScore proporcionan una evaluación inicial de las capacidades del modelo fundacional.



- **Rouge:**

  Recall-Oriented Understudy for Gisting Evaluation (ROUGE) es un conjunto de métricas que se utilizan para evaluar los sistemas de resumen automático y traducción automática. Mide la calidad de un resumen o traducción generado comparándolo con uno o más resúmenes o traducciones de referencia.

  Ahora que ha revisado ROUGE, pase a la siguiente pestaña para obtener más información sobre BLEU.

- **Bleu:**

  Bilingual Evaluation Understudy (BLEU) es una métrica que se utiliza para evaluar la calidad del texto generado automáticamente, particularmente en el contexto de la traducción automática. Mide la similitud entre un texto generado y una o más traducciones de referencia, teniendo en cuenta tanto la precisión como la brevedad.

  Ahora que ha revisado BLEU, pase a la siguiente pestaña para obtener más información sobre BERTScore.

- **Bertscore:**

  BERTScore es una métrica que evalúa la similitud semántica entre un texto generado y uno o más textos de referencia. Utiliza modelos previamente entrenados de representaciones de codificadores bidireccionales de transformadores (BERT) para calcular las incrustaciones contextualizadas de los textos de entrada y, posteriormente, calcula la similitud de coseno entre ellos.

Estas métricas se suelen utilizar para evaluar el rendimiento de los modelos fundacionales en las tareas de IA generativa, como el resumen de textos, la traducción automática y la generación de texto abierto. Sin embargo, es importante tener en cuenta que, si bien estas métricas proporcionan una medida cuantitativa del rendimiento,

es posible que no siempre se alineen perfectamente con el juicio humano. Con frecuencia se recomienda combinarlos con la evaluación humana para lograr una evaluación más completa.

IMPLEMENTACIÓN DE LA APLICACIÓN.

La fase de implementación del ciclo de vida de la IA generativa garantiza que el modelo entrenado se integre correctamente en el entorno objetivo para su uso práctico. Durante esta fase, se consideran cuidadosamente factores como la arquitectura del sistema, la escalabilidad, la seguridad y la experiencia del usuario para garantizar una implementación eficiente y sin problemas.



Consideraciones clave:

Hay factores que debe tener en cuenta al implementar su modelo en las instalaciones o en la nube. La siguiente lista no es exhaustiva, pero tenga en cuenta estos factores al implementar el modelo.

- **Costo:** pague por los recursos que utiliza, sin tarifas mínimas.
- **Regiones:** la implementación del modelo está limitada a determinadas regiones de AWS.
- **Cuotas:** asegúrese de contar con los recursos de servicio adecuados para su cuenta de AWS.
- **Seguridad:**
  - ✓ Si su modelo está implementado en infraestructura de AWS, la responsabilidad de seguridad es compartida entre la empresa y AWS.
  - ✓ Si se accede a un modelo por fuera de AWS, se deben evaluar las consideraciones de seguridad para los datos que salen de la cuenta de AWS.

Al navegar cuidadosamente por la fase de implementación, las organizaciones pueden aprovechar todo el potencial de los modelos de IA generativa. Esto les permite impulsar la innovación, mejorar la eficiencia operativa y ofrecer experiencias de usuario excepcionales.