OPTIMIZING FOUNDATION MODELS

INTRODUCCIÓN.

En este curso, explorará dos técnicas para mejorar el rendimiento de un modelo fundacional (Foundation Model, FM): la generación mejorada por recuperación (Retrieval Augmented Generation, RAG) y el refinamiento. Aprenderá sobre los servicios de Amazon Web Services (AWS) que almacenan incrustaciones con bases de datos vectoriales y el rol de los agentes en las tareas de varios pasos. También definirá los métodos para el refinamiento de un FM, aprenderá cómo preparar los datos para hacerlo y más.



OPTIMIZACIÓN DE UN MODELO FUNDACIONAL CON GENERACIÓN MEJORADA POR RECUPERACIÓN

CASO EMPRESARIAL

Introducción: EmpresaX, una empresa de telecomunicaciones.

EmpresaX es un proveedor de telecomunicaciones que ofrece servicios de telefonía e internet.

Por lo general, los clientes que tienen problemas se contactan con el centro de soporte de EmpresaX por teléfono, un proceso que es costoso e ineficiente.

Para agilizar el servicio de soporte, EmpresaX está adoptando soluciones en línea. En un principio, creó una sección de preguntas frecuentes en su sitio web para resolver los problemas más comunes. A pesar de esto, el volumen de tickets de soporte en línea sigue siendo alto. Para reducir aún más la carga de trabajo del personal y mejorar la eficiencia del servicio al cliente, EmpresaX está explorando el potencial de la inteligencia artificial (IA) generativa para desarrollar un chatbot. El chatbot sería capaz de guiar a los clientes, responder a los

problemas más comunes y realizar ciertas tareas de forma autónoma, como pedir un teléfono nuevo, actualizar el plan telefónico para obtener más datos 5G, etc.

EmpresaX tiene el objetivo de reducir la cantidad de tickets en línea en un 70 % al implementar el chatbot. La empresa también supervisará el nivel de satisfacción de los clientes a través de una encuesta que les proporcionará luego de resolver los problemas. Con la incorporación del chatbot, la empresa desea alcanzar un nivel de satisfacción de, como mínimo, 4 sobre 5.

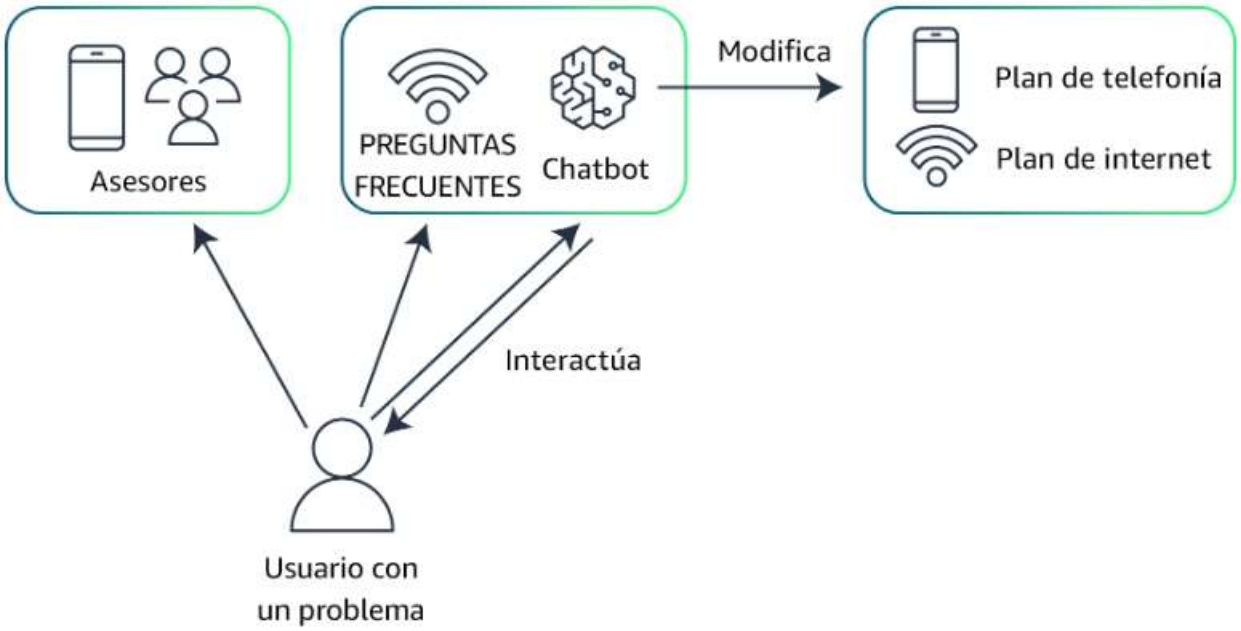


Diagrama de arquitectura del sistema de soporte de EmpresaX.

Profundización de la solución.

Para crear el chatbot, EmpresaX debe elegir un modelo fundacional (FM). El modelo necesitará habilidades de procesamiento de lenguaje natural (Natural Language Processing, NLP), además de una integración con el backend de EmpresaX para la automatización.

EmpresaX debe elegir un modelo de lenguaje grande (Large Language Model, LLM) porque estos FM tienen la capacidad de entender y procesar el lenguaje natural. Los LLM se entrenan con una gran cantidad de datos públicos. Esto es excelente para lograr la comprensión general del lenguaje. Sin embargo, no es la mejor opción para responder a las solicitudes específicas que realizan los clientes sobre los servicios de EmpresaX. Por lo tanto, EmpresaX necesita encontrar una forma de incorporar datos y una base de conocimientos propios para darle más contexto al chatbot y mejorar la exactitud de las respuestas.

Estos datos complementarios pueden provenir de registros de chat, de tickets de soporte gestionados anteriormente o, incluso, de grabaciones de llamadas de soporte. Hay que recopilar, anonimizar y limpiar los datos para poder incorporarlos a una base de conocimientos que, a su vez, pueda ser utilizada por el chatbot.
Por último, dado que EmpresaX está dispuesta a que el chatbot gestione algunas tareas de forma autónoma, este debe poder iniciar funciones adicionales capaces de modificar los parámetros de las cuentas de los clientes.

GENERACIÓN MEJORADA POR RECUPERACIÓN

Introducción.

En la lección anterior, el caso empresarial de EmpresaX demostró que los FM, por sí solos, no son suficientes para proporcionar respuestas idóneas. En esta lección, aprenderá sobre el enfoque de generación mejorada por recuperación (RAG) que permite a los FM consultar las bases de conocimientos para proporcionar respuestas precisas y actualizadas a las indicaciones de los clientes.

Del conjunto de datos a las incrustaciones vectoriales.

Conjuntos de datos empresariales:

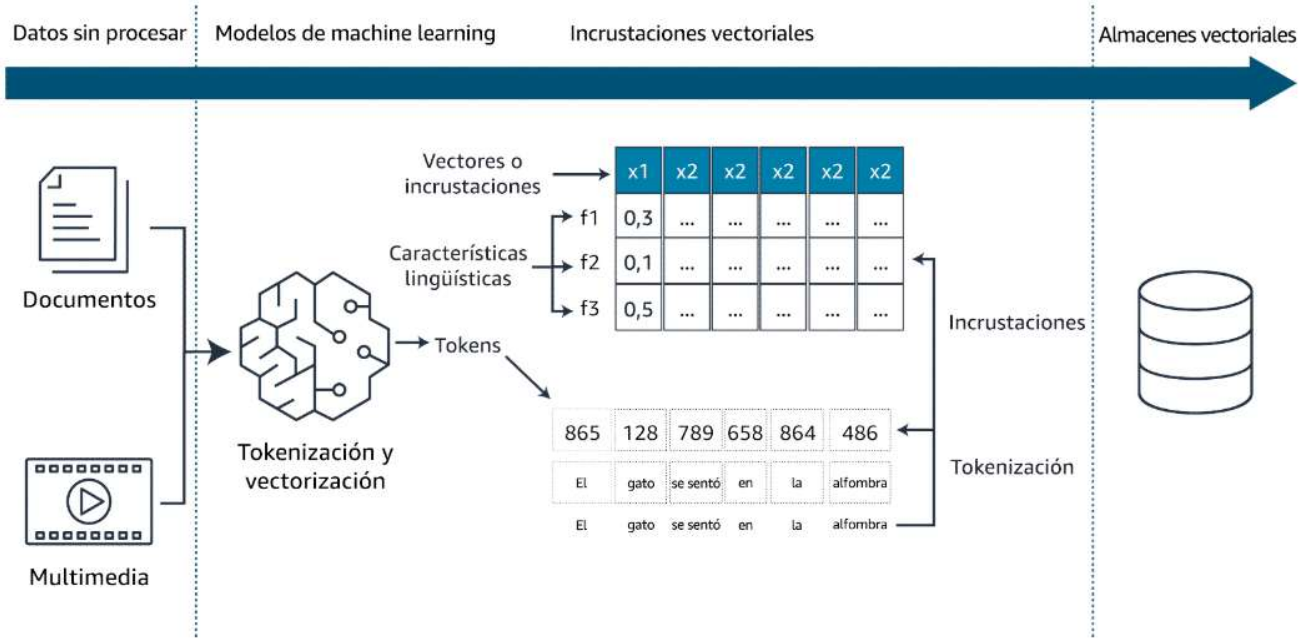
Si bien los LLM pueden generar texto, imágenes, audio y otro contenido similar al que producen los humanos a partir de indicaciones, es posible que esta habilidad no satisfaga las necesidades específicas de las empresas. Las aplicaciones empresariales personalizadas requieren que estos modelos procesen datos relevantes provenientes de conjuntos de datos empresariales.

Las empresas recopilan grandes cantidades de datos internos tales como documentos, presentaciones, manuales de usuario, informes y resúmenes de transacciones, todos ellos desconocidos para el FM. Cuando estos modelos ingieren y utilizan los orígenes de datos empresariales, adquieren conocimientos específicos del dominio, lo que les permite producir respuestas personalizadas y sumamente relevantes que satisfacen las necesidades empresariales.

Los datos empresariales pertinentes que se le brindan al modelo de lenguaje sirven para ampliar el contexto y, junto con la indicación, ayudan al modelo a ofrecer respuestas más precisas. Determinar el contexto correcto implica buscar conjuntos de datos empresariales mediante el texto de las indicaciones. Las incrustaciones vectoriales desempeñan un rol crucial en este proceso.

Incrustaciones vectoriales:

La incrustación es el proceso mediante el cual se asigna una representación numérica a textos, imágenes y audio en un espacio vectorial. Por lo general, la incrustación se realiza mediante un modelo de machine learning (ML). En el siguiente diagrama se proporcionan más detalles sobre la incrustación.



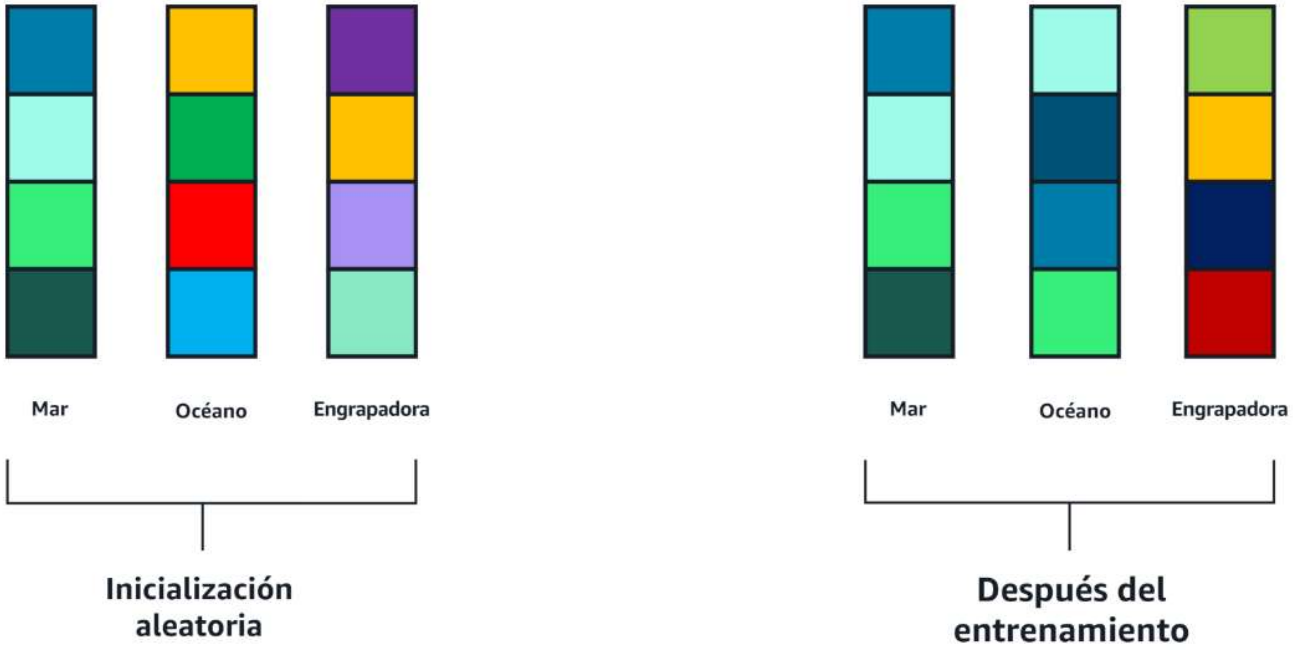
Los conjuntos de datos empresariales, como documentos, imágenes y audio, se pasan a los modelos de ML como tokens y se vectorizan. Estos vectores en un espacio n-dimensional, junto con los metadatos relacionados con ellos, se almacenan en bases de datos vectoriales personalizadas que permiten una recuperación más rápida.

Ahora profundizará en la etapa de incrustación.

Dos palabras relacionadas tendrán incrustaciones similares.

Un ejemplo de estas dos palabras son mar y océano. Se inicializan al azar y las primeras incrustaciones son distintas. A medida que avanza el entrenamiento, las incrustaciones se vuelven similares porque a menudo aparecen cerca y en un contexto similar. Para ilustrar este ejemplo, las incrustaciones que están muy juntas se representan con colores de la misma paleta. Por lo tanto, las palabras mar y océano se representan con colores

similares. Sin embargo, la palabra engrapadora tiene una incrustación completamente diferente, por lo que se representa con un conjunto de colores distinto.



Las palabras que se relacionan entre sí tendrán incrustaciones similares.

Almacenamiento de vectores:

La función principal de las bases de datos vectoriales es almacenar de forma compacta miles de millones de vectores de alta dimensionalidad que representan palabras y entidades. Las bases de datos vectoriales proporcionan búsquedas de similitudes ultrarrápidas entre estos miles de millones de vectores en tiempo real.

Los algoritmos más comunes usados para realizar la búsqueda de similitudes son los k vecinos más cercanos (k-nearest neighbors, k-NN) o la similitud del coseno.

Amazon Web Services (AWS) ofrece las siguientes opciones de bases de datos vectoriales viables:

- Amazon OpenSearch Service (aprovisionada)
- Amazon OpenSearch sin servidor
- Extensión pgvector en Amazon Relational Database Service (Amazon RDS) para PostgreSQL
- Extensión pgvector en Amazon Aurora, edición compatible con PostgreSQL
- Amazon Kendra

La RAG en el contexto del caso empresarial de Empresa X:

A continuación, se presenta una versión actualizada del diagrama de arquitectura de EmpresaX que incluye el sistema de RAG. El chatbot ahora puede consultar una base de datos que contiene datos empresariales y utilizarla para proporcionar respuestas más precisas y contextualizadas a los usuarios.

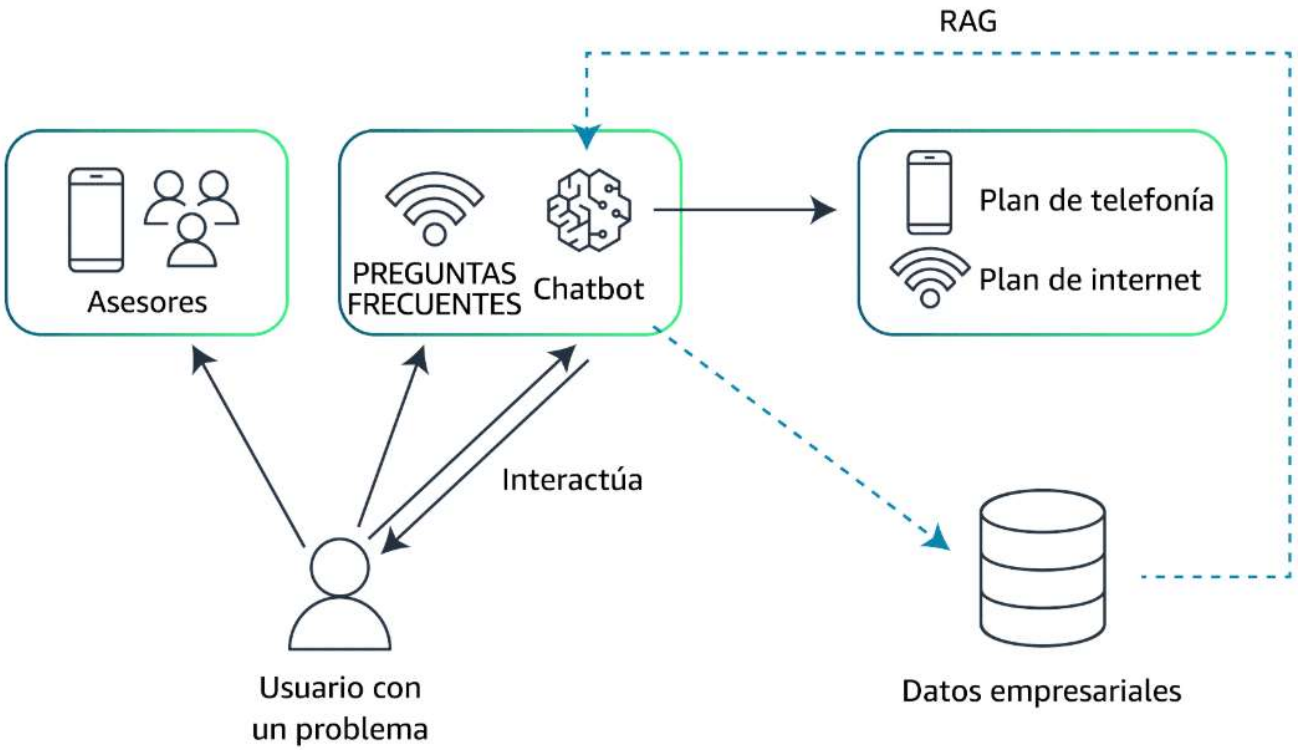


Diagrama de arquitectura del sistema de EmpresaX que incluye un enfoque de RAG para optimizar el rendimiento del modelo.

AGENTES

Introducción.

En esta lección, a partir del caso empresarial de EmpresaX como ejemplo, demostraremos el uso de agentes para cumplir con los requisitos empresariales.

Funciones clave de los agentes:

Los agentes pueden desempeñar diferentes roles en una aplicación de IA generativa, como, por ejemplo:

- **Operaciones intermediarias:** los agentes pueden actuar como intermediarios y facilitar la comunicación entre el modelo de IA generativa y varios sistemas de backend. El modelo de IA generativa gestiona la comprensión del lenguaje y la generación de respuestas. Los diversos sistemas de backend incluyen elementos como bases de datos, plataformas de CRM o herramientas de administración de servicios.

- **Inicio de acciones:** los agentes se pueden utilizar para ejecutar una amplia variedad de tareas. Estas tareas pueden incluir el ajuste de la configuración del servicio, el procesamiento de transacciones, la recuperación de documentos y más. Estas acciones se basan en las necesidades específicas de los usuarios que el modelo de IA generativa logra entender.
- **Integración de la retroalimentación:** los agentes también pueden contribuir al proceso de aprendizaje del sistema de IA por medio de la recopilación de datos acerca de los resultados de sus acciones. Esta retroalimentación ayuda a perfeccionar el modelo de IA, lo que mejorará su precisión y eficacia en futuras interacciones.

Empresa X: el uso de agentes.

EmpresaX es una empresa de telecomunicaciones que utiliza el poder de la IA generativa para reducir la cantidad de tickets que gestiona el personal. Para automatizar el mayor número de tareas, EmpresaX necesita combinar agentes con el modelo de IA generativa.

A continuación, se muestra una vista más detallada de la arquitectura de EmpresaX que incluye agentes. En este diagrama, el agente 1 se usa para tomar medidas sobre los planes de los clientes, según las indicaciones. El agente 2 usa la conversación entre el usuario y el chatbot para actualizar o agregar más datos a la base de datos empresariales. A su vez, esos datos refinados se pueden usar en el sistema de RAG para proporcionar respuestas más apropiadas más adelante. El agente 3 se usa para enviar una encuesta de satisfacción al usuario cuando finaliza la conversación. Esto ayudará a EmpresaX a supervisar el nivel de satisfacción y a alcanzar el objetivo de mejorarlo.

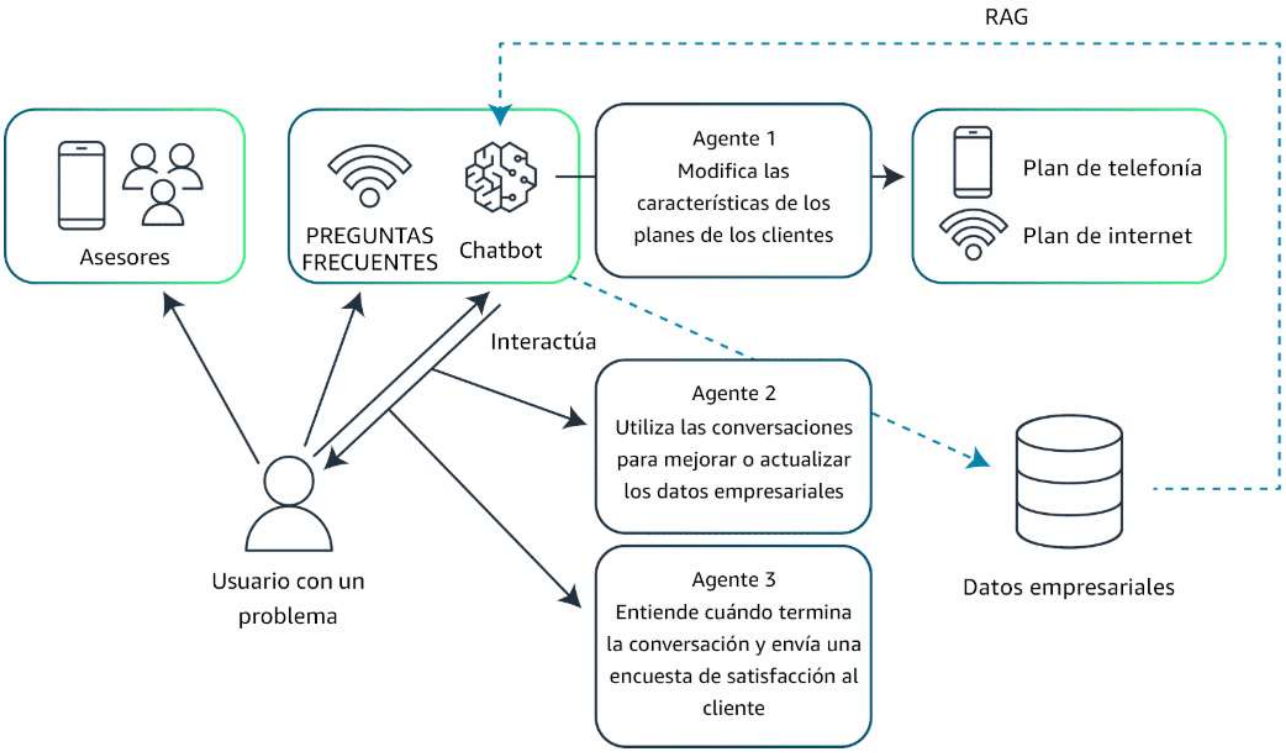


Diagrama de arquitectura de EmpresaX que incluye tres agentes.

EVALUACIÓN DE LOS RESULTADOS

Introducción.

La evaluación del rendimiento de los modelos de IA generativa es fundamental para medir su eficacia y garantizar que cumplan los objetivos previstos. Dos de los métodos de evaluación más comunes son la evaluación humana y el uso de conjuntos de datos de referencia. Cada método proporciona información única y sirve para valorar diferentes aspectos del rendimiento del modelo.

Evaluación humana.

La evaluación humana implica que usuarios reales interactúen con el modelo de IA y proporcionen comentarios basados en su experiencia. Este método es particularmente útil para evaluar los aspectos cualitativos del modelo, como, por ejemplo:

- **Experiencia del usuario**: ¿qué tan intuitiva y satisfactoria es la interacción con el modelo desde la perspectiva del usuario?
- **Adecuación contextual:** ¿el modelo responde de forma contextualmente relevante y sensible a los matices de la comunicación humana?
- **Creatividad y flexibilidad:** ¿qué tan bien maneja el modelo las consultas inesperadas o las situaciones complejas que requieren la comprensión de diferentes matices?

Por lo general, la evaluación humana se utiliza en las mejoras iterativas y el refinamiento para que el modelo cumpla mejor con las expectativas de los usuarios.

Conjunto de datos de referencia.

Los conjuntos de datos de referencia, por otro lado, proporcionan una forma cuantitativa de evaluar los modelos de IA generativa. Son conjuntos de datos predefinidos y métricas relacionadas que ofrecen un medio coherente y objetivo para medir el rendimiento de los modelos. Esto puede incluir lo siguiente:

- **Exactitud:** ¿con qué precisión realiza tareas específicas de acuerdo con los estándares predefinidos?
- **Velocidad y eficiencia:** ¿qué tan rápido genera las respuestas y cómo afecta esto a la eficiencia operativa?
- **Escalabilidad:** ¿puede mantener el nivel de rendimiento a medida que aumenta la magnitud de los datos o la cantidad de usuarios?

Los conjuntos de datos de referencia son particularmente útiles en las fases de prueba iniciales para garantizar que el modelo cumpla con ciertas especificaciones técnicas antes de someterlo a evaluaciones humanas más subjetivas. También son esenciales para comparar el rendimiento de diferentes modelos o de diferentes iteraciones del mismo modelo.

Creación de un conjunto de datos de referencia:

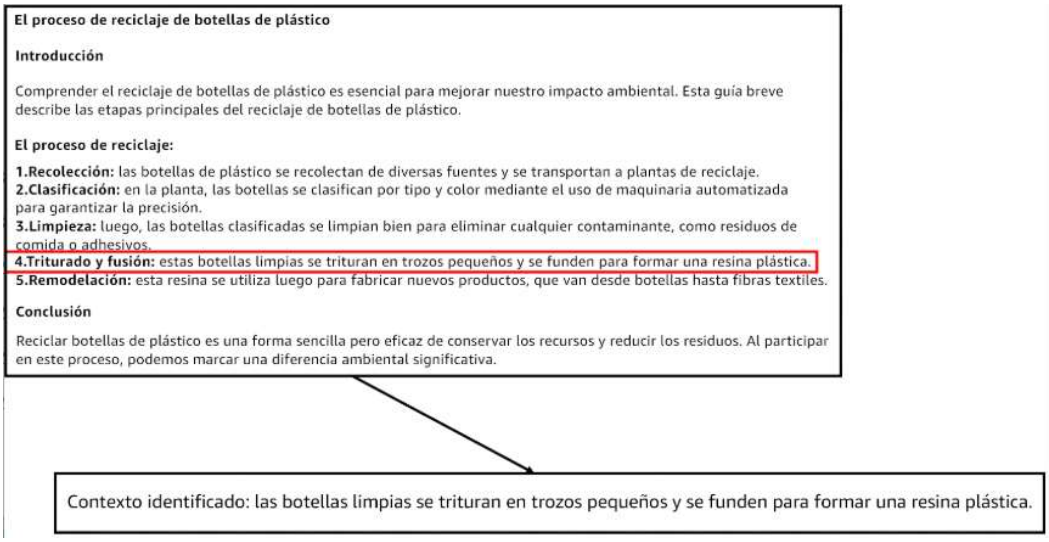
La creación de un conjunto de datos de referencia es clave para evaluar un sistema de RAG.

- **Paso 1: Formulación de preguntas relevantes.**

  Pregunta de ejemplo: "¿Qué sucede con las botellas de plástico durante el proceso de reciclaje?"

  En primer lugar, los expertos en la materia (Subject Matter Experts, SME) formulan preguntas relevantes y desafiantes relacionadas con el tema de interés o con documentos específicos.

- **Paso 2: Identificación del contexto.**



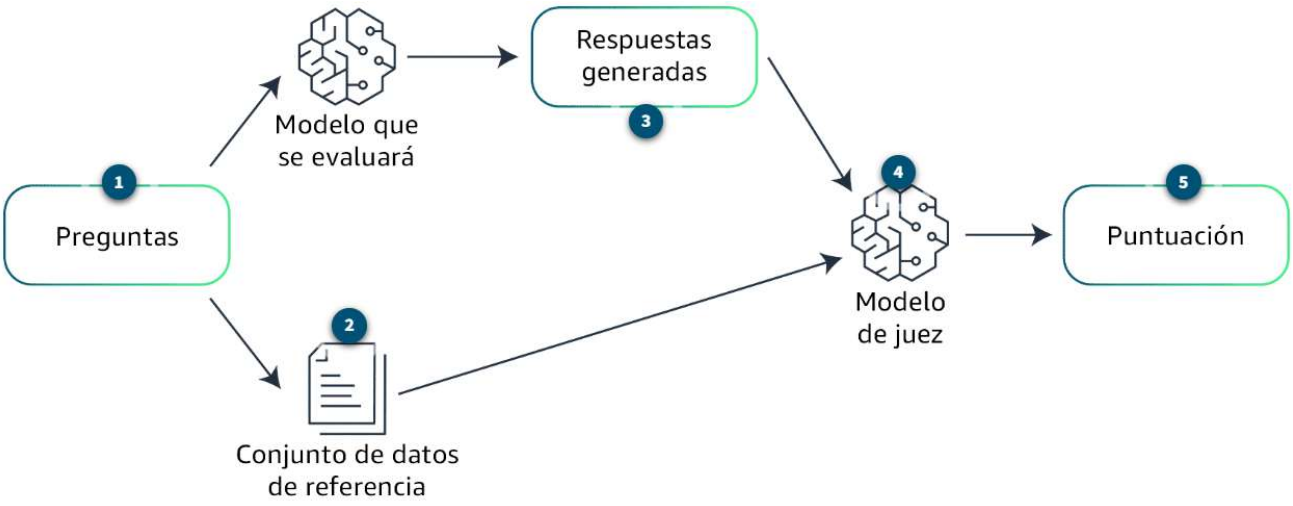
Los SME identifican las secciones de los documentos que proporcionan el contexto necesario para generar respuestas.

- **Paso 3: Redacción de respuestas.**

Respuesta redactada por los SME: "En el proceso de reciclaje, primero se recogen y clasifican las botellas de plástico. Luego, las botellas limpias se trituran en trozos pequeños, se funden y se convierten en una resina plástica que se utiliza para fabricar nuevos productos".

Los SME redactan respuestas precisas que se convierten en el punto de referencia para evaluar las respuestas del sistema de RAG.

La evaluación del rendimiento del LLM por medio de un conjunto de datos de referencia se puede automatizar con un enfoque de *LLM como juez*.



1. **Preguntas.**

Se utiliza una lista de preguntas para crear un conjunto de datos de referencia. Luego, se proporciona la misma lista al modelo para la evaluación de rendimiento.

2. **Conjunto de datos de referencia.**

   El conjunto de datos de referencia contiene tanto las respuestas como el contexto proporcionado por los SME.

3. **Respuestas generadas.**

   El modelo genera respuestas en función de la lista de preguntas.

4. **El modelo de juez.**

   El modelo de juez es un modelo externo que se utiliza para comparar las respuestas de los SME disponibles en el conjunto de datos de referencia con las respuestas generadas por el modelo que se desea evaluar.

5. **Puntuación.**

   El modelo de juez calcula una puntuación para valorar el rendimiento del modelo. Esta puntuación debe tener en cuenta métricas como la precisión (exactitud de la respuesta), la relevancia (adecuación de la respuesta a la pregunta) y la exhaustividad (profundidad y amplitud de la respuesta).

Enfoque combinado.

En la práctica, suele utilizarse una combinación de evaluación humana con conjunto de datos de referencia para proporcionar un panorama general del rendimiento de un modelo. Si bien los conjuntos de datos de referencia pueden cuantificar las habilidades técnicas del modelo, la evaluación humana aporta una perspectiva fundamental centrada en el ser humano que los datos de referencia no pueden captar por sí solos. Este enfoque combinado garantiza que el modelo no solo sea técnicamente competente, sino que también sea efectivo y atractivo en situaciones reales.

Caso empresarial de Empresa X.

Revise el caso empresarial de EmpresaX. Antes de implementar el modelo de chatbot en producción, la empresa puede evaluar el rendimiento del modelo comparándolo con conjuntos de datos de referencia. Una vez que el modelo esté en producción, una persona real interactuará con él y podrá calificar la interacción. Esto ayudará a mejorar la precisión en el futuro.

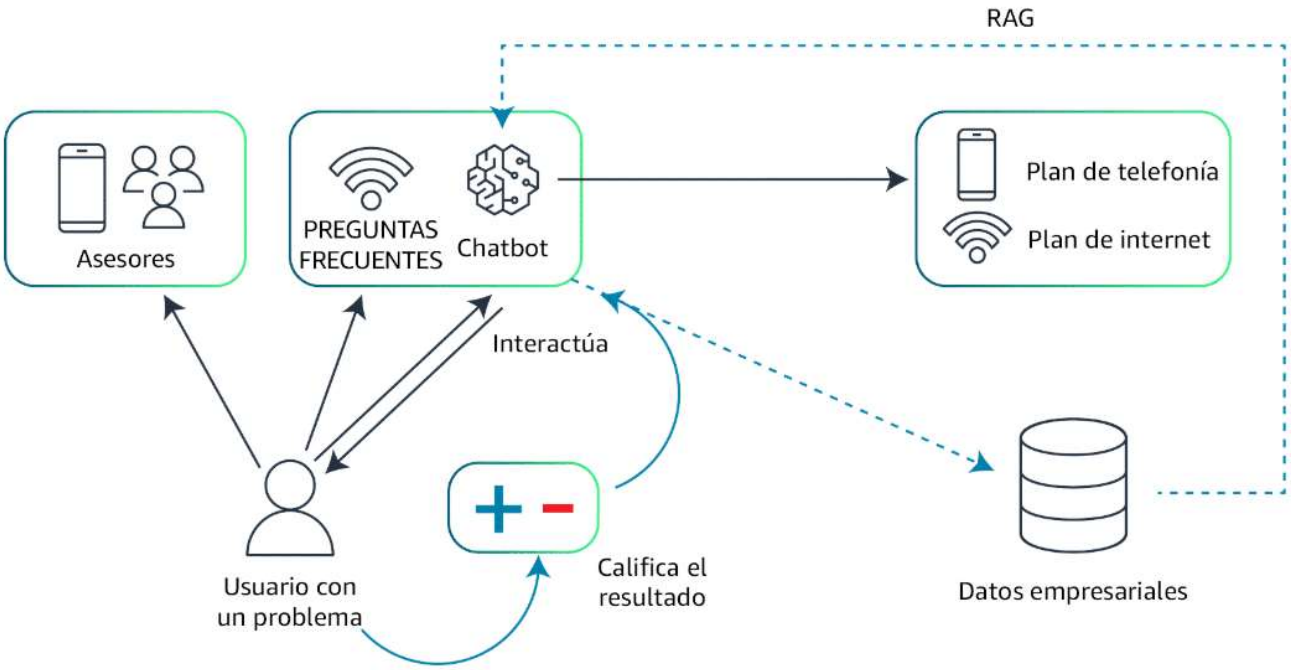


Diagrama de arquitectura de EmpresaX con una valoración humana de la interacción con el modelo.

OPTIMIZACIÓN DE UN MODELO FUNDACIONAL CON REFINAMIENTO

CASO EMPRESARIAL

EmpresaX: un minorista de moda.

EmpresaX, un minorista de moda en línea, se enfrenta a los desafíos que plantean las altas tasas de abandono de carrito y la escasa repetición de compra. Los clientes a menudo se sienten abrumados por la gran cantidad de opciones y les resulta difícil determinar qué productos se adaptan a su estilo y a sus necesidades personales.

EmpresaX tiene como objetivo personalizar la experiencia de compra de manera más efectiva para fomentar la participación de los usuarios, reducir el abandono de carrito y aumentar la repetición de compra.

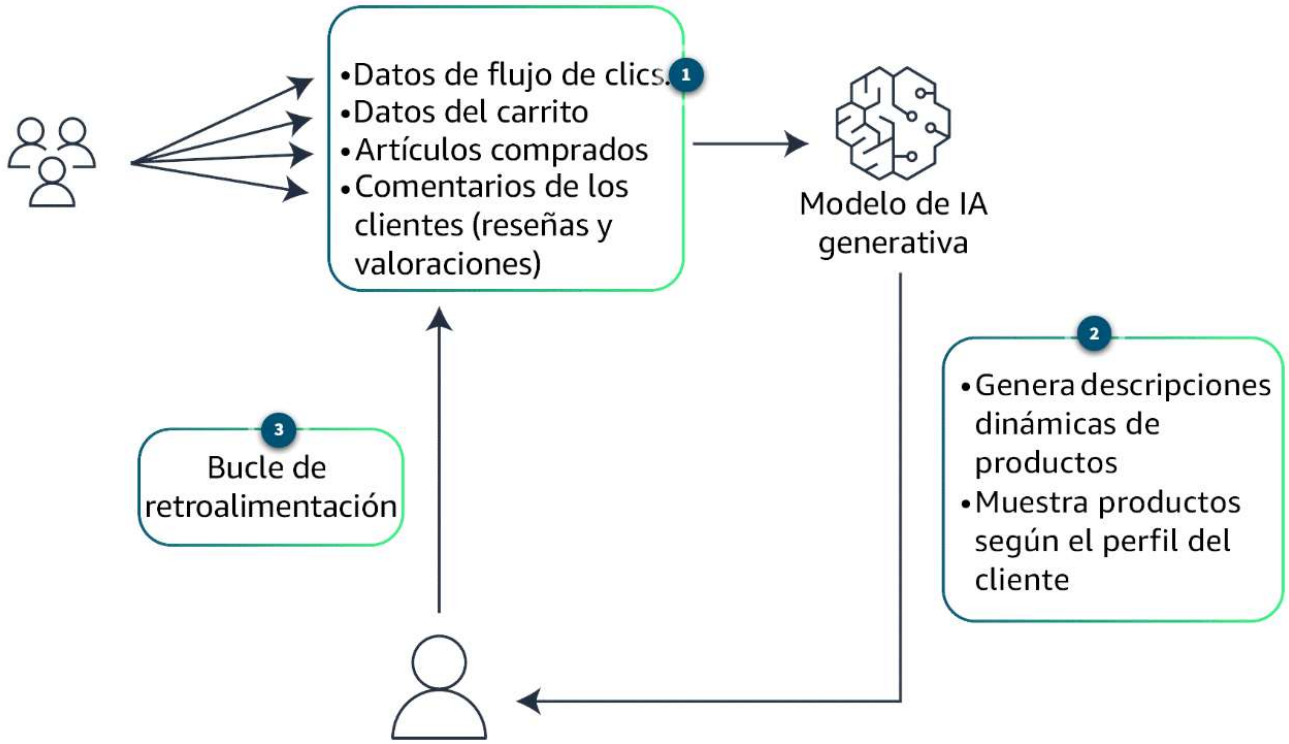
EmpresaX está dispuesta a utilizar el poder de la IA generativa para lograr estos objetivos. En concreto, supervisará las siguientes métricas:

- **Tasa de conversión:** aumento de las compras exitosas por cada visita al sitio
- **Valor promedio de los pedidos:** aumento del monto en dólares de cada transacción
- **Tasa de retención de clientes:** aumento del porcentaje de clientes recurrentes

La solución:

EmpresaX utilizará un LLM que tendrá varias funciones. Generará descripciones dinámicas de productos, ofrecerá asesoramiento personalizado y mejorará las interacciones automatizadas. La solución incluirá lo siguiente:

- **Uso de conjuntos de datos específicos:** refinamiento de los datos transaccionales, comentarios de los clientes y datos de interacción de los usuarios (me gusta, clics, compras anteriores).
- **Integración con el motor de recomendación:** el modelo de IA adapta la exhibición de productos y las promociones a los perfiles de cada cliente en tiempo real.
- **Aprendizaje continuo:** el modelo se ajusta de forma periódica en función de los nuevos datos de los clientes y la evolución de las tendencias de moda, lo que optimiza la exactitud de las recomendaciones sin intervención manual.



1. **Ingesta de datos:**

   Este paso captura la interacción detallada del usuario, los datos y los comentarios de los clientes. Esto ayudará a comprender cómo interactúan los usuarios con las descripciones de producto existentes y sus respuestas o comentarios sobre las características de los productos. Los comentarios de los usuarios también se analizan para identificar el idioma o las tendencias que coinciden con las preferencias de los clientes.

2. **Resultados del modelo:**

   El modelo de IA generativa genera descripciones de producto dinámicas que se basan en las preferencias y hábitos de los clientes, entre otros aspectos.

   Los productos que se le muestran a cada cliente también se modifican de forma dinámica.

3. **Bucle de retroalimentación:**

   Un bucle de retroalimentación utiliza los comentarios y las interacciones de los clientes para refinar aún más el rendimiento del modelo.

REFINAMIENTO

Introducción:

Si bien los modelos fundacionales son muy versátiles, a menudo requieren un refinamiento para adaptar las habilidades generales a aplicaciones específicas o para mejorar el rendimiento en áreas concretas. El refinamiento es fundamental porque ayuda a hacer lo siguiente:

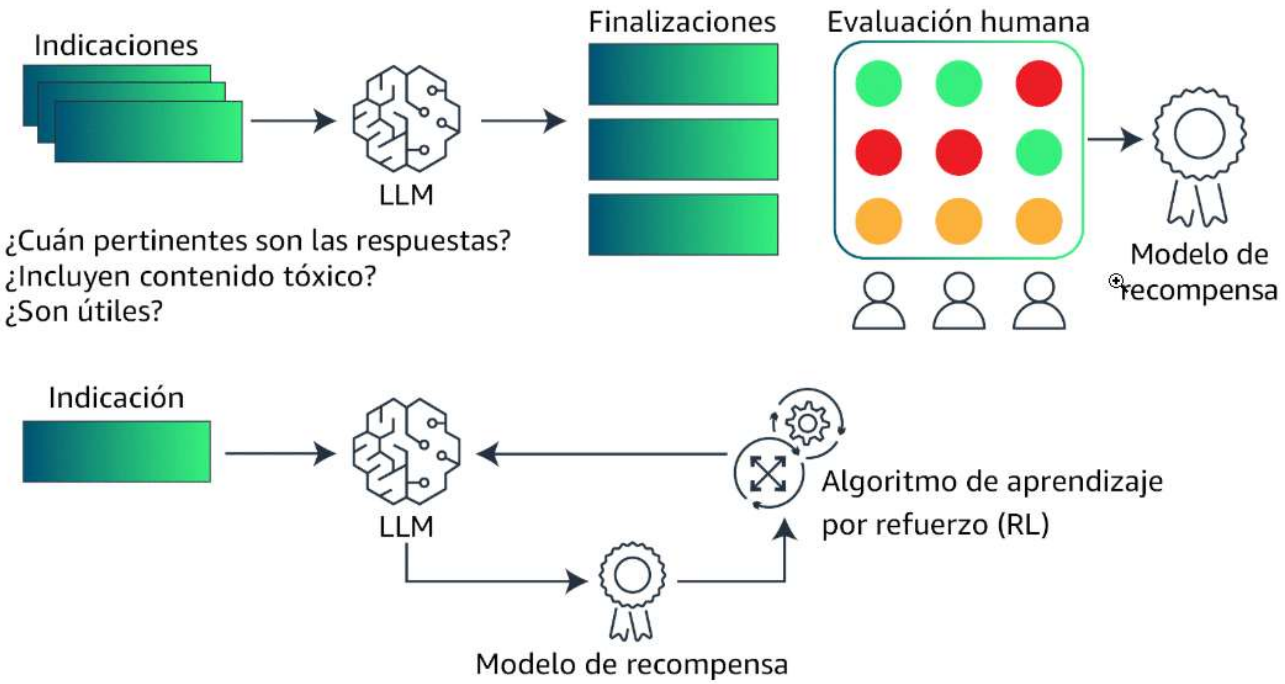
- **Aumentar la especificidad:** se adaptan las respuestas o predicciones del modelo a los matices de un área o una tarea específica que no se cubren de forma adecuada en el entrenamiento inicial.
- **Mejorar la exactitud:** se mejora el rendimiento del modelo en tareas especializadas por medio del entrenamiento con datos específicos del área, lo que reduce los errores que se producen por la naturaleza genérica del entrenamiento básico.
- **Reducir los sesgos:** se aborda y mitiga cualquier sesgo inherente a los datos de entrenamiento inicial, lo que hace que el modelo sea más justo y apropiado para las diferentes aplicaciones.
- **Aumentar la eficiencia:** se agilizan las operaciones del modelo en contextos específicos, lo que podría reducir los requisitos computacionales y acelerar los tiempos de respuesta.

En la siguiente sección, profundizará en las diferentes formas de ajustar con precisión un modelo fundacional.

Los diferentes enfoques de refinamiento:

- **Refinamiento de instrucciones:** este enfoque implica volver a entrenar el modelo con un conjunto de datos nuevo que incluye indicaciones seguidas de los resultados deseados. Está estructurado de manera que el modelo aprenda a seguir mejor las instrucciones específicas. Este método es particularmente útil para mejorar la capacidad del modelo de comprender y ejecutar los comandos del usuario con precisión, lo que lo hace muy eficaz para aplicaciones interactivas como los asistentes virtuales y los chatbots.

- **Aprendizaje por refuerzo a partir de la retroalimentación humana (Reinforcement Learning from Human Feedback, RLHF):** este enfoque es una técnica de refinamiento en la que el modelo inicialmente se entrena por medio del aprendizaje supervisado para predecir respuestas similares a las humanas. Luego, se refina aún más mediante un proceso de aprendizaje por refuerzo, en el que un modelo de recompensa creado a partir de la retroalimentación humana guía al modelo hacia la generación de resultados más deseables. Este método es eficaz para alinear los resultados del modelo con los valores y preferencias humanos, lo que aumenta la utilidad práctica en aplicaciones sensibles.



El RLHF se refiere a la mejora del modelo mediante el aprendizaje de los comentarios proporcionados por humanos, como calificaciones, preferencias, demostraciones, utilidad o toxicidad. El RLHF se usa durante la fase de preentrenamiento del modelo, pero también se puede usar para el ajuste preciso.

- **Adaptación de modelos para áreas específicas:** este enfoque implica el refinamiento del modelo con un corpus de texto o datos específicos de una industria o sector en particular. Por ejemplo, documentos legales para una IA legal o registros médicos para una IA de sanidad. Esta especificidad permite que el modelo funcione con un mayor grado de relevancia y precisión en tareas específicas de un área, lo que proporciona respuestas más útiles y adaptadas al contexto.
- **Aprendizaje por transferencia:** este enfoque se trata de un método a través del cual un modelo desarrollado para una tarea se reutiliza como punto de partida de un modelo que ejecutará una segunda tarea. En el caso de los modelos fundacionales, esto a menudo significa tomar un modelo entrenado con un conjunto de datos amplio y general y, a continuación, refinarlo con un conjunto de datos específico más

pequeño. Este método es muy eficiente para utilizar las características y los conocimientos aprendidos en la fase de entrenamiento general y aplicarlos a un ámbito más reducido que requiera menos entrenamiento adicional.

- **Preentrenamiento continuo:** este enfoque implica extender la fase de entrenamiento de un modelo previamente entrenado y alimentarlo continuamente con datos nuevos y emergentes. Este enfoque se utiliza para mantener el modelo actualizado con la información, el vocabulario, las tendencias o las investigaciones más recientes y garantiza que los resultados sigan siendo relevantes y precisos a lo largo del tiempo.

Preparación de los datos para la etapa de refinamiento:

Durante la fase de entrenamiento inicial, el modelo fundacional se entrena con un conjunto de datos amplio y diverso. Este conjunto de datos generalmente abarca una amplia gama de temas que le permite desarrollar una comprensión amplia y habilidades generales. Los objetivos de esta fase son los siguientes:

- **Cobertura amplia:** garantizar que el conjunto de datos cubra un amplio espectro de conocimientos que le brinde al modelo una comprensión básica sólida
- **Diversidad:** incluir distintos tipos de datos de varias fuentes para dotar al modelo de la capacidad de gestionar una amplia gama de tareas
- **Generalización:** enfocarse en crear un modelo que pueda desempeñar diferentes tareas en diferentes áreas sin una adaptación específica

La preparación de los datos en esta fase implica recopilar la mayor cantidad de datos posible. Los datos suelen provenir de fuentes públicas, de conjuntos de datos seleccionados y, a veces, de datos privados, según el uso que se prevea para el modelo. Los datos necesitan una limpieza exhaustiva y, posiblemente, una anonimización para garantizar la privacidad y el cumplimiento de las normas.

Preparación de datos para el refinamiento:

El refinamiento, por otro lado, es un proceso más específico en el que un modelo preentrenado se adapta para que rinda bien en una tarea específica o dentro de un área en particular. La preparación de los datos para el refinamiento es distinta a la que se utiliza en el entrenamiento inicial por las siguientes razones:

- **Especificidad:** el conjunto de datos para el refinamiento es mucho más focalizado y contiene ejemplos que se relacionan directamente con las tareas o problemas específicos que el modelo debe resolver.
- **Suma relevancia:** los datos deben ser de suma relevancia para los resultados deseados. Por ejemplo, documentos legales para una IA legal o interacciones de servicio al cliente para una IA de atención al cliente.

- **Calidad por encima de cantidad:** aunque el entrenamiento inicial requiere enormes cantidades de datos, el refinamiento a menudo puede lograr mejoras significativas con conjuntos de datos mucho más pequeños, pero bien seleccionados.

Pasos clave en la preparación de datos para el refinamiento:

En la siguiente lista se describen los pasos clave para preparar los datos que se utilizarán en el refinamiento:

1. **Selección de datos:** si bien es una continuación, esta etapa implica un proceso de selección más riguroso a fin de garantizar que cada dato sea de suma relevancia. Este paso también garantiza que los datos contribuyan al aprendizaje del modelo en el contexto específico.
2. **Etiquetado:** en el refinamiento, la exactitud y la relevancia de las etiquetas son fundamentales. Guían los ajustes del modelo para que se especialice en el área deseada.
3. **Gobernanza y cumplimiento:** dado que en el refinamiento a menudo se utilizan datos más especializados, es fundamental garantizar la gobernanza de los datos y el cumplimiento de las normativas específicas de la industria.
4. **Verificación de representatividad y sesgos:** es esencial garantizar que el conjunto de datos de refinamiento no introduzca ni perpetúe sesgos que puedan distorsionar el rendimiento del modelo de forma indeseable.
5. **Integración de comentarios:** en métodos como el RLHF, es fundamental incorporar los comentarios de los usuarios o de los expertos directamente en el proceso de entrenamiento. Tiene más matices y es más interactiva que la fase de entrenamiento inicial.

EVALUACIÓN DE MODELOS

Introducción:

Al evaluar el rendimiento de los modelos de lenguaje, especialmente de aquellos involucrados en la generación o transformación de texto, se pueden usar métricas específicas. Estas métricas evalúan la calidad del resultado comparándolo con un estándar escrito por humanos. Tres métricas que se utilizan comúnmente son: la métrica Suplente para la evaluación de la esencia orientado en la sensibilidad (Recall-Oriented Understudy for Gisting Evaluation, ROUGE), la métrica Evaluación bilingüe suplente (Bilingual Evaluation Understudy, BLEU) y la métrica BERTScore.

ROUGE:

ROUGE es un conjunto de métricas que se utilizan en el NLP para evaluar el resumen automático de textos y la calidad de la traducción automática. La idea principal de ROUGE es contar el número de unidades superpuestas. Esto incluye palabras, n-gramas o fragmentos de oraciones compartidos entre el resultado generado por el equipo y un conjunto de textos de referencia (escritos por humanos).

Dos maneras de usar la métrica ROUGE son las siguientes:

- **ROUGE-N:** métrica que mide la superposición de n-gramas entre el texto generado y el texto de referencia. Por ejemplo, ROUGE-1 se refiere a la superposición de unigramas, ROUGE-2 se refiere a bigramas, etc. Esta métrica evalúa principalmente la fluidez del texto y la medida en que incluye ideas clave de la referencia.
- **ROUGE-L:** métrica que utiliza la secuencia más larga en común entre el texto generado y los textos de referencia. Es particularmente buena para evaluar la coherencia y el orden de la narrativa de los resultados.

La métrica ROUGE es muy utilizada porque no es compleja. Es interpretable y se correlaciona bastante bien con el juicio humano, especialmente cuando se evalúa la exhaustividad de los resúmenes. Las evaluaciones examinan qué parte de la información importante de los textos fuente se incluye en los resúmenes generados.

BLEU:

La métrica BLEU se utiliza para evaluar la calidad del texto traducido automáticamente de un lenguaje natural a otro. La calidad se calcula comparando el texto generado automáticamente con una o más traducciones humanas de alta calidad. Mide la precisión de los n-gramas en el texto generado automáticamente que aparecen en los textos de referencia y aplica una penalización a las traducciones demasiado cortas (penalización por brevedad).

A diferencia de ROUGE, que se centra en la exhaustividad, BLEU es fundamentalmente una métrica de precisión. Comprueba cuántas palabras o frases de la traducción automática aparecen en las traducciones de referencia. BLEU evalúa la calidad a nivel de la oración utilizando, por lo general, una combinación de unigramas, bigramas, trigramas y cuadrigramas. Una penalización por brevedad desincentiva las traducciones demasiado concisas que podrían influir en la puntuación de precisión.

BLEU es muy usada en el campo de la traducción automática porque es fácil de usar y eficaz a gran escala. Sin embargo, tiene limitaciones para evaluar la fluidez y la gramaticalidad del resultado.

BERTScore:

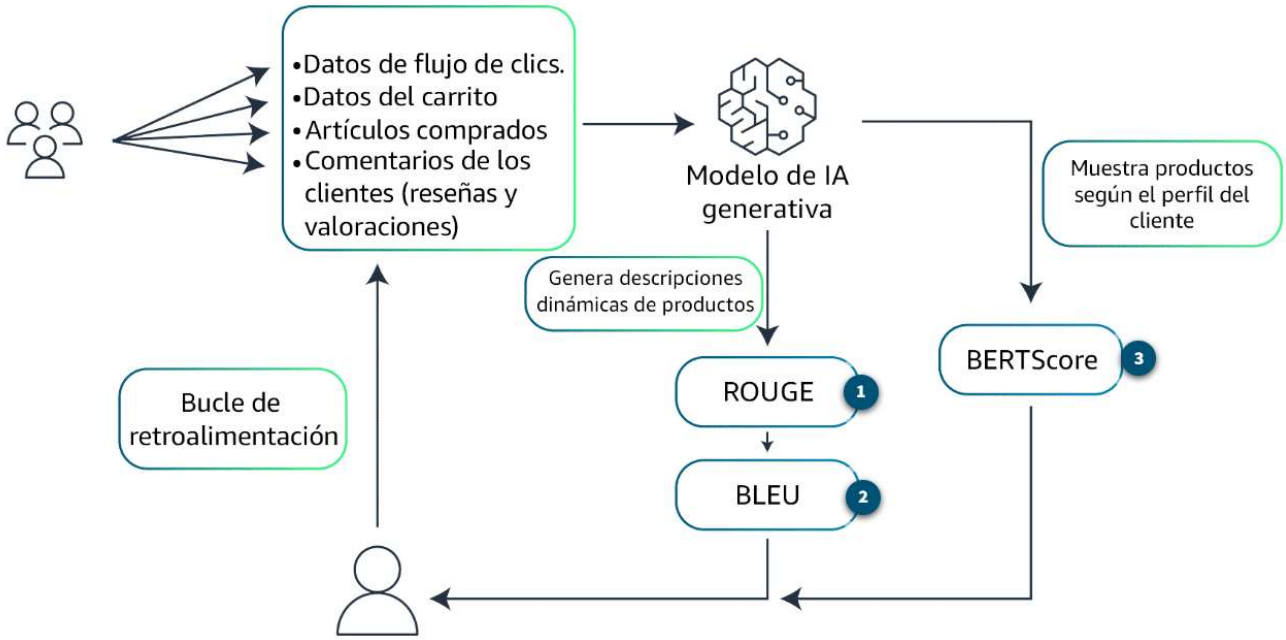
La métrica BERTScore utiliza las incrustaciones contextuales preentrenadas de modelos como BERT para evaluar la calidad de las tareas de generación de texto. Calcula la similitud coseno entre las incrustaciones contextuales de las palabras que aparecen en los textos propuestos y en los de referencia. A diferencia de las métricas tradicionales que se basan en coincidencias exactas de n-gramas o palabras.

Dado que BERTScore evalúa la similitud semántica en lugar de basarse en coincidencias léxicas exactas, es capaz de captar más matices de significado. BERTScore es menos propensa a algunos de los escollos de BLEU y ROUGE. Por ejemplo, es sensible a paráfrasis sutiles o al uso de sinónimos que no afectan al significado general del texto.

BERTScore se utiliza cada vez más junto con métricas tradicionales como BLEU y ROUGE para una evaluación más completa de los modelos de generación de lenguaje. Especialmente en los casos en los que es importante captar el significado semántico más profundo del texto.

Evaluación del modelo de EmpresaX:

Para obtener más información sobre cómo EmpresaX podría usar estas métricas para evaluar el rendimiento de su modelo.



1. **ROUGE.**

   Para las descripciones dinámicas de productos, se puede utilizar ROUGE para garantizar que la información esté completa. (Recordatorio: ROUGE mide la superposición de n-gramas entre la descripción del producto generada por el modelo y la descripción del producto de referencia).
2. **BLEU.**

   BLEU se puede usar en combinación con ROUGE para además garantizar que se incluyan de forma precisa las características críticas del producto y las frases clave que pueden influir en las decisiones de compra.
3. **BERTScore.**

   Para los productos que se muestran, en cambio, se puede utilizar la métrica BERTScore. Evaluará la adecuación semántica y la personalización de la recomendación del producto.

Al abordar los desafíos de EmpresaX relacionados con la alta tasa de abandono de carrito y la escasa repetición de compra, la integración de un FM de IA generativa demostró mejoras sustanciales en métricas empresariales clave. Tras la implementación, la tasa de conversión aumentó un 15 % gracias a descripciones de producto más atractivas. Esta mejora se evidenció cuantitativamente en las puntuaciones de ROUGE con un promedio de 0,85. Esto indica una gran superposición entre el contenido generado por el motor y el del material de referencia, lo que garantiza información completa y relevante que fomentó directamente las compras. El valor promedio de los pedidos aumentó un 20 %. Esto se debe a la precisión y exactitud de los términos técnicos y al lenguaje persuasivo de las descripciones de los productos, validados por una puntuación BLEU de 0,78. Estas puntuaciones se consideran buenas en este contexto, ya que sugieren una fuerte correspondencia con la calidad del lenguaje que históricamente conduce a mayores ventas.

Además, la tasa de retención de clientes mejoró un 25 %, respaldada por las evaluaciones con BERTScore que promediaron 0,90. Esta puntuación alta refleja la excelente calidad semántica de los consejos de compra y de la exhibición de productos personalizados. Esto indica que el contenido no solo es preciso, sino que también se ajusta a las preferencias individuales, lo que mejora la satisfacción y la lealtad del cliente.

Al confirmar la alta calidad y relevancia del contenido generado por la IA, estas métricas han desempeñado un rol fundamental para el cumplimiento de los objetivos de EmpresaX. Estos objetivos incluían mejorar la participación de los usuarios, reducir el abandono de carrito y aumentar la repetición de compra mediante una mejor personalización y precisión del contenido.